

Pipeline SDMX–ISTAT per popolazioni sintetiche comunali

Note tecniche — v0.1

Mirko Degli Esposti

18 luglio 2026

Abstract

Queste note documentano la costruzione e la validazione di una pipeline automatica per l'estrazione di vincoli demografici e socio-economici a livello comunale dal web service SDMX di ISTAT (esploradati.istat.it), finalizzata alla sintesi di popolazioni Max-Ent (GibbsPCD). La pipeline — quattro script Python eseguiti in locale (WSL2, env `m1`) — copre: catalogazione e ricerca sistematica dei 4884 dataflow disponibili; fetch generico guidato dal DSD; costruzione del constraint set per un comune arbitrario. Validazione completa sul caso Brescia (017029, ancoraggio 1/1/2025). Risultato metodologico principale: a livello comunale, anagrafe post-censuaria e censimento permanente coincidono *esattamente* cella per cella su sesso×età ($MAE = 0$), e le stime censuarie via SDMX sono servite non arrotondate; la distinzione hard/soft dei vincoli va quindi ridisegnata.

Contents

1	Scopo e contesto	1
2	Endpoint SDMX esploradati: comportamenti non documentati	2
3	I tre “laghi” del datalake ISTAT	2
4	Catalogo dataflow: la ricerca sistematica	3
5	Architettura della pipeline	3
6	L’ipercubo DCSS	3
7	Rosa dei fondamentali e semantica dei codici	4
8	Constraint set (Brescia 017029, ancoraggio 1/1/2025)	4
9	Risultato chiave: identità anagrafe–censimento	5
10	Da fare / prossimi passi	5

1 Scopo e contesto

Obiettivo: una pipeline riproducibile che, dato un codice comune ISTAT, produca il miglior constraint set ottenibile dai dati pubblici per la sintesi di una popolazione individuale (attributi: sesso, età a singolo anno, stato civile, cittadinanza, istruzione, condizione professionale, nazionalità). Il caso guida è Brescia (SIN Caffaro), con estensione prevista all’attributo di zona

sub-comunale (33 quartieri). Il lavoro sostituisce il precedente flusso su Colab con esecuzione locale (WSL2 Ubuntu, conda env `ml`, storage nativo in `~/progetti/`).

2 Endpoint SDMX esplorati: comportamenti non documentati

Lezioni operative emerse, tutte incorporate come guardie nel modulo `istat_sdmx.py`:

1. **Limite di 260 caratteri per segmento URL.** Il frontend Microsoft (`http.sys`) rifiuta con `400 Bad Request - Invalid URL` qualunque richiesta il cui KEY superi ~260 caratteri come singolo segmento di path — *prima* che la richiesta raggiunga l'applicazione SDMX. Il query builder del sito genera URL che violano questo limite (es. lista esplicita di 101 età). Soluzione: wildcard (posizione vuota nel KEY) e filtro dei codici aggregati a valle.
2. **startPeriod/endPeriod ignorati** su (almeno alcune) dataflow annuali: il server restituisce l'intera serie storica. Il filtro temporale va fatto client-side su `TIME_PERIOD`. Effetto collaterale positivo: serie storiche complete gratis (anagrafe 2019–2025, censimento 2018–2024).
3. **SDMX-CSV via content negotiation.** Con header `Accept: application/vnd.sdmx.data+csv;version=1.0` il server serve CSV direttamente ingeribile da pandas; niente parsing SDMX-ML per i dati.
4. **Rate limit** ~5 query/minuto: throttling globale a 13 s tra richieste; timeout sporadici (retry con backoff, 3 tentativi).
5. **Stime censuarie non arrotondate.** A differenza delle tavole web (che dichiarano arrotondamenti), il canale SDMX serve le stime del censimento permanente con i decimali, internamente additive: i residui totale—somma delle modalità sono *esattamente zero* (cfr. §9).

3 I tre “laghi” del datalake ISTAT

La reperibilità degli attributi a livello comunale è determinata dalla struttura della disseminazione, articolata in tre fonti con proprietà diverse:

Fonte	Contenuto comunale	Età	Natura
Anagrafe / ANPR (DCIS_*)	sex, age, civil status; foreigners; country of citizenship	single year	administrative, reconciled with census
Censimento permanente (DF_DCSS_*)	education, professional, citizenship, families, background migratory, pendularism	single year or classes, second table	stimates (sample + administrative sources), annual from 2018
Indagini campionarie (AVQ, EHIS, ...)	— (only regional/provincial)	classes	stimate survey

Conseguenza architetturale: *spine* anagrafica + *strato* censuario a livello comune; salute e stili di vita entrano solo come condizionali regionali (approccio two-stage, coerente con quanto già fatto per la struttura geografica in Brescia v3).

4 Catalogo dataflow: la ricerca sistematica

Il problema del “non trovare” i dati si risolve scaricando una volta l’elenco completo dei dataflow (/dataflow/IT1: 4884 voci, 13 MB XML) e greppandolo in locale (istat_catalog.py). Osservazioni:

- le tavole censuarie *non* contengono “censimento” nel nome: si riconoscono dal prefisso DF_DCSS_*;
- la granularità è codificata nel suffisso/nome: - comuni (tutti i comuni), _GC (province e grandi comuni), comuni con più di 20.000 ab.;
- il grep per parola chiave (istruzione, condizione prof, cittadin, stranier) individua in pochi secondi la rosa dei dataflow utili.

5 Architettura della pipeline

Quattro script in ~/progetti/gsp/scripts/:

Script	Funzione
istat_catalog.py	scarica/cachea il catalogo dataflow; grep_catalog(pattern)
istat_sdmx.py	modulo generico: cache strutture per dataflow, dimensioni dal DSD, build_key con wildcard, fetch SDMX-CSV, decodifica etichette via mapping dimensione→codelist del DSD, throttling e retry
fetch_comune.py	driver: rosa dei fondamentali per un codice comune; individuazione automatica della dimensione territorio; modalità -explore (solo strutture) / fetch / -only; cache dei CSV scaricati
build_constraints_v1.py	dai CSV decodificati al constraint set (§8); parametrico su comune e anno

Scelte di design rilevanti:

- **KEY guidato dal DSD:** l’ordine delle dimensioni è letto dalla struttura, mai hardcodato; le dimensioni non specificate vanno in wildcard.
- **Decodifica via DSD, non euristica:** il mapping dimensione→codelist è quello dichiarato (una prima euristica per inclusione di codici agganciava CL_ITTER107 alla dimensione sesso).
- **Territorio auto-rilevato:** per ogni tavola si cerca la dimensione la cui codelist contiene il codice comune; robusto a nomi diversi (REF_AREA, ITTER107, ...).
- **Esecuzione staged:** explore (strutture) → smoke test (una tavola) → run completo; ogni fase validata prima della successiva.

6 L’ipercubo DCSS

Tutte le tavole censuarie comunali condividono un unico DSD con ~10 dimensioni (INDICATOR, GENDER, AGE_NOCLASS, CITIZENSHIP, EDU_ATTAIN, CUR_ACT_STAT, LOC_DEST, REAS_COMMUTING, ...): ogni “tavola” è una fetta dell’ipercubo, con le dimensioni non pertinenti fissate al codice totale (TOTAL/ALL/99). Implicazioni:

- le cardinalità delle codelist (es. 343 codici età, inclusi i giorni di vita) sono della codelist condivisa, non della tavola; i valori effettivi li determina il ContentConstraint;
- i CSV contengono molte colonne costanti al totale: firma dell'ipercubo, da collassare nel builder;
- il wildcard su un singolo comune produce risposte piccole (10^2 – 10^3 righe/anno).

7 Rosa dei fondamentali e semantica dei codici

Tavole scaricate per comune (righe riferite a Brescia 017029, tutte le annualità):

Nome	Dataflow	Incrocio	Età	Righe
anag_sesso_eta_statociv	22_289_DF_DCIS_POPRES1_26	S×E×SC	singola	8 568
cens_sesso_eta_cittadinanza	DF_DCSS_POP_DEMCITMIG_SETA_1	S×E×C	singola	3 658
cens_istruzione_eta	DF_DCSS_ISTR_LAV_PEN_2_TV_1	S×E×I	4 classi	819
cens_istruzione_cittadinanza	DF_DCSS_ISTR_LAV_PEN_2_TV_2	C×I	tot. (9+)	441
cens_condprof_eta	DF_DCSS_ISTR_LAV_PEN_2_TV_3	S×E×P	4 classi	819
cens_condprof_cittadinanza	DF_DCSS_ISTR_LAV_PEN_2_TV_4	C×P	tot. (15+)	486
cens_stranieri_paesi	DF_DCSS_POP_DEMCITMIG_TV_3	paese	—	2 454

Semantica dei codici verificata sul dato (non ovvia dalle codelist):

- **Cittadinanza:** il codice effettivo per gli stranieri è FRGAPO (stranieri/apolidi), non FRG; normalizzato a FRG in uscita. Fallback implementato: derivazione per differenza TOTAL–ITL.
- **Condizione professionale, gerarchia a due livelli** (verificata additiva al centesimo): 22 = 1 + 12 (forze di lavoro = occupati + in cerca); 23 = 4 + 5 + 7 + 24 (non forze di lavoro = casalinga/o + studente/ssa + altra condizione + percettore di pensioni/redditi da capitale). Gli aggregati 22/23 vengono scartati *solo se* il rispettivo dettaglio è presente nel dato.
- **Classi d'età per regola di contenimento:** un codice classe è aggregato se il suo intervallo contiene interamente un'altra classe osservata (così Y_GE9 è aggregato, Y_GE65 è elementare); nessun hardcoding per comune o tavola.

8 Constraint set (Brescia 017029, ancoraggio 1/1/2025)

Filosofia: il censimento entra come *distribuzione condizionale applicata ai conteggi anagrafici* (quote censuarie per gruppo × totali anagrafici del gruppo). I marginali demografici restano esatti per costruzione; lo strato socio-economico eredita la struttura censuaria.

File	Tipo	Contenuto	Celle	Somma
c1_sex_age_marital	hard	S×E×stato civile (4 mod.)	712	199 853
c2_sex_age_citizenship	hard*	S×E×ITL/FRG	395	199 853
c3_sex_ageclass_edu	soft	S×classe×istruzione (6 mod.)	48	pop 9+
c4_sex_ageclass_condprof	soft	S×classe×condprof (6 mod.)	48	175 748
c5_edu_citizenship	soft	ITL/FRG×istruzione	12	186 538
c6_condprof_citizenship	soft	ITL/FRG×condprof	12	175 748
nationality_conditional	two-stage	P(paese FRG), 143 paesi	—	—

*riclassificato hard a valle del risultato in §9.

Collassi applicati (mapping stampati e verificati a runtime):

- **Stato civile** 7 → 4: unioni civili assimilate (15 →coniugato/unito, 17 →divorziato/sciolto, 16 →vedovo).
- **Istruzione** 10 → 6 (label-driven, con ordine dei check): nessun_titolo, elementare, media, diploma (USE_IF, incl. IFTS), laurea_o_its (BL: ITS + terziario di I livello), post_laurea (ML_RDD: II livello + dottorato).
- **Condprof** 6 modalità elementari: occupato, in cerca, casalinga/o, studente/ssa, percettore pensioni/redditi, altra condizione.
- **Nazionalità**: filtro keyword degli aggregati (“tutte le voci”, continenti, UE, ...); top-5 Brescia: Romania, Pakistan, Ucraina, Egitto, India; stranieri 38 228 (19,1%).

9 Risultato chiave: identità anagrafe–censimento

Il report di consistenza confronta cella per cella (sesso×età a singolo anno) l’anagrafe all’1/1/2025 con il censimento 2024:

$$\text{MAE} = 0.0, \quad \text{scarto totale} = 0 \text{ su } 199\,853.$$

Le due fonti sono *identiche*: la popolazione post-2018 è census-based e la diffusione SDMX comunale espone la base riconciliata, senza l’arrotondamento delle tavole web (§2, punto 5). Inoltre le stime censuarie sono internamente additive ($\sigma_{\text{arrotondamento}} = 0$ su tutte le tavole con totali).

Implicazione metodologica. La distinzione hard/soft prevista in fase di design va ridisegnata:

- i vincoli demografici (C1, C2) sono di fatto tutti *hard*: stessa base dati riconciliata;
- il carattere *soft* residuo di C3–C6 non deriva da inconsistenza tra fonti (nulla) né da arrotondamenti (nulli), ma esclusivamente dalla natura di stima campionaria delle variabili socio-economiche; l’incertezza pertinente è l’errore campionario documentato da ISTAT per il censimento permanente, non misurabile dagli scarti interni;
- per il solver: partenza con vincoli hard ovunque, regolarizzazione come assicurazione (inversione dell’impostazione iniziale).

10 Da fare / prossimi passi

- ☐ **Adattatore GibbsPCD**: da `constraints_2025/` al formato vincoli del solver; generazione Brescia v4 (8 attributi, nazionalità two-stage).
- ☐ **Livello sub-comunale**: fetch `SUB_MUN_DATA` (tema `censpop`) per le 33 aree sub-comunali di Brescia — sesso, età, cittadinanza, istruzione, condizione professionale su basi territoriali 2021; attributo zona nel MaxEnt con vincoli della stessa fonte censuaria.
- ☐ σ **campionarie**: recuperare gli errori di stima documentati del censimento permanente per parametrizzare i vincoli soft.
- ☐ **Generalizzazione multi-comune**: run su un secondo comune (es. Torino 001272) per verificare robustezza dei collassi label-driven e della gerarchia condprof.
- ☐ Tavole aggiuntive candidate: famiglie (`DF_DCSS_FAMIGLIE_TV_*`), background migratorio (`DF_DCSS_MIGR_BACKG`), pendolarismo.