

Pipeline SDMX-ISTAT per popolazioni sintetiche comunali

Note tecniche — v0.2

M. Degli Esposti

19 luglio 2026 (v0.1: 18 luglio 2026)

Sommario

Queste note documentano la costruzione e la validazione di una pipeline automatica per l'estrazione di vincoli demografici e socio-economici a livello comunale dal web service SDMX di ISTAT (esploradati.istat.it) e — da v0.2 — la loro trasformazione in un ConstraintSet MaxEnt e il fit con i solver del repo `maxent-popsynth-pcd` (esatto e GibbsPCD). Validazione completa sul caso Brescia (017029, ancoraggio 1/1/2025, $|X| = 5376$, $m \simeq 250$). Risultati metodologici principali: (i) anagrafe post-censuaria e censimento permanente coincidono esattamente cella per cella su sesso $\times$ età ($MAE = 0$) e le stime censuarie SDMX sono non arrotondate; (ii) i blocchi di vincoli definiti su un sotto-universo vanno completati a partizione dell'universo del CS, pena infattibilità e collasso del duale; (iii) le esclusioni strutturali ($\alpha = 0$) vanno applicate post-hoc sul supporto, non come vincoli; (iv) su CS reali con α su tre ordini di grandezza, la precisione di GibbsPCD è limitata da un pavimento stocastico *predicibile* $\sqrt{(1-\alpha)/(\alpha N)}$, verificato empiricamente (predetto 0.060, osservato 0.051–0.074); (v) il kernel Numba (lookup CSR) è semanticamente equivalente e $12\times$ più veloce.

Indice

1	Scopo e contesto	2
2	Endpoint SDMX esploradati: comportamenti non documentati	2
3	I tre “laghi” del datalake ISTAT	2
4	Catalogo dataflow: ricerca sistematica	3
5	Architettura della pipeline	3
6	L'ipercubo DCSS	3
7	Rosa dei fondamentali e semantica dei codici	3
8	Tavole-vincolo (Brescia 017029, ancoraggio 1/1/2025)	4
9	Dal constraint set al ConstraintSet: <code>cs_build.py</code>	4
10	Fit: solver esatto e GibbsPCD	4
10.1	Esclusioni strutturali ($\alpha = 0$)	5
10.2	Risultati	5
10.3	Pavimento stocastico di GibbsPCD (finding)	5

10.4 Kernel Numba (fix CSR)	5
10.5 Decisione di produzione	5
11 Da fare / prossimi passi	6

1 Scopo e contesto

Obiettivo: una pipeline riproducibile che, dato un codice comune ISTAT, produca il miglior constraint set ottenibile dai dati pubblici per la sintesi di una popolazione individuale (attributi: sesso, età, stato civile, cittadinanza, istruzione, condizione professionale, nazionalità) e la popolazione MaxEnt corrispondente. Caso guida: Brescia (SIN Caffaro), con estensione prevista all’attributo di zona sub-comunale (33 quartieri). Esecuzione locale (WSL2 Ubuntu, conda env ml, storage in ~/progetti/); sostituisce il flusso Colab.

2 Endpoint SDMX esplorati: comportamenti non documentati

Lezioni operative, incorporate come guardie nel modulo `istat_sdmx.py`:

- Limite ~260 caratteri per segmento URL** (frontend `http.sys`): 400 Bad Request - Invalid URL prima che la richiesta raggiunga il WS; il query builder del sito genera URL che lo violano. Soluzione: wildcard nel KEY e filtro degli aggregati a valle.
- startPeriod/endPeriod ignorati** su dataflow annuali: filtro client-side su `TIME_PERIOD`; effetto collaterale positivo, serie storiche complete (anagrafe 2019–2025, censimento 2018–2024).
- SDMX-CSV via content negotiation** (Accept: `application/vnd.sdmx.data+csv;version=1.0.0`).
- Rate limit ~5 query/min**: throttling 13s; retry con backoff sui timeout sporadici.
- Stime censuarie non arrotondate**: il canale SDMX serve le stime con i decimali, internamente additive ($\sigma_{\text{arrotondamento}} = 0$).

3 I tre “laghi” del datalake ISTAT

Fonte	Contenuto comunale	Età	Natura
Anagrafe / ANPR (DCIS_*)	sesso, età, stato civile; stranieri; paese di cittadinanza	singolo anno	conteggi amministrativi, riconciliati col censimento
Censimento permanente (DF_DCSS_*)	istruzione, condizione professionale, cittadinanza, famiglie, background migratorio, pendolarismo	singolo anno o classi	stime (campione + amm.), annuali dal 2018
Indagini campionarie (AVQ, EHIS, ...)	— (solo regionale/prov.)	classi	stime campionarie

Architettura conseguente: *spine* anagrafica + *strato* censuario a livello comune; salute/stili di vita come condizionali regionali (two-stage).

4 Catalogo dataflow: ricerca sistematica

Elenco completo dei dataflow (/dataflow/IT1: 4884 voci) scaricato una volta e greppato in locale (istat_catalog.py). Le tavole censuarie non contengono “censimento” nel nome: prefisso DF_DCSS_*; granularità nel suffisso (- comuni, _GC, >20.000 ab.).

5 Architettura della pipeline

Sei script in ~/progetti/gsp/scripts/:

Script	Funzione
istat_catalog.py	catalogo dataflow + grep_catalog(pattern)
istat_sdmx.py	modulo generico: cache strutture, dimensioni dal DSD, build_key con wildcard, fetch SDMX-CSV, decodifica via mapping DSD, throttling e retry
fetch_comune.py	rosa dei fondamentali per codice comune; territorio auto-rilevato; -explore / fetch / -only; cache dei CSV
build_constraints_v1.py	dai CSV decodificati alle tavole-vincolo C1-C6 + nazionalità; report di consistenza
cs_build.py	dalle tavole-vincolo al ConstraintSet (§9)
fit_k6c.py	fit esatto + GibbsPCD, diagnostiche, campione sintetico (§10)

Scelte di design: KEY guidato dal DSD (ordine dimensioni mai hardcoded); decodifica via mapping dimensione→codelist dichiarato (non euristica); territorio auto-rilevato; esecuzione staged (explore → smoke test → run).

6 L’ipercubo DCSS

Tutte le tavole censuarie comunali condividono un unico DSD (~10 dimensioni); ogni tavola è una fetta con le dimensioni non pertinenti al codice totale. Cardinalità delle codelist non indicative (le determina il ContentConstraint); molte colonne costanti nei CSV; wildcard su singolo comune ⇒ risposte piccole.

7 Rosa dei fondamentali e semantica dei codici

Tavole per comune (righe: Brescia, tutte le annualità):

Nome	Dataflow	Incrocio	Età	Righe
anag_sesso_eta_statociv	22_289_DF_DCIS_POPRES1_26	S×E×SC	singola	8 568
cens_sesso_eta_cittadinanza	DF_DCSS_POP_DEMCITMIG_SETA_1	S×E×C	singola	3 658
cens_istruzione_eta	DF_DCSS_ISTR_LAV_PEN_2_TV_1	S×E×I	4 classi	819
cens_istruzione_cittadinanza	DF_DCSS_ISTR_LAV_PEN_2_TV_2	C×I	tot. (9+)	441
cens_condprof_eta	DF_DCSS_ISTR_LAV_PEN_2_TV_3	S×E×P	4 classi	819
cens_condprof_cittadinanza	DF_DCSS_ISTR_LAV_PEN_2_TV_4	C×P	tot. (15+)	486
cens_stranieri_paesi	DF_DCSS_POP_DEMCITMIG_TV_3	paese	—	2 454

Semantica verificata sul dato: stranieri = FRGAPO (normalizzato a FRG; fallback TOTAL-ITL); gerarchia condprof additiva al centesimo: 22 = 1 + 12, 23 = 4 + 5 + 7 + 24 (aggregati scartati solo se il dettaglio è presente); classi d’età elementari per regola di contenimento.

8 Tavole-vincolo (Brescia 017029, ancoraggio 1/1/2025)

Filosofia: censimento come distribuzione condizionale applicata ai conteggi anagrafici; marginali demografici esatti per costruzione. Collassi: stato civile $7 \rightarrow 4$ (unioni civili assimilate); istruzione $10 \rightarrow 6$ (label-driven); condprof 6 modalità elementari; nazionalità $P(\text{paese} \mid \text{FRG})$, 143 paesi, stranieri 38 228 (19,1%), top-5 Romania, Pakistan, Ucraina, Egitto, India.

Risultato chiave (v0.1). Raccordo anagrafe 1/1/2025 $\leftrightarrow$ censimento 2024 su sesso $\times$ età: MAE = 0.0, scarto totale = 0 su 199 853. Le due fonti sono la stessa base riconciliata; i vincoli demografici sono tutti hard; il carattere soft residuo delle variabili socio-economiche è il solo errore campionario documentato da ISTAT.

9 Dal constraint set al ConstraintSet: cs_build.py

Livello **K6C**: sesso, età, stato_civile, cittadinanza, istruzione, condizione; $|X| = 2 \times 8 \times 4 \times 2 \times 6 \times 7 = 5\,376$ (la settima modalità di condizione è `non_applicabile`, v. sotto). Bin d'età: 0-8, 9-14, 15-24, 25-34, 35-49, 50-64, 65-74, 75+ — raffinano entrambe le famiglie di classi censuarie; unica spezzatura interna 25-49 $\rightarrow$ 25-34/35-49. Universo default: popolazione intera (`-min-age` per restringere).

Tre primitive modulari:

- `block_exact`: tavola già alla granularità del CS (C1, C2; domani i blocchi zona da SUB_MUN);
- `block_from_class`: attributo $\times$ (sesso, classe censuaria) $\rightarrow$ bin, con allocazione pesata sull'anagrafe a singolo anno. Unica assunzione dichiarata della pipeline: *distribuzione dell'attributo costante entro la classe censuaria*;
- `block_conditional`: quote esterne (regionali/nazionali) $\times$ conteggi comunali — gancio per le fonti two-stage.

Copertura strutturale sotto l'età minima delle tavole: istruzione = `nessun_titolo` sotto i 9 anni; condizione = `non_applicabile` sotto i 15. Blocchi risultanti: A (S $\times$ E $\times$ SC, anagrafe), B (S $\times$ E $\times$ C), C (S $\times$ E $\times$ I), D (S $\times$ E $\times$ P), E (C $\times$ I), F (C $\times$ P), S_i/S_c strutturali; $m = 269$; verifica somme: A = B = E = F = 1.0000; $C+S_i = D+S_c = 1.0000$ esatti.

Lezione di infattibilità (E/F). Nella prima versione E ed F usavano i target censuari del solo universo 9+/15+: con l'universo del CS a popolazione intera, il vincolo di uguaglianza è infattibile (es. la cella (ITL, nessun_titolo) deve contenere anche tutti i bambini italiani under-9: $\mathbb{E}[f] \geq \alpha_E + 0.06$ sempre) $\Rightarrow$ duale illimitato, λ in fuga, collasso della soluzione su una cella ($H = 0$, supporto $1/|X|$), MRE bloccata su plateau. Regola generale: *con vincoli di uguaglianza, ogni blocco definito su un sotto-universo va completato a partizione dell'universo del CS (aggiungendo la massa complementare) oppure dichiarato parziale*. Il completamento usa la ripartizione esatta per cittadinanza degli under-soglia da C2.

10 Fit: solver esatto e GibbsPCD

Setup: `fit_k6c.py`, pruning `-min-alpha 2e-4` (21 vincoli droppati; costo informativo nullo: H della soluzione invariata alla terza cifra), $m = 246$ vincoli effettivi, $\alpha \in [2 \cdot 10^{-4}, 0.37]$.

10.1 Esclusioni strutturali ($\alpha = 0$)

Due vincoli a zero (vedovi 15–24, M e F): zeri anagrafici genuini. Un modello log-lineare non può rappresentare massa nulla con λ finito:

- come vincoli ($\alpha = 0$ o floored a $\varepsilon = 10^{-8}$) avvelenano il duale (direzioni rigide, oscillazioni L-BFGS) e dominano la MRE del solver ($|\hat{\alpha} - \varepsilon|/\varepsilon = O(10)$ anche a fit perfetto), falsando pure il criterio di stop;
- soluzione adottata: **esclusioni fuori dai solver, applicate post-hoc sul supporto** ($p[\text{celle escluse}] = 0$, rinormalizzazione). L’esclusione è una definizione del dominio, non un’aspettazione da matchare.

Massa spontanea del Gibbs sulle celle escluse (misurata pre-azzeramento): $\sim 3 \cdot 10^{-3}$ (≈ 560 individui su 200k) — azzerata a costo zero dal post-hoc.

10.2 Risultati

	$\text{MRE}_{\alpha>0}$	H (nat)	supporto	KL vs exact	tempo
Esatto (L-BFGS)	$5.0 \cdot 10^{-4}$	5.842	4 181/5 376	—	27 s
GibbsPCD ($N=50\text{k}$, no-numba)	$5.1 \cdot 10^{-2}$	6.142	5 208	$7.6 \cdot 10^{-2}$	485 s
GibbsPCD ($N=50\text{k}$, numba)	$7.4 \cdot 10^{-2}$	6.254	5 208	$1.1 \cdot 10^{-1}$	40 s

Campione sintetico $n = 199\,853$ generato dal modello esatto (popolazione_K6C.csv) — bozza Brescia v4 senza zona e nazionalità.

10.3 Pavimento stocastico di GibbsPCD (finding)

Il gradiente PCD stima ogni α_j dal pool: deviazione relativa per sweep $\sqrt{(1 - \alpha_j)/(\alpha_j N)}$. Pavimento MRE predetto:

$$\text{MRE}_{\min} \approx \frac{1}{m} \sum_j \sqrt{\frac{1 - \alpha_j}{\alpha_j N}} = 0.0597 \quad (N = 5 \cdot 10^4),$$

osservato 0.051 e 0.074 su due run indipendenti: **il fit è noise-limited, non sottoallenato**, e il pavimento è calcolabile *a priori*. Regola di dimensionamento: $N \gtrsim 100/\alpha_{\min}$ per $\sim 10\%$ di rumore sul vincolo più piccolo; per una MRE target τ , $N \approx 1/\alpha/\tau^2$. Nota di contesto: i benchmark A0/A1 usano $\alpha \geq 1/n$ da `add_from_data`; il regime $\alpha \ll 1/N_{\text{pool}}$ dei CS reali non era coperto.

10.4 Kernel Numba (fix CSR)

Il lookup dict-of-tuples (non tipabile in nopython) è appiattito in array CSR `int64`; kernel `@njit(parallel=True)` con prange sugli individui (catene indipendenti: parallelizzazione corretta per costruzione). Traiettorie MRE sovrapponibile al path NumPy entro il rumore stocastico; **speedup** $12\times$ ($485\text{ s} \rightarrow 40\text{ s}$, Ryzen AI 9 HX 375, 24 thread). RNG del kernel non seedato e distinto dal path NumPy: riproducibilità tra backend non garantita (da sistemare per gli esperimenti da pubblicazione).

10.5 Decisione di produzione

A livello comunale ($|X| \sim 5 \cdot 10^3$) il solver esatto domina: $100\times$ più preciso, tempi comparabili. Con la zona (33 quartieri, $|X| \approx 1.8 \cdot 10^5$) l’esatto resta praticabile; GibbsPCD è lo strumento per domini non enumerabili, con N dimensionato dalla formula del pavimento. Ruolo attuale del Gibbs: validazione incrociata e caratterizzazione dello strumento (linea “controllability first”).

11 Da fare / prossimi passi

- ☒ Adattatore ConstraintSet (`cs_build.py`) + fit (`fit_k6c.py`) — v0.2.
- ☐ **Livello sub-comunale**: fetch SUB_MUN_DATA (tema `censpop`) per le 33 aree sub-comunali di Brescia; variabile `zona` in testa a `VAR_ORDER`, blocchi esatti; K7C.
- ☐ Nazionalità two-stage sul campione (`nationality_conditional.csv`).
- ☐ Seed esplicito nel kernel Numba (riproducibilità).
- ☐ σ campionarie del censimento permanente per i vincoli soft.
- ☐ Secondo comune (es. Torino 001272): robustezza dei collassi label-driven e della gerarchia `condprof`.
- ☐ Tavole aggiuntive: famiglie, background migratorio, pendolarismo.