

Pipeline SDMX–ISTAT per popolazioni sintetiche comunali e sub-comunali

Note tecniche — v0.3

M. Degli Esposti

19 luglio 2026 (v0.1–v0.2: 18–19 luglio 2026)

Abstract

Pipeline riproducibile dai dati pubblici ISTAT alla popolazione sintetica MaxEnt, ora estesa al livello *sub-comunale*: Brescia K7C con variabile zona a 33 quartieri ($|X| = 177\,408$, $m \simeq 2\,500$), da sezioni di censimento 2023. Risultati principali aggiunti in v0.3: (vi) le sezioni di censimento portano i codici delle aree sub-comunali (COM_ASC1) per tutti i comuni partizionati — niente spatial join; (vii) quinta identità esatta della base riconciliata: sezioni $\equiv$ censimento comunale 2023 $\equiv$ anagrafe 1/1/2024 = 198 259 alla persona; (viii) **lezione di consistenza generalizzata**: con vincoli di uguaglianza devono coincidere *tutti* i margini impliciti sovrapposti tra blocchi, non solo quelli verso la spine — violarla produce collasso del duale; l’IPF entra come *armonizzatore di tabelle* a monte del MaxEnt (non come solver); (ix) terza verifica della formula del pavimento stocastico PCD (predetto 0.0650, osservato 0.0634, $N = 2 \cdot 10^5$): da osservazione a risultato replicato; (x) il pavimento limita lo *stimatore-pool*, non la distribuzione appresa: la MRE dei λ mediati da Adam batte il pavimento di $\sim 2\times$.

Contents

1	Scopo e contesto	1
2	Endpoint SDMX esplorati: comportamenti non documentati	1
3	Le fonti: tre laghi più uno	2
4	Brescia: sezioni, quartieri, audit	2
5	K7C: disegno dei blocchi di zona	2
5.1	Lezione di consistenza generalizzata (e collasso istruttivo)	3
6	Fit K7C	3
6.1	Pavimento stocastico: terza verifica (risultato replicato)	3
6.2	Stimatore-pool vs distribuzione appresa (finding)	3
6.3	Decisione di produzione (ribadita)	4
7	Architettura aggiornata della pipeline	4
8	Sintesi dei livelli	4
9	Da fare / prossimi passi	4

1 Scopo e contesto

Obiettivo: dato un codice comune ISTAT, produrre il miglior constraint set dai dati pubblici e la popolazione MaxEnt corrispondente; caso guida Brescia (SIN Caffaro), ora con attributo di zona a 33 quartieri. Esecuzione locale (WSL2, env ml); solver dal repo `maxent-popsynth-pcd` (esatto L-BFGS, GibbsPCD con kernel Numba CSR).

2 Endpoint SDMX esploradati: comportamenti non documentati

(v0.1, invariata)

1. limite ~ 260 char/segmento URL (`http.sys`) $\Rightarrow$ wildcard;
2. `startPeriod/endPeriod` ignorati $\Rightarrow$ filtro client-side; serie storiche complete gratis;
3. SDMX-CSV via Accept: `application/vnd.sdmx.data+csv;version=1.0.0`;
4. rate limit ~ 5 /min, throttling 13s, retry;
5. stime censuarie comunali *non arrotondate* (decimali, additive).

3 Le fonti: tre laghi più uno

Ai tre laghi di v0.1 (anagrafe DCIS_*; censimento permanente DF_DCSS_*; indagini campionarie, solo regionali) si aggiunge il canale **sub-comunale**:

- le *aree sub-comunali* (ASC) aggregate via SDMX (DF_BULK_SUBCOM2021/2023) coprono **solo i capoluoghi delle Città Metropolitane**: Brescia esclusa;
- le *sezioni di censimento* coprono tutti i comuni: bulk download (niente SDMX, niente rate limit) `Dati_regionali_2023.zip` su `esploradati.istat.it/databrowser/DWL/PERMPOP/SUBCOM/` — un xlsx per regione + `TRACCIATO FILE REGIONALI.xlsx`; edizione censimento 31-12-2023 (agg. 5/3/2026: più variabili, +59 comuni); disponibile anche il 2021;
- **scoperta chiave**: il file sezioni contiene le colonne `COM_ASC1/2/3` — i codici delle aree sub-comunali sono assegnati sezione per sezione *per tutti i comuni partizionati*. Per Brescia `COM_ASC1` ha 33 valori (17029001–17029033) = i 33 quartieri: lo spatial join sezioni $\rightarrow$ quartieri è superfluo, basta un groupby.

Variabili del tracciato utili: sesso $\times$ età quinquennale (P30–45, P67–82), istruzione a 5 livelli per sesso (P86–100, universo 9+), occupati 15–64 per sesso (P101–103), italiani/stranieri per sesso $\times$ macro-età (IT1–12, ST22–33), UE/extra-UE, background migratorio (EM1–6), famiglie (PF), abitazioni.

4 Brescia: sezioni, quartieri, audit

1 822 sezioni, 33 quartieri; 1 sezione fittizia (888888x, senza fissa dimora): 549 persone, assegnate da ISTAT al quartiere 17029004 — **tenute** (opzione a: coerenza contabile con i totali ufficiali; esclusione con riscalatura come variante documentata per l'analisi di esposizione Caffaro).

Quinta identità esatta della base riconciliata:

sezioni 2023 $\equiv$ censimento comunale 2023 $\equiv$ anagrafe 1/1/2024 = 198 259 (alla persona; stranieri 37 478).

Additività interna piena (classi età $\rightarrow$ P1; istruzione $\rightarrow$ P83). Differenza di convenzione: le sezioni sono in *interi* (allocazione RBI $\leftrightarrow$ RSBL di individui interi), il canale SDMX comunale

in stime decimali — scarti di unità possibili sui sotto-totali, assorbiti dal disegno condizionale (§5).

Ancoraggio temporale K7C: -anno 2024 (anagrafe 1/1/2024 $\equiv$ censimento 31-12-2023 $\equiv$ sezioni), tutto sulla stessa data. Tabelle di quartiere (`build_zona_tables.py`): Z1 zona $\times$ sexso $\times$ età5 (1 056 righe), Z2 zona $\times$ sexso $\times$ macro-età $\times$ ITL/FRG (396), Z3 zona $\times$ sexso $\times$ istruzione5 (330), Z4 zona $\times$ sexso $\times$ occupato/non (132, 15–64). Sanity qualitativa: top-5 quota stranieri = Fiumicello (0.371), Centro Storico Nord (0.303), Primo Maggio (0.285), Don Bosco (0.276), Chiesanuova (0.259) — la geografia sociale dell’orbita SIN Caffaro.

5 K7C: disegno dei blocchi di zona

Livello **K7C**: zona in testa a VAR_ORDER; $|X| = 33 \times 5\,376 = 177\,408$. Scelta di arietà: *piena* dove il dato la sostiene (Z2 a arietà 4: zona $\times$ sexso $\times$ età $\times$ cittadinanza cattura direttamente “dentro Fiumicello gli stranieri sono giovani”, non solo i due fatti separati).

Principio: ogni tabella di zona entra come $P(\text{zona} \mid \text{gruppo}) \times$ conteggi comunali del gruppo, mai come conteggi grezzi: i margini sommati sulle zone coincidono coi blocchi comunali per costruzione. Assunzioni aggiuntive dichiarate: (2) quota di zona costante entro la classe quinquennale (Z1) e la macro-classe (Z2); (3) $P(\text{zona} \mid \text{sexso}, \text{occupato})$ costante sui bin 15–64 (Z4, che vincola il solo lato occupato).

5.1 Lezione di consistenza generalizzata (e collasso istruttivo)

Il primo fit K7C è collassato con firma nuova: discesa (MRE 0.26 $\rightarrow$ 0.06 in 40 iter), poi *risalita* fino a plateau (3.4). Causa: i blocchi Z definivano gli stessi pattern impliciti attraverso decomposizioni condizionali diverse — es. sul bin 15–24 il totale (zona, sesso, età) secondo Z1 usa le quote quinquennali 15–19/20–24, secondo Z2 (sommato sulle cittadinanze) la quota piatta della macro-classe 15–64: due valori diversi per lo stesso pattern $\Rightarrow$ vincoli di uguaglianza contraddittori $\Rightarrow$ duale illimitato.

Regola generalizzata (estende la lezione E/F di v0.2): *con vincoli di uguaglianza devono coincidere numericamente TUTTI i margini impliciti sovrapposti tra blocchi — non solo quelli verso la spine; l’audit deve verificarli tutti prima del fit.*

Fix: IPF come armonizzatore di tabelle (non come solver). Per ogni (sexso, bin): IPF sulla matrice 33×2 zona $\times$ cittadinanza con margini-riga = Z1 e margini-colonna = blocco comunale B (Z2); per sesso: zona $\times$ istruzione con righe Z1 e colonne totali comunali (Z3); Z4 con cap cellwise su Z1 e ridistribuzione (34 celle cappate su Brescia). Audit post-armonizzazione: Z2-vs-Z1 e Z3-vs-Z1 $\max |\Delta| \sim 10^{-11}$; Z-vs-comunale = 0. Ruolo concettuale: il raking, perdente come solver (AISTAT), è lo strumento giusto per rendere mutuamente consistenti tabelle sovrapposte *a monte* del MaxEnt.

6 Fit K7C

Setup: `fit_cs.py` (generalizza `fit_k6c.py`; firme dei blocchi per nome variabile, robuste allo shift di indici della zona), pruning -min-alpha 2e-4, $m = 2\,216$ effettivi su 2 513; esclusioni $\alpha = 0$ fuori dai solver, post-hoc sul supporto (5 544 celle: $2 \times 33 \times 2 \times 6 \times 7$). Matrice indicatrice F : 3.15 GB, costruita in 4 s.

	MRE $_{\alpha>0}$	H (nat)	supporto	KL vs exact	tempo
Esatto (L-BFGS)	$3.6 \cdot 10^{-4}$	9.157	130 161/177 408	—	351 s
GibbsPCD ($N=2 \cdot 10^5$, numba)	$3.1 \cdot 10^{-2}$	9.592	171 864	$1.2 \cdot 10^{-1}$	1 070 s

Nota su H: se la zona fosse indipendente dagli attributi, $H \approx H_{K6C} + H(\text{zona}) \approx 5.84 + 3.4$; il deficit misura l'informazione mutua $\text{zona} \leftrightarrow \text{attributi}$ catturata dal CS. Campione $n = 198\,259$ dal modello esatto (`popolazione_K7C.csv`, con colonna quartiere); marginali di zona e quote stranieri per quartiere riprodotti (check sostanziale superato).

6.1 Pavimento stocastico: terza verifica (risultato replicato)

$$\text{MRE}_{\min} \approx \frac{1}{m} \sum_j \sqrt{\frac{1 - \alpha_j}{\alpha_j N}} : \quad \begin{array}{ll} \text{K6C, } N=5 \cdot 10^4 : & \text{pred. } 0.0597, \text{ oss. } 0.051/0.074; \\ \text{K7C, } N=2 \cdot 10^5 : & \text{pred. } 0.0650, \text{ oss. } 0.0634. \end{array}$$

Su un CS $9\times$ più grande e con spettro di α diverso, la predizione a priori sbaglia del 2%: il pavimento è calcolabile dal solo constraint set, prima di ogni run. Regole di dimensionamento: $N \gtrsim 100/\alpha_{\min}$; per MRE target τ : $N \approx 1/\alpha/\tau^2$.

6.2 Stimatore-pool vs distribuzione appresa (finding)

A convergenza, MRE calcolata sulle *frequenze empiriche del pool* = 0.063 (al pavimento); MRE calcolata sulla *distribuzione implicata dai λ* (via matrice indicatrice) = 0.031: fattore ~ 2 . I λ sono mediati nel tempo da Adam lungo centinaia di outer e integrano l'informazione di molti pool successivi: **il pavimento stocastico limita lo stimatore-pool (singolo snapshot), non la distribuzione appresa**. Corollario: se il deliverable è p_λ (o un campione da essa) anziché il pool finale, la precisione effettiva è migliore del pavimento nominale.

6.3 Decisione di produzione (ribadita)

Anche a $|X| = 1.8 \cdot 10^5$ il solver esatto domina: $100\times$ più preciso a un terzo del tempo. GibbsPCD: strumento per domini non enumerabili, con N dimensionato dalla formula; ruolo attuale, caratterizzazione dello strumento (“controllability first”).

7 Architettura aggiornata della pipeline

Script	Funzione
<code>istat_catalog.py</code>	catalogo 4884 dataflow + grep
<code>istat_sdmx.py</code>	modulo SDMX generico (KEY dal DSD, CSV, cache, retry)
<code>fetch_comune.py</code>	rosa dei fondamentali comunali per codice comune
<code>build_constraints.py</code>	tavole comunali $\rightarrow$ vincoli C1–C6 + nazionalità
<code>build_zona_tables.py</code>	sezioni $\rightarrow$ tabelle di quartiere Z1–Z4 + audit
<code>cs_build.py</code> (v2)	vincoli $\rightarrow$ ConstraintSet; livelli K6C/K7C; IPF di armonizzazione
<code>fit_cs.py</code>	fit esatto + GibbsPCD (K6C/K7C), diagnostiche, popolazione

8 Sintesi dei livelli

	anno	$ X $	m	MRE esatto	H (nat)
K6C	1/1/2025	5 376	269	$5.0 \cdot 10^{-4}$	5.842
K7C	1/1/2024	177 408	2 513	$3.6 \cdot 10^{-4}$	9.157

9 Da fare / prossimi passi

- ☒ Livello sub-comunale K7C (sezioni $\rightarrow$ 33 quartieri, IPF, fit) — v0.3.
- ☐ **Run B** (pool = popolazione + λ caldi dall'esatto): misura diretta della fluttuazione stazionaria = pavimento isolato dal transiente; richiede warm start nel GibbsPCDSolver (subclass).
- ☐ Nazionalità two-stage sul campione K7C (`nationality_conditional.csv`); poi via/civico entro quartiere (macchinario v3).
- ☐ Seed esplicito nel kernel Numba (riproducibilità tra backend e tra run).
- ☐ Variante Caffaro: esclusione sezione fittizia (549) con riscalatura, per l'analisi di esposizione.
- ☐ σ campionarie del censimento permanente; secondo comune (Torino 001272); tavole aggiuntive (famiglie, background migratorio, UE/extra-UE come raffinamento cittadinanza).
- ☐ Aggiornamento periodico: sub-comunale 2024 quando rilasciato (piano ISTAT: annuale) $\rightarrow$ riallineamento in avanti.