

Pipeline SDMX–ISTAT per popolazioni sintetiche comunali e sub-comunali

Note tecniche — v0.4

M. Degli Esposti

19 luglio 2026 (v0.1–v0.3: 18–19 luglio 2026)

Abstract

Pipeline riproducibile dai dati pubblici ISTAT alla popolazione sintetica MaxEnt con quartieri: Brescia K7C, 198 259 individui $\times$ 11 attributi (`popolazione_K7C_naz.csv`). In v0.4: (xi) nazionalità two-stage gerarchica — area UE/extra-UE condizionata a (zona, sesso) dalle sezioni, paese condizionato a (area, sesso) dal comunale, allocazione esatta largest-remainder; doppia contabilità comunale $\leftrightarrow$ sezioni verificata a $\sim 3\%$; mappa quartiere $\times$ paese-top qualitativamente corretta (Fiumicello/Chiesanuova a trazione Pakistan, Primo Maggio/Don Bosco a trazione Romania); (xii) ricettario di esecuzione end-to-end della pipeline (§9). Risultati precedenti: identità esatte della base riconciliata ($5\times$); regole di feasibility (completamento a partizione; consistenza di tutti i margini sovrapposti + IPF come armonizzatore); formula del pavimento stocastico PCD replicata 3 volte; stimatore-pool vs distribuzione appresa.

Contents

1	Scopo e contesto	1
2	Endpoint SDMX esploradati: comportamenti non documentati	2
3	Le fonti: tre laghi più uno	2
4	Brescia: sezioni, quartieri, audit	2
5	K7C: blocchi di zona, feasibility, IPF	2
6	Fit K7C e caratterizzazione GibbsPCD	3
7	Nazionalità two-stage (livello 1)	3
8	Sintesi dei livelli e deliverable	3
9	Ricettario: esecuzione della pipeline	3
9.1	Adattamento a un comune diverso da Brescia	5
10	Da fare / prossimi passi	5

1 Scopo e contesto

Dato un codice comune ISTAT, produrre il miglior constraint set dai dati pubblici e la popolazione MaxEnt corrispondente; caso guida Brescia (SIN Caffaro) con zona a 33 quartieri. Esecuzione locale (WSL2, env `ml`); solver dal repo `maxent-popsynth-pcd`.

2 Endpoint SDMX esploradati: comportamenti non documentati

1. limite ~ 260 char/segmento URL (`http.sys`) $\Rightarrow$ wildcard nel KEY;
2. `startPeriod/endPeriod` ignorati $\Rightarrow$ filtro client-side (serie storiche complete gratis);
3. SDMX-CSV via `Accept: application/vnd.sdmx.data+csv;version=1.0.0`;
4. rate limit ~ 5 /min: throttling 13s, retry con backoff;
5. stime censuarie comunali *non arrotondate* (decimali, additive).

3 Le fonti: tre laghi più uno

Anagrafe (DCIS_*, singolo anno d'età); censimento permanente comunale (DF_DCSS_*, ipercubo unico, granularità nel suffisso); indagini campionarie (solo regionali $\rightarrow$ condizionali two-stage); canale sub-comunale:

- ASC aggregate via SDMX (DF_BULK_SUBCOM*): solo capoluoghi Città Metropolitane;
- **sezioni di censimento**, tutti i comuni: `bulk Dati_regionali_<anno>.zip` (xlsx per regione + tracciato) su `esploradati.istat.it/databrowser/DWL/PERMPOP/SUBCOM/`; edizioni 2021 e 2023 (rilascio annuale a regime);
- scoperta chiave: `COM_ASC1/2/3` nel file sezioni — i codici delle aree sub-comunali sono già assegnati sezione per sezione per tutti i comuni partizionati (Brescia: 33 valori = quartieri; spatial join superfluo).

Variabili del tracciato: sesso $\times$ età quinquennale, istruzione a 5 livelli per sesso (9+), occupati 15–64 per sesso, ITA/stranieri per sesso $\times$ macro-età, **UE/extra-UE per sesso** (ST16–21), background migratorio, famiglie, abitazioni.

4 Brescia: sezioni, quartieri, audit

1 822 sezioni, 33 quartieri; sezione fittizia 888888x (549 senza fissa dimora) tenuta nel quartiere assegnato 17029004 (opzione a). **Quinta identità esatta**: sezioni $\equiv$ censimento comunale 2023 $\equiv$ anagrafe 1/1/2024 = 198 259 (stranieri 37 478); additività interna piena. Sezioni in interi (RBI $\leftrightarrow$ RSBL), comunale in stime decimali: scarti di unità assorbiti dal disegno condizionale. Ancoraggio K7C: -anno 2024. Sanity: top-5 quota stranieri = Fiumicello (0.371), Centro Storico Nord, Primo Maggio, Don Bosco, Chiesanuova — l'orbita SIN Caffaro.

5 K7C: blocchi di zona, feasibility, IPF

zona in testa a `VAR_ORDER`; $|X| = 33 \times 5\,376 = 177\,408$; arietà piena dove il dato la sostiene (Z2: zona $\times$ sesso $\times$ età $\times$ cittadinanza). Principio: ogni tabella di zona entra come $P(\text{zona} \mid \text{gruppo}) \times \text{conteggi comunali}$. Assunzioni (2) quota di zona costante entro quinquennale/macro-classe; (3) $P(\text{zona} \mid \text{sesso, occ})$ costante sui bin 15–64.

Regola di consistenza generalizzata (dal collasso discesa $\rightarrow$ risalita del primo fit): con vincoli di uguaglianza devono coincidere numericamente *tutti* i margini impliciti sovrapposti tra blocchi, non solo quelli verso la spine. **Fix: IPF come armonizzatore di tabelle** (righe da Z1, colonne dal blocco comunale, per gruppo); Z4 con cap su Z1 e redistribuzione. Audit post: Z-vs-Z $\sim 10^{-11}$, Z-vs-comunale = 0.

6 Fit K7C e caratterizzazione GibbsPCD

	$\text{MRE}_{\alpha>0}$	H (nat)	supporto	KL vs exact	tempo
Esatto (L-BFGS)	$3.6 \cdot 10^{-4}$	9.157	130 161/177 408	—	351 s
GibbsPCD ($N=2 \cdot 10^5$, numba)	$3.1 \cdot 10^{-2}$	9.592	171 864	$1.2 \cdot 10^{-1}$	1 070 s

Esclusioni ($\alpha = 0$) fuori dai solver, post-hoc sul supporto (5 544 celle). **Pavimento stocastico replicato** (terzo punto): predetto 0.0650, osservato 0.0634 ($N = 2 \cdot 10^5$); formula $\text{MRE}_{\min} \approx m^{-1} \sum_j \sqrt{(1 - \alpha_j)/(\alpha_j N)}$ calcolabile dal solo CS. **Stimatore-pool vs distribuzione appresa**: MRE su frequenze del pool 0.063 (al pavimento), MRE su p_λ 0.031: i λ mediati da Adam battono il pavimento del singolo snapshot di $\sim 2\times$. Decisione di produzione: esatto anche a K7C (100 $\times$ più preciso, 1/3 del tempo); GibbsPCD per domini non enumerabili, N dalla formula.

7 Nazionalità two-stage (livello 1)

La nazionalità (143 paesi) resta fuori dal MaxEnt (nessun incrocio vincolabile; $|X|$ esploderebbe) ed entra come assegnazione gerarchica sul campione (`assign_nationality.py`):

- (2a) $\text{area} \in \{\text{UE}, \text{EXTRA_UE}\} \sim P(\text{area} \mid \text{zona}, \text{sezzo})$ dalle sezioni (ST17/18/20/21; UE+extraUE = ST1 esatto, apolidi assorbiti in extra-UE);
- (2b) $\text{paese} \sim P(\text{paese} \mid \text{area}, \text{sezzo})$ dal comunale (DF_DCSS_POP_DEMCITMIG_TV_3, 2023, GENDER conservato); classificazione UE label-driven (23 paesi UE presenti a Brescia; Cechia/Lussemburgo/Malta assenti dal dato, non errori di match).

Allocazione **esatta** (largest remainder) a entrambi i livelli, shuffle seedato entro gruppo. **Assunzione (4)**: $\text{paese} \perp \text{zona} \mid (\text{area}, \text{sezzo})$ — la struttura territoriale entra al livello area; il limite è visibile (dentro l’extra-UE stesso mix in tutti i quartieri).

Validazione: doppia contabilità comunale $\leftrightarrow$ sezioni per area $\times$ sezzo coincide a $\sim 3\%$ (canali indipendenti); top-10 campione = Romania, Pakistan, Ucraina, India, Egitto, Cina, Albania, Moldova, Sri Lanka, Filippine (ordine reale, Ucraina con asimmetria F via condizionamento per sesso); paese-top per quartiere: Fiumicello e Chiesanuova $\rightarrow$ Pakistan, Primo Maggio e Don Bosco $\rightarrow$ Romania — differenziazione emergente da $P(\text{area} \mid \text{zona}, \text{sezzo})$.

8 Sintesi dei livelli e deliverable

	anno	$ X $	m	MRE esatto	H (nat)
K6C	1/1/2025	5 376	269	$5.0 \cdot 10^{-4}$	5.842
K7C	1/1/2024	177 408	2 513	$3.6 \cdot 10^{-4}$	9.157

Deliverable: `popolazione_K7C_naz.csv` — 198 259 individui $\times$ 11 attributi (zona, quartiere, sesso, eta, stato_civile, cittadinanza, istruzione, condizione, area, paese; ITL $\rightarrow$ paese Italia), ancorati all’1/1/2024, con 4 assunzioni dichiarate e numerate.

9 Ricettario: esecuzione della pipeline

Sequenza completa da zero a `popolazione_K7C_naz.csv`. Prerequisiti: env ml attivo; repo `maxent-popsynth-pcd` clonato in `~/progetti/`; `pip install lxml openpyxl`. Script in `~/progetti/gsp/scr`. Le fasi 0–4 sono **generiche per qualunque comune** (parametro `<codice>`, ITTER107); le

fasi 5–8 sono generiche nel disegno ma gli script attuali hanno tre punti parametrizzati su Brescia, elencati in §9.1.

Fase 0 — catalogo (una tantum, riusabile).

```
python istat_catalog.py          # scarica e indicizza 4884 dataflow
python istat_catalog.py istruzione # esempio di grep esplorativa
```

Fase 1 — tavole comunali (esplorazione staged, poi fetch; ~3 min per il throttling).

```
python fetch_comune.py <codice> --explore # strutture: dimensioni,
    territorio
python fetch_comune.py <codice>          # 7 tavole -> data/comuni/<codice>/
    >/
```

Fase 2 — tavole-vincolo comunali (per ogni ancoraggio che serve; K7C usa -anno 2024).

```
python build_constraints.py <codice> --anno 2024
python build_constraints.py <codice> --anno 2025 # opzionale, K6C recente
```

Verificare nel log: pop totale plausibile; report.md con MAE del raccordo (atteso ≈ 0 post-2018).

Fase 3 — ConstraintSet K6C e fit (opzionale ma consigliato come regressione).

```
python cs_build.py <codice> --anno 2025
python fit_cs.py <codice> --anno 2025 --eps 1e-8 --min-alpha 2e-4 --no-gibbs
```

Fase 4 — sezioni di censimento (bulk, nessun rate limit).

```
mkdir -p ~/progetti/gsp/data/submun && cd ~/progetti/gsp/data/submun
wget https://esploradati.istat.it/databrowser/DWL/PERMPOP/SUBCOM/
    Dati_regionali_2023.zip
unzip Dati_regionali_2023.zip "Dati_regionali_2023/R<NN>_<Regione>_2023_sezioni
    .xlsx" \
    "Dati_regionali_2023/TRACCIATO FILE REGIONALI.xlsx"
```

Estrarre il comune dal file regionale (filtro PROCOM, xlsx $\rightarrow$ csv) e verificare: n. sezioni, COM_ASC1 popolata e con quante zone, sezioni fittizie 888888x, P1 vs popolazione attesa.

Fase 5 — tabelle di quartiere.

```
python build_zona_tables.py      # Z1-Z4 + zona_nomi -> data/comuni/<codice>/
    zona_2023/
```

Audit stampati: totali = comunale, quota stranieri per quartiere (sanity qualitativa).

Fase 6 — ConstraintSet K7C e fit.

```
python cs_build.py <codice> --anno 2024 --livello K7C
python fit_cs.py <codice> --anno 2024 --livello K7C --eps 1e-8 \
    --min-alpha 2e-4 --no-gibbs
```

Nel build verificare: somme blocchi ($Z1-Z3 = 1.0000$), audit Z-vs-Z $\sim 10^{-11}$ e Z-vs-comunale = 0. Nel fit: $MRE_{\alpha>0}$ attesa $\sim 10^{-4}$ – 10^{-3} ; se compare discesa $\rightarrow$ risalita, c'è un margine sovrapposto non armonizzato (§5). Output: popolazione_K7C.csv. (Facoltativo, caratterizzazione GibbsPCD: stesso comando senza -no-gibbs, con -pool dimensionato dalla formula del pavimento e -numba.)

Fase 7 — nazionalità two-stage.

```
python assign_nationality.py <codice> --anno 2024
```

Verificare: classificazione UE stampata; doppia contabilità comunale $\leftrightarrow$ sezioni; top paesi e paese-top per quartiere. Output finale: popolazione_K7C_naz.csv.

9.1 Adattamento a un comune diverso da Brescia

Tre punti oggi parametrizzati su Brescia, da generalizzare (candidati per una v3 degli script):

1. **estrazione sezioni**: il filtro PROCOM dal file regionale è un one-liner manuale; `build_zona_tables.py` e `assign_nationality.py` leggono il path hardcoded `brescia_sezioni_2023.csv`;
2. **mappa nomi ASC** (`ASC_NOMI`): fornita a mano per Brescia; per altri comuni va reperita dal comune stesso (i codici `COM_ASC1` sono nel dato, i nomi no) e l'`assert len==33` parametrizzato;
3. **presenza delle ASC**: verificare che `COM_ASC1` sia popolata per il comune scelto; se il comune non ha partizioni amministrative dichiarate, la zona va costruita per aggregazione spaziale delle sezioni (basi territoriali 2021 + confini scelti).

Con questi tre punti resi parametrici, la pipeline è end-to-end generica: `<codice> → popolazione_K7C_naz.csv`

10 Da fare / prossimi passi

- ☒ Nazionalità two-stage livello 1 — v0.4.
- ☐ Generalizzazione multi-comune degli script sub-comunali (§9.1) + run di regressione su Torino 001272.
- ☐ Run B (pool = popolazione, λ caldi): misura diretta del pavimento stazionario; richiede warm start (subclass del solver) — da ridiscutere prima.
- ☐ Via/civico entro quartiere (macchinario geografico v3).
- ☐ Seed esplicito nel kernel Numba.
- ☐ Variante Caffaro: esclusione sezione fittizia (549) con riscalatura.
- ☐ σ campionarie del censimento; UE/extra-UE come raffinamento della cittadinanza nel CS; famiglie e background migratorio.
- ☐ Aggiornamento annuale: sub-comunale 2024 al rilascio.