

Pipeline SDMX–ISTAT per popolazioni sintetiche comunali e sub-comunali

Note tecniche — v0.6

M. Degli Esposti

20 luglio 2026 (v0.1–v0.5: 18–20 luglio 2026)

Abstract

Pipeline riproducibile dai dati pubblici ISTAT alla popolazione sintetica MaxEnt con quartieri: Brescia K7C, 198 259 individui $\times$ 11 attributi (`popolazione_K7C_naz.csv`). In v0.4: (xi) nazionalità two-stage gerarchica — area UE/extra-UE condizionata a (zona, sesso) dalle sezioni, paese condizionato a (area, sesso) dal comunale, allocazione esatta largest-remainder; doppia contabilità comunale $\leftrightarrow$ sezioni verificata a $\sim 3\%$; mappa quartiere $\times$ paese-top qualitativamente corretta (Fiumicello/Chiesanuova a trazione Pakistan, Primo Maggio/Don Bosco a trazione Romania); (xii) ricettario di esecuzione end-to-end della pipeline (§13). In v0.5, l’espansione degli attributi verso le bio LLM: (xiii) architettura a *tre anelli* (MaxEnt / condizionali two-stage / generativo) come criterio di smistamento dei nuovi attributi (§8); (xiv) ricognizione del datalake: AVQ con microdati pubblici (fiducia istituzionale $\rightarrow$ trust data-grounded), pendolarismo censuario fermo al 2019 e quindi retrocesso all’anello 2; (xv) background migratorio: tassonomia a 6 categorie portata da INDICATOR, incrocio completo con sesso e origine dei genitori, settima identità esatta; EM1–6 nelle sezioni $\rightarrow$ assunzione (5); (xvi) livello **K8C** ($|X| = 161\,280$): fit esatto MRE $6 \cdot 10^{-4}$, $H = 6.964$ nat ($+1.122$ vs K6C); K9C ($5.3 \cdot 10^6$) in attesa della F sparsa; (xvii) due meccanismi di guadagno entropico: zona = diversità correlata, background = diversità quasi-indipendente. In v0.6, generalizzazione multi-comune e due bug di feasibility scoperti e risolti sui casi limite: (xviii) pipeline verificata su tre comuni strutturalmente diversi — Brescia (33 quartieri), Bologna (6 quartieri o 18 zone, registro parametrico), San Vito dei Normanni (17931 ab., *nessuna* sub-area: caso “zona assente” gestito con degrado esplicito a $P(\text{area} \mid \text{sesso})$ comunale in `assign_nationality`); (xix) **bug di indipendenza spuria**: cittadinanza e background, pur coerenti nei margini aggregati, risultavano indipendenti cella per cella nel campione (30.5% di combinazioni logicamente impossibili su Brescia K8C) — il MaxEnt riempie con l’ipotesi di indipendenza ogni relazione non vincolata esplicitamente, anche quando è deterministica; fix: vincolo diretto arity-2 (`GC_cittad_background`, zero esatto sulle celle impossibili) $\rightarrow$ 0% su tre comuni; (xx) primo **K9C** completo (Bologna, zona+background, $|X| = 967\,680$): collasso e fix gemello, stessa famiglia della lezione generalizzata ma un livello più sottile — il conflitto passava per una variabile derivata (cittadinanza $\leftarrow$ background) tra i blocchi Z5 e Z2; fix: IPF di Z5 vincolato *dentro* ciascun gruppo di cittadinanza, mai attraverso la frontiera ITL/FRG; fit pulito, MRE $3.8 \cdot 10^{-4}$, $H = 8.046$ nat, 0% incoerenze. Risultati precedenti: identità esatte della base riconciliata; regole di feasibility (partizione; margini sovrapposti + IPF); pavimento stocastico PCD replicato 3 $\times$; stimatore-pool vs distribuzione appresa.

Contents

1	Scopo e contesto	2
2	Endpoint SDMX esplorati: comportamenti non documentati	2
3	Le fonti: tre laghi più uno	2

4	Brescia: sezioni, quartieri, audit	3
5	K7C: blocchi di zona, feasibility, IPF	3
6	Fit K7C e caratterizzazione GibbsPCD	3
7	Nazionalità two-stage (livello 1)	3
8	Espansione degli attributi: architettura a tre anelli	4
8.1	Ricognizione e rosa v2	4
9	Background migratorio: K8C	5
10	Generalizzazione multi-comune: tre casi limite	5
11	Due bug di feasibility sui casi limite	6
11.1	Indipendenza spuria: cittadinanza vs background	6
11.2	K9C: il conflitto attraverso una variabile derivata	6
12	Sintesi dei livelli e deliverable	7
13	Ricettario: esecuzione della pipeline	7
13.1	Adattamento a un comune diverso da Brescia	8
14	Da fare / prossimi passi	9

1 Scopo e contesto

Dato un codice comune ISTAT, produrre il miglior constraint set dai dati pubblici e la popolazione MaxEnt corrispondente; caso guida Brescia (SIN Caffaro) con zona a 33 quartieri. Esecuzione locale (WSL2, env ml); solver dal repo `maxent-popsynth-pcd`.

2 Endpoint SDMX esploradati: comportamenti non documentati

1. limite ~260 char/segmento URL (`http.sys`) $\Rightarrow$ wildcard nel KEY;
2. `startPeriod/endPeriod` ignorati $\Rightarrow$ filtro client-side (serie storiche complete gratis);
3. SDMX-CSV via Accept: `application/vnd.sdmx.data+csv;version=1.0.0`;
4. rate limit ~5/min: throttling 13s, retry con backoff;
5. stime censuarie comunali *non arrotondate* (decimali, additive).

3 Le fonti: tre laghi più uno

Anagrafe (DCIS_*, singolo anno d'età); censimento permanente comunale (DF_DCSS_*, ipercubo unico, granularità nel suffisso); indagini campionarie (solo regionali $\rightarrow$ condizionali two-stage); canale sub-comunale:

- ASC aggregate via SDMX (DF_BULK_SUBCOM*): solo capoluoghi Città Metropolitane;
- **sezioni di censimento**, tutti i comuni: `bulk Dati_regionali_<anno>.zip` (xlsx per regione + tracciato) su `esploradati.istat.it/databrowser/DWL/PERMPOP/SUBCOM/`; edizioni 2021 e 2023 (rilascio annuale a regime);

- scoperta chiave: `COM_ASC1/2/3` nel file sezioni — i codici delle aree sub-comunali sono già assegnati sezione per sezione per tutti i comuni partizionati (Brescia: 33 valori = quartieri; spatial join superfluo).

Variabili del tracciato: sesso×età quinquennale, istruzione a 5 livelli per sesso (9+), occupati 15–64 per sesso, ITA/stranieri per sesso×macro-età, **UE/extra-UE per sesso** (ST16–21), background migratorio, famiglie, abitazioni.

4 Brescia: sezioni, quartieri, audit

1 822 sezioni, 33 quartieri; sezione fittizia 888888x (549 senza fissa dimora) tenuta nel quartiere assegnato 17029004 (opzione a). **Quinta identità esatta:** sezioni $\equiv$ censimento comunale 2023 $\equiv$ anagrafe 1/1/2024 = 198 259 (stranieri 37 478); additività interna piena. Sezioni in interi (RBI $\leftrightarrow$ RSBL), comunale in stime decimali: scarti di unità assorbiti dal disegno condizionale. Ancoraggio K7C: -anno 2024. Sanity: top-5 quota stranieri = Fiumicello (0.371), Centro Storico Nord, Primo Maggio, Don Bosco, Chiesanuova — l’orbita SIN Caffaro.

5 K7C: blocchi di zona, feasibility, IPF

zona in testa a `VAR_ORDER`; $|X| = 33 \times 5\,376 = 177\,408$; arietà piena dove il dato la sostiene (Z2: zona×sesso×età×cittadinanza). Principio: ogni tabella di zona entra come $P(\text{zona} \mid \text{gruppo}) \times \text{conteggi comunali}$. Assunzioni (2) quota di zona costante entro quinquennale/macro-classe; (3) $P(\text{zona} \mid \text{sesso, occ})$ costante sui bin 15–64.

Regola di consistenza generalizzata (dal collasso discesa $\rightarrow$ risalita del primo fit): con vincoli di uguaglianza devono coincidere numericamente *tutti* i margini impliciti sovrapposti tra blocchi, non solo quelli verso la spine. **Fix: IPF come armonizzatore di tabelle** (righe da Z1, colonne dal blocco comunale, per gruppo); Z4 con cap su Z1 e redistribuzione. Audit post: Z-vs-Z $\sim 10^{-11}$, Z-vs-comunale = 0.

6 Fit K7C e caratterizzazione GibbsPCD

	$\text{MRE}_{\alpha>0}$	H (nat)	supporto	KL vs exact	tempo
Esatto (L-BFGS)	$3.6 \cdot 10^{-4}$	9.157	130 161/177 408	—	351 s
GibbsPCD ($N=2 \cdot 10^5$, numba)	$3.1 \cdot 10^{-2}$	9.592	171 864	$1.2 \cdot 10^{-1}$	1 070 s

Esclusioni ($\alpha = 0$) fuori dai solver, post-hoc sul supporto (5 544 celle). **Pavimento stocastico replicato** (terzo punto): predetto 0.0650, osservato 0.0634 ($N = 2 \cdot 10^5$); formula $\text{MRE}_{\min} \approx m^{-1} \sum_j \sqrt{(1 - \alpha_j)/(\alpha_j N)}$ calcolabile dal solo CS. **Stimatore-pool vs distribuzione appresa:** MRE su frequenze del pool 0.063 (al pavimento), MRE su p_λ 0.031: i λ mediati da Adam battono il pavimento del singolo snapshot di $\sim 2\times$. Decisione di produzione: esatto anche a K7C (100× più preciso, 1/3 del tempo); GibbsPCD per domini non enumerabili, N dalla formula.

7 Nazionalità two-stage (livello 1)

La nazionalità (143 paesi) resta fuori dal MaxEnt (nessun incrocio vincolabile; $|X|$ esploderebbe) ed entra come assegnazione gerarchica sul campione (`assign_nationality.py`):

- (2a) $\text{area} \in \{\text{UE}, \text{EXTRA_UE}\} \sim P(\text{area} \mid \text{zona}, \text{sesso})$ dalle sezioni (ST17/18/20/21; UE+extraUE = ST1 esatto, apolidi assorbiti in extra-UE);

- (2b) paese $\sim P(\text{paese} \mid \text{area}, \text{sezzo})$ dal comunale (DF_DCSS_POP_DEMCITMIG_TV_3, 2023, GENDER conservato); classificazione UE label-driven (23 paesi UE presenti a Brescia; Cechia/Lussemburgo/Malta assenti dal dato, non errori di match).

Allocazione **esatta** (largest remainder) a entrambi i livelli, shuffle seedato entro gruppo. **Assunzione (4)**: paese $\perp$ zona $\mid$ (area, sesso) — la struttura territoriale entra al livello area; il limite è visibile (dentro l’extra-UE stesso mix in tutti i quartieri).

Validazione: doppia contabilità comunale $\leftrightarrow$ sezioni per area $\times$ sesso coincide a $\sim 3\%$ (canali indipendenti); top-10 campione = Romania, Pakistan, Ucraina, India, Egitto, Cina, Albania, Moldova, Sri Lanka, Filippine (ordine reale, Ucraina con asimmetria F via condizionamento per sesso); paese-top per quartiere: Fiumicello e Chiesanuova $\rightarrow$ Pakistan, Primo Maggio e Don Bosco $\rightarrow$ Romania — differenziazione emergente da $P(\text{area} \mid \text{zona}, \text{sesso})$.

8 Espansione degli attributi: architettura a tre anelli

Motivazione (obiettivo bio LLM): il vettore di attributi è il seed del prompt; la diversità delle storie generabili è limitata dall’entropia e dalla credibilità congiunta del seed — pochi attributi $\Rightarrow$ individui indistinguibili $\Rightarrow$ l’LLM riempie con stereotipi. Ogni attributo aggiuntivo, se correlato realisticamente, è un vincolo contro la confabulazione stereotipata. Non tutti gli attributi devono però passare dal MaxEnt:

1. **Anello 1 — MaxEnt**: attributi con dati constraint-grade a livello comune/zona e interazioni da codificare (costano $|X|$);
2. **Anello 2 — condizionali two-stage**: $P(\text{nuovo} \mid \text{sottoinsieme degli esistenti})$ da fonti regionali/nazionali (costo $|X|$ nullo; per la bio equivalgono, nella misura in cui il dato sostiene la condizionale);
3. **Anello 3 — generativo**: ciò che l’LLM inventa liberamente; la frontiera 2/3 va spinta il più in là possibile.

8.1 Ricognizione e rosa v2

- **AVQ** (Multiscopo, $\sim 50k$ individui/anno): microdati ad uso pubblico a download libero (mIcro.STAT; 2024 disponibile), file per la ricerca su richiesta; geografia al meglio regionale/ripartizione. Copre fiducia istituzionale (indicatori BES: parlamento, giustizia, forze dell’ordine, scale 0–10), salute percepita, stili di vita, soddisfazione, titolo di godimento dell’abitazione, spostamenti casa-lavoro/scuola (post-COVID, con mezzo e tempo). Un solo download sblocca quattro attributi; punto qualificante: il trust delle personas passa da *designed* (Montelago LOW/MED/HIGH) a *data-grounded* ($P(\text{fiducia} \mid \text{sesso}, \text{età}, \text{istruzione})$).
- **Pendolarismo censuario** (DF_DCSS_ISTR_LAV_PEN_2_TV_5): smoke test $\Rightarrow$ solo sesso $\times$ destinazione $\times$ motivo, **solo 2018–2019** (108k pendolari su 198k, Brescia 2019); nessuna alternativa comunale nel catalogo. Quote pre-COVID su popolazione 2024 per la variabile che il COVID ha ristrutturato: assunzione di stabilità non difendibile $\Rightarrow$ **retrocesso all’anello 2** (AVQ regionale recente), con la TV_5 2019 come ancora storica. Gotcha: TIME_PERIOD servito come stringa in questa tavola.
- **Famiglie** (DF_DCSS_FAMIGLIE_TV_*) : tavole di famiglie, non di individui; conversione famiglia $\rightarrow$ individuo con assunzioni proprie $\Rightarrow$ in coda. Dal tracciato sezioni: PF3–PF8 (ampiezza per zona), NA1 (auto), A2/A3/A8 (abitazioni occupate/vuote) come attributi di *contesto* di quartiere; titolo di godimento assente a livello sezione $\Rightarrow$ anello 2 (AVQ).
- **Reddito** (MEF/AdE, dichiarazioni per comune, classi e tipologia): anello 1.5 — prima fonte non riconciliata, da trattare con le cautele codificate.

9 Background migratorio: K8C

Dato (DF_DCSS_MIGR_BACKG_PAR_TV_1_COM, 2021–2023, DSD a 9 dimensioni — niente LOC_DEST/CUR_ACT — nuove PREVIOUS_CITIZEN e PLACE_BIRTH_PAR): la tassonomia è portata da INDICATOR (11 categorie, 6 elementari), non da CITIZENSHIP:

categoria	codice	Brescia 2023
italiano_nativo	IT_BIRT_IT	143 058
italiano_rientrato	IT_BIRT_AB	2 824
naturalizzato_g2	NATIT_B_IT	4 959
naturalizzato_immigrato	NATIT_B_AB	9 940
straniero_g2	FOR_B_IT	6 188
straniero_immigrato	FOR_B_AB	31 290

Somma = 198 259: **settima identità esatta**. PLACE_BIRTH_PAR aggiunge l’origine dei genitori a 4 modalità elementari, *coppie miste incluse* (madre straniera/padre italiano e viceversa, $\sim 4\%$); l’incrocio completo GENDER $\times$ INDICATOR $\times$ PBP esiste nel dato (495 righe = $3 \times 11 \times 5 \times 3$). Nel tracciato sezioni la stessa tassonomia è in EM1–EM6, *senza sesso* $\Rightarrow$ **assunzione (5)**: quota di zona del background uguale tra i sessi (i margini per sesso restano esatti via IPF). Nota operativa: dataflow più fragile delle sorelle (due 500 transitori su struttura e dati; risolti con retry).

Design: background (6 modalità) *affianca cittadinanza* (non la sostituisce: E/F e la nazionalità two-stage restano intatte); le due variabili sono linearmente dipendenti (background implica cittadinanza) $\Rightarrow$ audit di identità pre-fit: G aggregato a ITL/FRG per sesso $\equiv$ B sommato sulle età (armonizzazione 1D su C2 in build_constraints, fattori $|f - 1| \sim 0$). **origine_genitori** (5 modalità con non_applicabile per i nati all’estero) come vincolo vero: blocco H a arietà 3 (sesso $\times$ background $\times$ origine), costruito come partizione completa in c8. Livelli nuovi: **K8C** = K6C + background + origine ($|X| = 5\,376 \times 30 = 161\,280$, F densa ancora praticabile); **K9C** = zona + K8C ($|X| = 5.3 \cdot 10^6$: oltre il muro della F densa ~ 95 GB $\Rightarrow$ richiede **F sparsa** nel solver esatto — prerequisito, non ancora fatto). Blocco di zona Z5 (zona $\times$ sesso $\times$ background) pronto in cs_build: quote EM1–6 $\times$ G, IPF pattern-Z3.

Fit K8C (esatto, -min-alpha 2e-4): $MRE_{\alpha>0} = 6.0 \cdot 10^{-4}$ in 67 s; $H = 6.964$ nat (+1.122 vs K6C = 5.842); supporto 87 231/161 280. Decomposizione del guadagno: $H(\text{background}) \approx 0.94$ nat domina; origine_genitori aggiunge ~ 0.18 (quasi deterministica dato background per i rami immigrati). **Contrasto con la zona**: il background aggiunge diversità *quasi-indipendente* (condizionato solo al sesso, deficit di correlazione piccolo), la zona diversità *correlata* (deficit = informazione mutua zona $\leftrightarrow$ attributi). Due meccanismi distinti di arricchimento del seed delle bio.

Generalità: il ramo comunale della pipeline (fasi 0–4 del ricettario, K6C incluso) è stato verificato senza modifiche su un secondo comune (**Bologna**); per la zona restano i tre punti di §13.1.

10 Generalizzazione multi-comune: tre casi limite

La pipeline (fasi 0–4 comunali, K6C/K8C) è stata eseguita senza modifiche su tre comuni di scala e struttura territoriale molto diverse, a validazione della genericità del ricettario:

comune	popolazione	sub-aree	livello zona
Brescia (017029)	198 259	33 quartieri (ASC1)	K7C/K9C
Bologna (037006)	390 098	6 quartieri (ASC1) / 18 zone (ASC2)	K7C/K9C, entrambi i livelli
San Vito dei Normanni (074017)	17 931	nessuna (ASC1=ASC2= 0)	K6C/K8C soltanto

Registro parametrico: `build_zona_tables.py` v3 unifica gli script Brescia/Bologna in un unico motore con un dict `COMUNI` (CSV sezioni, colonna ASC, numero atteso di unità, nomi, gerarchia zona→quartiere se applicabile); aggiungere un comune = una voce nel registro. Bologna valida il caso multi-livello (stessa sezione, due colonne ASC1/ASC2 con gerarchia esplicita `ZONE_TO_QUARTIERE`).

Caso limite: comune senza sub-aree. San Vito (`COM_ASC1=COM_ASC2= 0` su tutte le sezioni: codice convenzionale ISTAT “nessuna partizione”, non una zona reale) non supporta K7C/K9C: si ferma a K6C/K8C. In `assign_nationality.py`, la rilevazione (`col_sez.nunique()<=1`) fa degradare automaticamente il passo (2a) a $P(\text{area} \mid \text{sezzo})$ puramente comunale (il fallback già esistente per zone non coperte diventa il percorso primario), senza flag né branch aggiuntivi nel chiamante — stesso comando di Brescia/Bologna. Validato: 703/703 assegnati, doppia contabilità comunale↔sezioni coerente anche su un’unica sezione aggregata (UE 53/117 vs 53/118), top-10 paesi coerente con la geografia migratoria del Sud (Romania, Marocco, Georgia, Nigeria, Senegal).

11 Due bug di feasibility sui casi limite

11.1 Indipendenza spuria: cittadinanza vs background

Su Brescia K8C, verifica di coerenza cittadinanza↔background sul campione: 60 501/198 259 righe (30.5%) con combinazioni logicamente impossibili (es. `cittadinanza=ITL` con `background=straniero_imm`). Diagnosi: i blocchi B (cittadinanza) e G (background) erano vincolati solo contro la spine e verificati in aggregato (audit margini G-vs-B), ma *mai vincolati insieme nella stessa cella*; background implica cittadinanza in modo deterministico, ma nessun vincolo lo impone atomicamente ⇒ il MaxEnt, a entropia massima, tende all’indipendenza fra le due variabili ovunque un vincolo esplicito non gliela neghi — anche quando l’indipendenza è impossibile per definizione.

Fix: blocco `GC_cittad_background` (arity 2, partizione completa `cittadinanza×background`, zero esatto sulle 6 celle impossibili, trattate come esclusioni strutturali come i vedovi 15–24). Verificato 0.0000% su Brescia e San Vito; effetto collaterale sano su Brescia K8C: celle escluse post-hoc 5 040 → 83 160 (il vincolo esclude un’ampia fetta di $|X|$ strutturalmente impossibile), H : 6.964 → 6.479 nat — il valore precedente era gonfiato da massa fantasma su combinazioni vietate, non da vera diversità.

Principio generale: quando due attributi sono in relazione deterministica (uno implica l’altro), la coerenza dei soli margini aggregati non basta — serve un vincolo diretto sull’incrocio, altrimenti il MaxEnt colma lo spazio libero con l’ipotesi di indipendenza. Estende la lezione E/F/Z-vs-Z (§??) al caso più severo: là il conflitto era numerico (margini quasi coerenti), qui è logico (celle vietate).

11.2 K9C: il conflitto attraverso una variabile derivata

Primo K9C completo (Bologna, zona+background, $|X| = 33 \times 5\,376 \times 6 = 967\,680$; qui 6 quartieri ⇒ 967 680): con `GC` in posto ma `Z5` (`zona×sezzo×background`) costruita come nelle sessioni precedenti (IPF contro `Z1` e `G` soltanto), il fit ha mostrato la firma ormai nota — discesa fino a $\text{MRE} \approx 0.025$ (iter 100–120), poi risalita monotona fino a collasso totale ($H = 0$, supporto 1/967 680). Diagnosi: `Z5` non vede mai `cittadinanza`, ma background la implica; le quote di cittadinanza per zona che `Z5` induce implicitamente (aggregando i suoi background per gruppo ITL/FRG) non erano vincolate a coincidere con quelle — già affidabili, già armonizzate IPF contro `Z1` — del blocco `Z2`. Due decomposizioni diverse dello stesso margine (`zona×sezzo×cittadinanza`), stavolta mediate da una variabile derivata anziché condivisa esplicitamente: stessa famiglia della lezione generalizzata, un livello di indirection più sottile.

Fix: IPF di Z5 eseguito *separatamente per ciascuna coppia (sesso, gruppo di cittadinanza)*, mai attraverso la frontiera ITL/FRG — righe: quote di zona per quel gruppo, da Z2 aggregata su età (autorità già armonizzata); colonne: G ristretto al gruppo; inizializzazione: quote di background *entro* il gruppo da z6 (EM1–6), pesate sui target di riga. Poiché la massa non attraversa mai la frontiera di gruppo, la coerenza con GC è garantita per costruzione. Audit aggiunto: Z5 (aggregata per gruppo) vs Z2, $\max|\Delta| = 2.2 \cdot 10^{-11}$ — terzo controllo della famiglia Z-vs-Z, accanto a Z2-vs-Z1 e Z3-vs-Z1.

Risultato (Bologna K9C, post-fix): discesa monotona (con il consueto tremolio fine di L-BFGS su duale grande), $\text{MRE}_{\alpha>0} = 3.8 \cdot 10^{-4}$ in 831 s, $H = 8.046$ nat, supporto 244 904/967 680; 0/390 098 incoerenze cittadinanza× background; marginali di zona sensati (15–18% per quartiere); top quota-stranieri per quartiere coerente con l’audit sub-comunale (Navile 0.205, San Donato-San Vitale 0.176, Borgo Panigale-Reno 0.158).

Nota di scala: Bologna con 6 quartieri resta sotto il muro della F densa ($|X| \approx 9.7 \cdot 10^5$, F stimata 5.9 GB); Brescia K9C (33 zone, $|X| \approx 5.3 \cdot 10^6$) richiede ancora la F sparsa (§14) — il fix di questa sezione si applica identico quando sarà eseguibile.

12 Sintesi dei livelli e deliverable

	anno	$ X $	m	MRE esatto	H (nat)
K6C	1/1/2025	5 376	269	$5.0 \cdot 10^{-4}$	5.842
K7C	1/1/2024	177 408	2 513	$3.6 \cdot 10^{-4}$	9.157
K8C (Brescia, post-fix GC)	1/1/2024	161 280	—	$5.8 \cdot 10^{-4}$	6.479
K9C (Brescia, 33 zone)	1/1/2024	5 322 240	—	in attesa F sparsa	
K9C (Bologna, 6 quartieri)	1/1/2024	967 680	763	$3.8 \cdot 10^{-4}$	8.046

Deliverable: `popolazione_K7C_naz.csv` — 198 259 individui × 11 attributi (zona, quartiere, sesso, età, stato_civile, cittadinanza, istruzione, condizione, area, paese; ITL → paese Italia), ancorati all’1/1/2024, con 4 assunzioni dichiarate e numerate.

13 Ricettario: esecuzione della pipeline

Sequenza completa da zero a `popolazione_K7C_naz.csv`. Prerequisiti: `env ml` attivo; repo `maxent-popsynth-pcd` clonato in `~/progetti/`; `pip install lxml openpyxl`. Script in `~/progetti/gsp/scri`. Le fasi 0–4 sono **generiche per qualunque comune** (parametro `<codice>`, ITTER107); le fasi 5–8 sono generiche nel disegno ma gli script attuali hanno tre punti parametrizzati su Brescia, elencati in §13.1.

Fase 0 — catalogo (una tantum, riusabile).

```
python istat_catalog.py # scarica e indicizza 4884 dataflow
python istat_catalog.py istruzione # esempio di grep esplorativa
```

Fase 1 — tavole comunali (esplorazione staged, poi fetch; ~3 min per il throttling).

```
python fetch_comune.py <codice> --explore # strutture: dimensioni,
    territorio
python fetch_comune.py <codice> # 7 tavole -> data/comuni/<codice>
    >/
```

Fase 2 — tavole-vincolo comunali (per ogni ancoraggio che serve; K7C usa `-anno 2024`).

```
python build_constraints.py <codice> --anno 2024
python build_constraints.py <codice> --anno 2025 # opzionale, K6C recente
```

Verificare nel log: pop totale plausibile; report.md con MAE del raccordo (atteso ≈ 0 post-2018).

Fase 3 — ConstraintSet K6C e fit (opzionale ma consigliato come regressione).

```
python cs_build.py <codice> --anno 2025
python fit_cs.py <codice> --anno 2025 --eps 1e-8 --min-alpha 2e-4 --no-gibbs
```

Fase 4 — sezioni di censimento (bulk, nessun rate limit).

```
mkdir -p ~/progetti/gsp/data/submun && cd ~/progetti/gsp/data/submun
wget https://esploradati.istat.it/databrowser/DWL/PERMPOP/SUBCOM/
    Dati_regionali_2023.zip
unzip Dati_regionali_2023.zip "Dati_regionali_2023/R<NN>_<Regione>_2023_sezioni
    .xlsx" \
    "Dati_regionali_2023/TRACCIATO FILE REGIONALI.xlsx"
```

Estrarre il comune dal file regionale (filtro PROCOM, xlsx $\rightarrow$ csv) e verificare: n. sezioni, COM_ASC1 popolata e con quante zone, sezioni fittizie 888888x, P1 vs popolazione attesa.

Fase 5 — tabelle di quartiere.

```
python build_zona_tables.py      # Z1-Z4 + zona_nomi -> data/comuni/<codice>/
    zona_2023/
```

Audit stampati: totali = comunale, quota stranieri per quartiere (sanity qualitativa).

Fase 6 — ConstraintSet K7C e fit.

```
python cs_build.py <codice> --anno 2024 --livello K7C
python fit_cs.py <codice> --anno 2024 --livello K7C --eps 1e-8 \
    --min-alpha 2e-4 --no-gibbs
```

Nel build verificare: somme blocchi ($Z1-Z3 = 1.0000$), audit Z-vs-Z $\sim 10^{-11}$ e Z-vs-comunale = 0. Nel fit: $MRE_{\alpha>0}$ attesa $\sim 10^{-4}-10^{-3}$; se compare discesa $\rightarrow$ risalita, c'è un margine sovrapposto non armonizzato (§5). Output: popolazione_K7C.csv. Per il livello **K8C** (background + origine, senza zona): stessa coppia di comandi con -livello K8C (richiede la tavola cens_migr_backg in fase 1 — riga DF_DCSS_MIGR_BACKG_PAR_TV_1_COM in CORE — e il conseguente build_constraints, che produce c7/c8; per il livello zona, build_zona_tables produce anche z6 da EM1-6). K9C: dopo la F sparsa. (Facoltativo, caratterizzazione GibbsPCD: stesso comando senza -no-gibbs, con -pool dimensionato dalla formula del pavimento e -numba.)

Fase 7 — nazionalità two-stage.

```
python assign_nationality.py <codice> --anno 2024
```

Verificare: classificazione UE stampata; doppia contabilità comunale $\leftrightarrow$ sezioni; top paesi e paese-top per quartiere. Output finale: popolazione_K7C_naz.csv.

13.1 Adattamento a un comune diverso da Brescia

Tre punti oggi parametrizzati su Brescia, da generalizzare (candidati per una v3 degli script):

1. **estrazione sezioni**: il filtro PROCOM dal file regionale è un one-liner manuale; build_zona_tables.py e assign_nationality.py leggono il path hardcoded brescia_sezioni_2023.csv;
2. **mappa nomi ASC** (ASC_NOMI): fornita a mano per Brescia; per altri comuni va reperita dal comune stesso (i codici COM_ASC1 sono nel dato, i nomi no) e l'assert len==33 parametrizzato;

3. **presenza delle ASC**: verificare che `COM_ASC1` sia popolata per il comune scelto; se il comune non ha partizioni amministrative dichiarate, la zona va costruita per aggregazione spaziale delle sezioni (basi territoriali 2021 + confini scelti).

Con questi tre punti resi parametrici, la pipeline è end-to-end generica: `<codice> → popolazione_K7C_naz.csv`

14 Da fare / prossimi passi

- ☒ Nazionalità two-stage livello 1 — v0.4.
- ☒ Rosa v2 attributi (tre anelli) + background/origine (K8C fittato) — v0.5.
- ☒ Generalizzazione multi-comune (Brescia/Bologna/San Vito) + fix GC (indipendenza spuria cittadinanza-background) + fix Z5-vs-Z2 (K9C Bologna completo) — v0.6.
- ☐ **F sparsa** nel solver esatto (scipy.sparse): unico prerequisito rimasto per K9C-Brescia ($|X| = 5.3 \cdot 10^6$); apre anche il confronto sparse-exact vs GibbsPCD su dominio grande.
- ☐ **AVQ**: download microdati pubblici 2024, lettura tracciato; strato condizionali (fiducia istituzionale, stili di vita, titolo godimento casa, pendolarismo post-COVID).
- ☐ Reddito MEF/AdE comunale (anello 1.5, fonte non riconciliata).
- ☐ Check di sostanza K8C/K9C: mappa background×condizione (es. straniero_immigrato vs in_cerca).
- ☐ Run B (pool = popolazione, λ caldi): misura diretta del pavimento stazionario; richiede warm start (subclass del solver) — da ridiscutere prima.
- ☐ Via/civico entro quartiere (macchinario geografico v3).
- ☐ Seed esplicito nel kernel Numba.
- ☐ Variante Caffaro: esclusione sezione fittizia (549) con riscalatura.
- ☐ σ campionarie del censimento; UE/extra-UE come raffinamento della cittadinanza nel CS; famiglie.
- ☐ Aggiornamento annuale: sub-comunale 2024 al rilascio.