

Pipeline SDMX–ISTAT per popolazioni sintetiche comunali e sub-comunali

Note tecniche — v0.7

M. Degli Esposti

21 luglio 2026 (v0.1–v0.6: 18–20 luglio 2026)

Abstract

Pipeline riproducibile dai dati pubblici ISTAT alla popolazione sintetica MaxEnt con quartieri: Brescia K7C, 198 259 individui $\times$ 11 attributi (`popolazione_K7C_naz.csv`). In v0.4: (xi) nazionalità two-stage gerarchica — area UE/extra-UE condizionata a (zona, sesso) dalle sezioni, paese condizionato a (area, sesso) dal comunale, allocazione esatta largest-remainder; doppia contabilità comunale ↔ sezioni verificata a $\sim 3\%$; mappa quartiere $\times$ paese-top qualitativamente corretta (Fiumicello/Chiesanuova a trazione Pakistan, Primo Maggio/Don Bosco a trazione Romania); (xii) ricettario di esecuzione end-to-end della pipeline (§14). In v0.5, l’espansione degli attributi verso le bio LLM: (xiii) architettura a *tre anelli* (MaxEnt / condizionali two-stage / generativo) come criterio di smistamento dei nuovi attributi (§8); (xiv) ricognizione del datalake: AVQ con microdati pubblici (fiducia istituzionale $\rightarrow$ trust data-grounded), pendolarismo censuario fermo al 2019 e quindi retrocesso all’anello 2; (xv) background migratorio: tassonomia a 6 categorie portata da INDICATOR, incrocio completo con sesso e origine dei genitori, settima identità esatta; EM1–6 nelle sezioni $\rightarrow$ assunzione (5); (xvi) livello **K8C** ($|X| = 161\,280$): fit esatto MRE $6 \cdot 10^{-4}$, $H = 6.964$ nat (+1.122 vs K6C); K9C ($5.3 \cdot 10^6$) in attesa della F sparsa; (xvii) due meccanismi di guadagno entropico: zona = diversità correlata, background = diversità quasi-indipendente. In v0.6, generalizzazione multi-comune e due bug di feasibility scoperti e risolti sui casi limite: (xviii) pipeline verificata su tre comuni strutturalmente diversi — Brescia (33 quartieri), Bologna (6 quartieri o 18 zone, registro parametrico), San Vito dei Normanni (17 931 ab., *nessuna* sub-area: caso “zona assente” gestito con degrado esplicito a $P(\text{area} \mid \text{sesso})$ comunale in `assign_nationality`); (xix) **bug di indipendenza spuria**: cittadinanza e background, pur coerenti nei margini aggregati, risultavano indipendenti cella per cella nel campione (30.5% di combinazioni logicamente impossibili su Brescia K8C) — il MaxEnt riempie con l’ipotesi di indipendenza ogni relazione non vincolata esplicitamente, anche quando è deterministica; fix: vincolo diretto arity-2 (`GC_cittad_background`, zero esatto sulle celle impossibili) $\rightarrow$ 0% su tre comuni; (xx) primo **K9C** completo (Bologna, zona+background, $|X| = 967\,680$): collasso e fix gemello, stessa famiglia della lezione generalizzata ma un livello più sottile — il conflitto passava per una variabile derivata (cittadinanza $\leftarrow$ background) tra i blocchi Z5 e Z2; fix: IPF di Z5 vincolato *dentro* ciascun gruppo di cittadinanza, mai attraverso la frontiera ITL/FRG; fit pulito, MRE $3.8 \cdot 10^{-4}$, $H = 8.046$ nat, 0% incoerenze; (xxi) caratterizzazione GibbsPCD sullo stesso K9C: quarta verifica indipendente del pavimento stocastico (predetto 0.024, osservato 0.038); e un effetto nuovo — la massa spontanea sulle celle escluse da un vincolo diretto (GC) scala con l’estensione delle celle vietate, non solo col loro numero: un ordine di grandezza sopra i run senza GC, perché il sampler locale fatica più del solver globale a rispettare un’esclusione estesa (il post-hoc resta comunque esatto in entrambi i casi). In v0.7, la **F sparsa**: (xxii) patch al repo (`build_indicator_matrix_sparse` in CSR, `ExactMaxEntSolver` con flag `sparse`) — collaudata su Bologna K9C (risultato identico al denso a 4 cifre, $18\times$ più veloce, $43\times$ meno memoria), poi risolutiva su **Brescia K9C** ($|X| = 5.322.240$, densità osservata 0.4%): fit esatto in 291 s anziché stimato-impraticabile (~ 110 GB densi), MRE $= 5.7 \cdot 10^{-4}$, $H = 9.804$ nat — primo K9C completo su Brescia, con nazionalità two-stage assegnata (`popolazione_K9C_naz.csv`, 198 259 $\times$ 12 attributi, il vettore più ricco della pipeline);

(xxiii) H quasi perfettamente additivo tra le due espansioni indipendenti (zona e background: 9.804 osservato vs 9.794 atteso sommando i guadagni separati, scarto 0.01 nat) — interazione zona×background marginale oltre i due effetti principali; (xxiv) quinta verifica del pavimento (predetto 0.047, osservato 0.043) e secondo punto della relazione massa-spontanea/estensione-GC (Bologna $2.8 \cdot 10^{-2} \rightarrow$ Brescia $5.1 \cdot 10^{-2}$, coerente con l'estensione delle celle vietate $5.5\times$ maggiore). Risultati precedenti: identità esatte della base riconciliata; regole di feasibility (partizione; margini sovrapposti + IPF); pavimento stocastico PCD replicato $5\times$; stimatore-pool vs distribuzione appresa.

Contents

1	Scopo e contesto	3
2	Endpoint SDMX esplorati: comportamenti non documentati	3
3	Le fonti: tre laghi più uno	3
4	Brescia: sezioni, quartieri, audit	3
5	K7C: blocchi di zona, feasibility, IPF	3
6	Fit K7C e caratterizzazione GibbsPCD	4
7	Nazionalità two-stage (livello 1)	4
8	Espansione degli attributi: architettura a tre anelli	4
8.1	Ricognizione e rosa v2	5
9	Background migratorio: K8C	5
10	Generalizzazione multi-comune: tre casi limite	6
11	Due bug di feasibility sui casi limite	7
11.1	Indipendenza spuria: cittadinanza vs background	7
11.2	K9C: il conflitto attraverso una variabile derivata	7
11.3	GibbsPCD su K9C: quarta verifica del pavimento e un effetto nuovo del vincolo GC	8
12	F sparsa: dal muro di memoria al primo K9C completo	8
12.1	Motivazione e implementazione	8
12.2	Collaudo (Bologna K9C) e risoluzione (Brescia K9C)	8
12.3	Additività dell'entropia tra espansioni indipendenti	9
12.4	Quinta verifica del pavimento e secondo punto della relazione massa-spontanea/estensione	9
13	Sintesi dei livelli e deliverable	10
14	Ricettario: esecuzione della pipeline	10
14.1	Adattamento a un comune diverso da Brescia	11
15	Da fare / prossimi passi	11

1 Scopo e contesto

Dato un codice comune ISTAT, produrre il miglior constraint set dai dati pubblici e la popolazione MaxEnt corrispondente; caso guida Brescia (SIN Caffaro) con zona a 33 quartieri. Esecuzione locale (WSL2, env ml); solver dal repo `maxent-popsynth-pcd`.

2 Endpoint SDMX esploradati: comportamenti non documentati

1. limite ~ 260 char/segmento URL (`http.sys`) $\Rightarrow$ wildcard nel KEY;
2. `startPeriod/endPeriod` ignorati $\Rightarrow$ filtro client-side (serie storiche complete gratis);
3. SDMX-CSV via `Accept: application/vnd.sdmx.data+csv;version=1.0.0`;
4. rate limit ~ 5 /min: throttling 13s, retry con backoff;
5. stime censuarie comunali *non arrotondate* (decimali, additive).

3 Le fonti: tre laghi più uno

Anagrafe (DCIS_*, singolo anno d'età); censimento permanente comunale (DF_DCSS_*, ipercubo unico, granularità nel suffisso); indagini campionarie (solo regionali $\rightarrow$ condizionali two-stage); canale sub-comunale:

- ASC aggregate via SDMX (DF_BULK_SUBCOM*): solo capoluoghi Città Metropolitane;
- **sezioni di censimento**, tutti i comuni: `bulk Dati_regionali_<anno>.zip` (xlsx per regione + tracciato) su `esploradati.istat.it/databrowser/DWL/PERMPOP/SUBCOM/`; edizioni 2021 e 2023 (rilascio annuale a regime);
- scoperta chiave: `COM_ASC1/2/3` nel file sezioni — i codici delle aree sub-comunali sono già assegnati sezione per sezione per tutti i comuni partizionati (Brescia: 33 valori = quartieri; spatial join superfluo).

Variabili del tracciato: sesso $\times$ età quinquennale, istruzione a 5 livelli per sesso (9+), occupati 15–64 per sesso, ITA/stranieri per sesso $\times$ macro-età, **UE/extra-UE per sesso** (ST16–21), background migratorio, famiglie, abitazioni.

4 Brescia: sezioni, quartieri, audit

1 822 sezioni, 33 quartieri; sezione fittizia 888888x (549 senza fissa dimora) tenuta nel quartiere assegnato 17029004 (opzione a). **Quinta identità esatta:** sezioni $\equiv$ censimento comunale 2023 $\equiv$ anagrafe 1/1/2024 = 198 259 (stranieri 37 478); additività interna piena. Sezioni in interi (RBI $\leftrightarrow$ RSBL), comunale in stime decimali: scarti di unità assorbiti dal disegno condizionale. Ancoraggio K7C: -anno 2024. Sanity: top-5 quota stranieri = Fiumicello (0.371), Centro Storico Nord, Primo Maggio, Don Bosco, Chiesanuova — l'orbita SIN Caffaro.

5 K7C: blocchi di zona, feasibility, IPF

zona in testa a `VAR_ORDER`; $|X| = 33 \times 5\,376 = 177\,408$; arietà piena dove il dato la sostiene (Z2: zona $\times$ sesso $\times$ età $\times$ cittadinanza). Principio: ogni tabella di zona entra come $P(\text{zona} \mid \text{gruppo}) \times \text{conteggi comunali}$. Assunzioni (2) quota di zona costante entro quinquennale/macro-classe; (3) $P(\text{zona} \mid \text{sesso, occ})$ costante sui bin 15–64.

Regola di consistenza generalizzata (dal collasso discesa→risalita del primo fit): con vincoli di uguaglianza devono coincidere numericamente *tutti* i margini impliciti sovrapposti tra blocchi, non solo quelli verso la spine. **Fix: IPF come armonizzatore di tabelle** (righe da Z1, colonne dal blocco comunale, per gruppo); Z4 con cap su Z1 e redistribuzione. Audit post: Z-vs-Z $\sim 10^{-11}$, Z-vs-comunale = 0.

6 Fit K7C e caratterizzazione GibbsPCD

	$MRE_{\alpha>0}$	H (nat)	supporto	KL vs exact	tempo
Esatto (L-BFGS)	$3.6 \cdot 10^{-4}$	9.157	130 161/177 408	—	351 s
GibbsPCD ($N=2 \cdot 10^5$, numba)	$3.1 \cdot 10^{-2}$	9.592	171 864	$1.2 \cdot 10^{-1}$	1 070 s

Esclusioni ($\alpha = 0$) fuori dai solver, post-hoc sul supporto (5 544 celle). **Pavimento stocastico replicato** (terzo punto): predetto 0.0650, osservato 0.0634 ($N = 2 \cdot 10^5$); formula $MRE_{\min} \approx m^{-1} \sum_j \sqrt{(1 - \alpha_j)/(\alpha_j N)}$ calcolabile dal solo CS. **Stimatore-pool vs distribuzione appresa**: MRE su frequenze del pool 0.063 (al pavimento), MRE su p_λ 0.031: i λ mediati da Adam battono il pavimento del singolo snapshot di $\sim 2\times$. Decisione di produzione: esatto anche a K7C (100× più preciso, 1/3 del tempo); GibbsPCD per domini non enumerabili, N dalla formula.

7 Nazionalità two-stage (livello 1)

La nazionalità (143 paesi) resta fuori dal MaxEnt (nessun incrocio vincolabile; $|X|$ esploderebbe) ed entra come assegnazione gerarchica sul campione (`assign_nationality.py`):

- (2a) $area \in \{UE, EXTRA_UE\} \sim P(area \mid zona, sesso)$ dalle sezioni (ST17/18/20/21; UE+extraUE = ST1 esatto, apolidi assorbiti in extra-UE);
- (2b) $paese \sim P(paese \mid area, sesso)$ dal comunale (DF_DCSS_POP_DEMCITMIG_TV_3, 2023, GENDER conservato); classificazione UE label-driven (23 paesi UE presenti a Brescia; Cechia/Lussemburgo/Malta assenti dal dato, non errori di match).

Allocazione **esatta** (largest remainder) a entrambi i livelli, shuffle seedato entro gruppo. **Assunzione (4)**: $paese \perp zona \mid (area, sesso)$ — la struttura territoriale entra al livello area; il limite è visibile (dentro l’extra-UE stesso mix in tutti i quartieri).

Validazione: doppia contabilità comunale↔sezioni per area×sesso coincide a $\sim 3\%$ (canali indipendenti); top-10 campione = Romania, Pakistan, Ucraina, India, Egitto, Cina, Albania, Moldova, Sri Lanka, Filippine (ordine reale, Ucraina con asimmetria F via condizionamento per sesso); paese-top per quartiere: Fiumicello e Chiesanuova → Pakistan, Primo Maggio e Don Bosco → Romania — differenziazione emergente da $P(area \mid zona, sesso)$.

8 Espansione degli attributi: architettura a tre anelli

Motivazione (obiettivo bio LLM): il vettore di attributi è il seed del prompt; la diversità delle storie generabili è limitata dall’entropia e dalla credibilità congiunta del seed — pochi attributi $\Rightarrow$ individui indistinguibili $\Rightarrow$ l’LLM riempie con stereotipi. Ogni attributo aggiuntivo, se correlato realisticamente, è un vincolo contro la confabulazione stereotipata. Non tutti gli attributi devono però passare dal MaxEnt:

1. **Anello 1 — MaxEnt**: attributi con dati constraint-grade a livello comune/zona e interazioni da codificare (costano $|X|$);

2. **Anello 2 — condizionali two-stage:** $P(\text{nuovo} \mid \text{sottoinsieme degli esistenti})$ da fonti regionali/nazionali (costo $|X|$ nullo; per la bio equivalgono, nella misura in cui il dato sostiene la condizionale);
3. **Anello 3 — generativo:** ciò che l’LLM inventa liberamente; la frontiera 2/3 va spinta il più in là possibile.

8.1 Ricognizione e rosa v2

- **AVQ** (Multiscopo, ~50k individui/anno): microdati ad uso pubblico a download libero (mIcro.STAT; 2024 disponibile), file per la ricerca su richiesta; geografia al meglio regionale/ripartizione. Copre fiducia istituzionale (indicatori BES: parlamento, giustizia, forze dell’ordine, scale 0–10), salute percepita, stili di vita, soddisfazione, titolo di godimento dell’abitazione, spostamenti casa-lavoro/scuola (post-COVID, con mezzo e tempo). Un solo download sblocca quattro attributi; punto qualificante: il trust delle personas passa da *designed* (Montelago LOW/MED/HIGH) a *data-grounded* ($P(\text{fiducia} \mid \text{sex}, \text{età}, \text{istruzione})$).
- **Pendolarismo censuario** (DF_DCSS_ISTR_LAV_PEN_2_TV_5): smoke test $\Rightarrow$ solo sesso $\times$ destinazione $\times$ motivo, **solo 2018–2019** (108k pendolari su 198k, Brescia 2019); nessuna alternativa comunale nel catalogo. Quote pre-COVID su popolazione 2024 per la variabile che il COVID ha ristrutturato: assunzione di stabilità non difendibile $\Rightarrow$ **retrocesso all’anello 2** (AVQ regionale recente), con la TV_5 2019 come ancora storica. Gotcha: TIME_PERIOD servito come stringa in questa tavola.
- **Famiglie** (DF_DCSS_FAMIGLIE_TV_*): tavole di famiglie, non di individui; conversione famiglia $\rightarrow$ individuo con assunzioni proprie $\Rightarrow$ in coda. Dal tracciato sezioni: PF3–PF8 (ampiezza per zona), NA1 (auto), A2/A3/A8 (abitazioni occupate/vuote) come attributi di *contesto* di quartiere; titolo di godimento assente a livello sezione $\Rightarrow$ anello 2 (AVQ).
- **Reddito** (MEF/AdE, dichiarazioni per comune, classi e tipologia): anello 1.5 — prima fonte non riconciliata, da trattare con le cautele codificate.

9 Background migratorio: K8C

Dato (DF_DCSS_MIGR_BACKG_PAR_TV_1_COM, 2021–2023, DSD a 9 dimensioni — niente LOC_DEST/CUR_ACT — nuove PREVIOUS_CITIZEN e PLACE_BIRTH_PAR): la tassonomia è portata da INDICATOR (11 categorie, 6 elementari), non da CITIZENSHIP:

categoria	codice	Brescia 2023
italiano_nativo	IT_BIRT_IT	143 058
italiano_rientrato	IT_BIRT_AB	2 824
naturalizzato_g2	NATIT_B_IT	4 959
naturalizzato_immigrato	NATIT_B_AB	9 940
straniero_g2	FOR_B_IT	6 188
straniero_immigrato	FOR_B_AB	31 290

Somma = 198 259: **settima identità esatta**. PLACE_BIRTH_PAR aggiunge l’origine dei genitori a 4 modalità elementari, *coppie miste incluse* (madre straniera/padre italiano e viceversa, ~4%); l’incrocio completo GENDER $\times$ INDICATOR $\times$ PBP esiste nel dato (495 righe = $3 \times 11 \times 5 \times 3$). Nel tracciato sezioni la stessa tassonomia è in EM1–EM6, *senza sesso* $\Rightarrow$ **assunzione (5)**: quota di zona del background uguale tra i sessi (i margini per sesso restano esatti via IPF). Nota operativa: dataflow più fragile delle sorelle (due 500 transitori su struttura e dati; risolti con retry).

Design: background (6 modalità) affianca cittadinanza (non la sostituisce: E/F e la nazionalità two-stage restano intatte); le due variabili sono linearmente dipendenti (background implica cittadinanza) $\Rightarrow$ audit di identità pre-fit: G aggregato a ITL/FRG per sesso $\equiv$ B sommato sulle età (armonizzazione 1D su C2 in `build_constraints`, fattori $|f - 1| \sim 0$). `origine_genitori` (5 modalità con `non_applicabile` per i nati all'estero) come vincolo vero: blocco H a arietà 3 (sesso $\times$ background $\times$ origine), costruito come partizione completa in c8. Livelli nuovi: **K8C** = K6C + background + origine ($|X| = 5\,376 \times 30 = 161\,280$, F densa ancora praticabile); **K9C** = zona + K8C ($|X| = 5.3 \cdot 10^6$: oltre il muro della F densa ~ 95 GB $\Rightarrow$ richiede **F sparsa** nel solver esatto — requisito, non ancora fatto). Blocco di zona Z5 (zona $\times$ sesso $\times$ background) pronto in `cs_build`: quote EM1–6 $\times$ G, IPF pattern-Z3.

Fit K8C (esatto, `-min-alpha 2e-4`): $MRE_{\alpha>0} = 6.0 \cdot 10^{-4}$ in 67 s; $H = 6.964$ nat (+1.122 vs K6C = 5.842); supporto 87 231/161 280. Decomposizione del guadagno: $H(\text{background}) \approx 0.94$ nat domina; `origine_genitori` aggiunge ~ 0.18 (quasi deterministica dato background per i rami immigrati). **Contrasto con la zona:** il background aggiunge diversità *quasi-indipendente* (condizionato solo al sesso, deficit di correlazione piccolo), la zona diversità *correlata* (deficit = informazione mutua zona $\leftrightarrow$ attributi). Due meccanismi distinti di arricchimento del seed delle bio.

Generalità: il ramo comunale della pipeline (fasi 0–4 del ricettario, K6C incluso) è stato verificato senza modifiche su un secondo comune (**Bologna**); per la zona restano i tre punti di §14.1.

10 Generalizzazione multi-comune: tre casi limite

La pipeline (fasi 0–4 comunali, K6C/K8C) è stata eseguita senza modifiche su tre comuni di scala e struttura territoriale molto diverse, a validazione della genericità del ricettario:

comune	popolazione	sub-aree	livello zona
Brescia (017029)	198 259	33 quartieri (ASC1)	K7C/K9C
Bologna (037006)	390 098	6 quartieri (ASC1) / 18 zone (ASC2)	K7C/K9C, entrambi i livelli
San Vito dei Normanni (074017)	17 931	nessuna (ASC1=ASC2= 0)	K6C/K8C soltanto

Registro parametrico: `build_zona_tables.py` v3 unifica gli script Brescia/Bologna in un unico motore con un dict `COMUNI` (CSV sezioni, colonna ASC, numero atteso di unità, nomi, gerarchia zona $\rightarrow$ quartiere se applicabile); aggiungere un comune = una voce nel registro. Bologna valida il caso multi-livello (stessa sezione, due colonne ASC1/ASC2 con gerarchia esplicita `ZONE_TO_QUARTIERE`).

Caso limite: comune senza sub-aree. San Vito (`COM_ASC1=COM_ASC2= 0` su tutte le sezioni: codice convenzionale ISTAT “nessuna partizione”, non una zona reale) non supporta K7C/K9C: si ferma a K6C/K8C. In `assign_nationality.py`, la rilevazione (`col_sez.nunique()<=1`) fa degradare automaticamente il passo (2a) a $P(\text{area} \mid \text{sesso})$ puramente comunale (il fallback già esistente per zone non coperte diventa il percorso primario), senza flag né branch aggiuntivi nel chiamante — stesso comando di Brescia/Bologna. Validato: 703/703 assegnati, doppia contabilità comunale $\leftrightarrow$ sezioni coerente anche su un’unica sezione aggregata (UE 53/117 vs 53/118), top-10 paesi coerente con la geografia migratoria del Sud (Romania, Marocco, Georgia, Nigeria, Senegal).

11 Due bug di feasibility sui casi limite

11.1 Indipendenza spuria: cittadinanza vs background

Su Brescia K8C, verifica di coerenza cittadinanza $\leftrightarrow$ background sul campione: 60 501/198 259 righe (30.5%) con combinazioni logicamente impossibili (es. `cittadinanza=ITL` con `background=straniero_imm`). Diagnosi: i blocchi B (cittadinanza) e G (background) erano vincolati solo contro la spine e verificati in aggregato (audit margini G-vs-B), ma *mai vincolati insieme nella stessa cella*; background implica cittadinanza in modo deterministico, ma nessun vincolo lo impone atomicamente $\Rightarrow$ il MaxEnt, a entropia massima, tende all'indipendenza fra le due variabili ovunque un vincolo esplicito non gliela neghi — anche quando l'indipendenza è impossibile per definizione.

Fix: blocco `GC_cittad_background` (arity 2, partizione completa `cittadinanza` $\times$ `background`, zero esatto sulle 6 celle impossibili, trattate come esclusioni strutturali come i vedovi 15–24). Verificato 0.0000% su Brescia e San Vito; effetto collaterale sano su Brescia K8C: celle escluse post-hoc 5 040 $\rightarrow$ 83 160 (il vincolo esclude un'ampia fetta di $|X|$ strutturalmente impossibile), H : 6.964 $\rightarrow$ 6.479 nat — il valore precedente era gonfiato da massa fantasma su combinazioni vietate, non da vera diversità.

Principio generale: quando due attributi sono in relazione deterministica (uno implica l'altro), la coerenza dei soli margini aggregati non basta — serve un vincolo diretto sull'incrocio, altrimenti il MaxEnt colma lo spazio libero con l'ipotesi di indipendenza. Estende la lezione E/F/Z-vs-Z (§??) al caso più severo: là il conflitto era numerico (margini quasi coerenti), qui è logico (celle vietate).

11.2 K9C: il conflitto attraverso una variabile derivata

Primo K9C completo (Bologna, zona+background, $|X| = 33 \times 5\,376 \times 6 = 967\,680$; qui 6 quartieri $\Rightarrow$ 967 680): con `GC` in posto ma `Z5` (zona $\times$ sezzo $\times$ background) costruita come nelle sessioni precedenti (IPF contro `Z1` e `G` soltanto), il fit ha mostrato la firma ormai nota — discesa fino a $MRE \approx 0.025$ (iter 100–120), poi risalita monotona fino a collasso totale ($H = 0$, supporto 1/967 680). Diagnosi: `Z5` non vede mai `cittadinanza`, ma background la implica; le quote di cittadinanza per zona che `Z5` induce implicitamente (aggregando i suoi background per gruppo ITL/FRG) non erano vincolate a coincidere con quelle — già affidabili, già armonizzate IPF contro `Z1` — del blocco `Z2`. Due decomposizioni diverse dello stesso margine (zona $\times$ sezzo $\times$ cittadinanza), stavolta mediate da una variabile derivata anziché condivisa esplicitamente: stessa famiglia della lezione generalizzata, un livello di indirection più sottile.

Fix: IPF di `Z5` eseguito *separatamente per ciascuna coppia* (sezzo, gruppo di cittadinanza), mai attraverso la frontiera ITL/FRG — righe: quote di zona per quel gruppo, da `Z2` aggregata su età (autorità già armonizzata); colonne: `G` ristretto al gruppo; inizializzazione: quote di background *entro* il gruppo da `z6` (EM1–6), pesate sui target di riga. Poiché la massa non attraversa mai la frontiera di gruppo, la coerenza con `GC` è garantita per costruzione. Audit aggiunto: `Z5` (aggregata per gruppo) vs `Z2`, $\max|\Delta| = 2.2 \cdot 10^{-11}$ — terzo controllo della famiglia Z-vs-Z, accanto a `Z2-vs-Z1` e `Z3-vs-Z1`.

Risultato (Bologna K9C, post-fix): discesa monotona (con il consueto tremolio fine di L-BFGS su duale grande), $MRE_{\alpha>0} = 3.8 \cdot 10^{-4}$ in 831 s, $H = 8.046$ nat, supporto 244 904/967 680; 0/390 098 incoerenze cittadinanza $\times$ background; marginali di zona sensati (15–18% per quartiere); top quota-stranieri per quartiere coerente con l'audit sub-comunale (Navile 0.205, San Donato-San Vitale 0.176, Borgo Panigale-Reno 0.158).

Nota di scala: Bologna con 6 quartieri resta sotto il muro della F densa ($|X| \approx 9.7 \cdot 10^5$, F stimata 5.9 GB); Brescia K9C (33 zone, $|X| \approx 5.3 \cdot 10^6$) richiede ancora la F sparsa (§15) — il fix di questa sezione si applica identico quando sarà eseguibile.

11.3 GibbsPCD su K9C: quarta verifica del pavimento e un effetto nuovo del vincolo GC

Caratterizzazione GibbsPCD su Bologna K9C ($m = 763$, $N = 4 \cdot 10^5$, Numba): pavimento predetto 0.0239, early stop a iter 846 ($\text{rel_improv} = -0.0093$) con $\text{MRE}_{\alpha>0} = 3.76 \cdot 10^{-2}$ — rapporto osservato/predetto $\approx 1.6\times$, più lasco delle tre verifiche precedenti (K6C $\sim 1.0\text{--}1.2\times$; K7C $\sim 1.0\times$) ma stesso ordine di grandezza e stesso segno: **quarta conferma indipendente della formula del pavimento**, su un quinto spettro di α . Il gap maggiore è coerente con l’arresto su un tratto ancora rumoroso (MRE in leggera risalita tra iter 750–800 subito prima dello stop): fluttuazione attorno al pavimento, non sottoallenamento sistematico. $H_{\text{gibbs}} = 8.412$ vs $H_{\text{exact}} = 8.046$ (eccesso di lisciatura $+0.37$ nat, coerente in verso e ordine di grandezza con tutti i confronti precedenti); $\text{KL}(\text{exact}||\text{gibbs}) = 0.092$.

Effetto nuovo: la massa spontanea sulle celle escluse da GC scala con l’estensione delle celle, non solo col loro numero. Massa spontanea pre-azzeramento sulle celle escluse: $2.76 \cdot 10^{-2}$ — un ordine di grandezza sopra i run senza GC (Brescia K6C $\sim 3\text{--}4 \cdot 10^{-3}$, K7C $\sim 4.7 \cdot 10^{-3}$). Con GC in campo le celle escluse sono 483 840 (metà di $|X|$, contro le poche migliaia dei soli vedovi 15–24), e il Gibbs — che si muove per sweep locali coordinata-per-coordinata — fatica sensibilmente di più a rispettare un vincolo che vieta un’intera regione estesa dello spazio rispetto a uno che ne vieta una manciata di celle isolate; il solver esatto, ottimizzando globalmente sul duale, non risente della stessa difficoltà (massa post-hoc = 0 in entrambi i casi, per costruzione). Il deliverable finale resta corretto (azzeramento post-hoc esatto), ma la massa spontanea pre-azzeramento diventa un indicatore utile della “difficoltà” che un vincolo di esclusione impone al sampler stocastico, proporzionale all’estensione delle celle vietate più che alla loro numerosità in astratto — distinzione che vale la pena portare nel disegno di futuri vincoli diretti su domini grandi.

12 F sparsa: dal muro di memoria al primo K9C completo

12.1 Motivazione e implementazione

Il costo dominante del solver esatto (matrice indicatrice $F \in \{0, 1\}^{|X| \times m}$, prodotti $F\lambda$ e $F^\top p$ ad ogni iterazione L-BFGS) è $O(|X| \cdot m)$ in tempo e memoria con rappresentazione densa. Brescia K9C ($|X| = 5,3 \cdot 10^6$, $m \approx 2600$) richiederebbe ~ 110 GB per la sola F — impraticabile. Ma F è strutturalmente quasi-sparsa: con vincoli organizzati in ~ 16 blocchi che sono quasi ovunque partizioni complete di X rispetto al loro sottoinsieme di variabili, ogni riga (un pattern $x \in X$) soddisfa esattamente un vincolo per blocco — densità attesa $\approx n_{\text{blocchi}}/m \sim 2\%$.

Patch al repo (`maxent-popsynth-pcd`): nuovo metodo `ConstraintSet.build_indicator_matrix_sparse`, che costruisce F direttamente in formato CSR (`scipy.sparse`) senza mai allocare l’array denso $|X| \times m$; `ExactMaxEntSolver` esteso con flag `sparse` (default `False`: K6C/K7C/K8C restano bit-identici) che seleziona il costruttore denso o sparso e corregge il prodotto trasposto (`alpha_hat = F.T @ p`, robusto a entrambi i formati, contro `p @ F` che non lo è per CSR). In `fit_cs.py`: flag `-sparse` propagato al costruttore; gestione di `excl_cells` con `np.asarray(...).ravel()` sul risultato di somma per colonne sparsa (che restituisce `np.matrix`, non array).

12.2 Collaudo (Bologna K9C) e risoluzione (Brescia K9C)

Collaudo: stesso CS di Bologna K9C (§11.2) rifittato con `-sparse`: densità osservata 1.50% (F, $967\,680 \times 763$, 137 MB) e 1.45% (F_g); risultato **identico al denso a quattro cifre** ($\text{MRE} = 3.96 \cdot 10^{-4}$ vs $3.81 \cdot 10^{-4}$, $H = 8.047$ vs 8.046 nat) in 46s anziché 828s — $18\times$ più veloce, $43\times$ meno memoria (F+F_g: ~ 269 MB vs 11,8 GB stimati densi). Correttezza e beneficio computazionale entrambi confermati prima di procedere sul caso vero.

Brescia K9C (33 zone + background, $|X| = 5,322,240$, $m = 2963 \rightarrow 2585$ dopo pruning): densità osservata 0.41–0.43% (ancora più bassa che a Bologna, coerente con più zone = più colonne a parità di non-zeri per riga); F ed F_g rispettivamente 732 e 698 MB (contro ~ 110 GB densi stimati per la sola F: fattore $\sim 150\times$). Costruzione di entrambe le matrici in 63 s; fit esatto convergente in 291 s, $\text{MRE}_{\alpha>0} = 5.7 \cdot 10^{-4}$, $H = 9.804$ nat, supporto 1,127,415/5,322,240 (21%); 2,744,280 celle escluse post-hoc (esattamente metà di $|X|$, la stessa frazione di Bologna, ora su un dominio $5,5\times$ più grande). **Primo K9C completo su Brescia**: il muro di memoria che bloccava questo livello dall’inizio della sessione è superato senza perdita di precisione.

Nazionalità two-stage applicata sul campione K9C: risultati identici (a due decimali) a quelli già ottenuti su K7C — stessa top-10 paesi, stessa mappa quartiere-top (Fiumicello/Chiesanuova $\rightarrow$ Pakistan, Primo Maggio/Don Bosco $\rightarrow$ Romania), doppia contabilità comunale $\leftrightarrow$ sezioni coerente ($\sim 3\%$) — atteso, poiché l’assegnazione dipende solo da zona/sexo/cittadinanza, invarianti rispetto all’aggiunta di background. Deliverable finale: `popolazione_K9C_naz.csv`, 198 259 individui $\times$ 12 attributi (zona, quartiere, sesso, età, stato civile, cittadinanza, istruzione, condizione, background, origine genitori, area, paese) — il vettore più ricco prodotto dalla pipeline, con cinque assunzioni numerate dichiarate lungo il percorso.

12.3 Additività dell’entropia tra espansioni indipendenti

Confronto a tre punti: K6C $H = 5.842$; K7C (solo zona) $H = 9.157$ ($\Delta_{\text{zona}} = +3.315$); K8C post-fix (solo background) $H = 6.479$ ($\Delta_{\text{background}} = +0.637$); K9C (zona+background) $H = 9.804$. Se le due espansioni fossero perfettamente indipendenti negli effetti aggiuntivi che portano oltre K6C, atteso $H_{\text{K6C}} + \Delta_{\text{zona}} + \Delta_{\text{background}} = 5.842 + 3.315 + 0.637 = 9.794$ — a 0.01 nat dall’osservato 9.804: **quasi perfetta additività**. Lettura: l’interazione zona $\times$ background catturata dai blocchi Z5/IPF aggiunge pochissima informazione oltre ai due effetti principali già misurati separatamente — coerente con l’assunzione (5) (quota di zona del background quasi indipendente dal resto), e un test quantitativo pulito della composizionalità dell’entropia quando due attributi vengono aggiunti in blocchi separati del CS.

12.4 Quinta verifica del pavimento e secondo punto della relazione massa-spontanea/estensione

GibbsPCD su Brescia K9C ($m = 2585$, $N = 4 \cdot 10^5$, Numba, sparse): pavimento predetto 0.0468, osservato $\text{MRE}_{\alpha>0} = 4.29 \cdot 10^{-2}$ — rapporto $\approx 0.92\times$, tra i migliori allineamenti della serie. **Quinta conferma indipendente** della formula, su un sesto spettro di α (il più esteso finora, 33 zone $\times$ 6 background). Massa spontanea sulle celle escluse da GC (pre-azzeramento): $5.10 \cdot 10^{-2}$, quasi doppia di Bologna ($2.76 \cdot 10^{-2}$) — **secondo punto** della relazione massa-spontanea/estensione-esclusione (§11.3): le celle vietate da GC sono 2 744 280 qui contro 483 840 a Bologna ($5,7\times$ più estese), e la massa spontanea cresce di un fattore comparabile ($1,8\times$) — pattern coerente, non più un’osservazione isolata. $H_{\text{gibbs}} = 10.363$ vs $H_{\text{exact}} = 9.804$ ($+0.56$ nat); $\text{KL}(\text{exact}||\text{gibbs}) = 0.161$. Decisione di produzione confermata anche a questa scala: esatto (sparse) 291 s vs Gibbs ~ 8700 s (gonfiato da una sospensione di sistema durante il run; tempo di calcolo effettivo stimato ~ 3700 s) per una precisione $\sim 75\times$ inferiore.

Nota pratica: run lunghi (Gibbs su domini grandi, ore) vanno protetti da interruzioni con `tmux` (sopravvive alla chiusura del terminale) e disattivando temporaneamente la sospensione automatica del sistema (una sospensione a metà run distorce i tempi misurati, pur senza comprometterne la correttezza).

13 Sintesi dei livelli e deliverable

	anno	$ X $	m	MRE esatto	H (nat)
K6C	1/1/2025	5 376	269	$5.0 \cdot 10^{-4}$	5.842
K7C	1/1/2024	177 408	2513	$3.6 \cdot 10^{-4}$	9.157
K8C (Brescia, post-fix GC)	1/1/2024	161 280	—	$5.8 \cdot 10^{-4}$	6.479
K9C (Brescia, 33 zone)	1/1/2024	5 322 240	2585	$5.7 \cdot 10^{-4}$	9.804
K9C (Bologna, 6 quartieri)	1/1/2024	967 680	763	$3.8 \cdot 10^{-4}$	8.046

Deliverable: `popolazione_K7C_naz.csv` — 198 259 individui $\times$ 11 attributi (zona, quartiere, sesso, eta, stato_civile, cittadinanza, istruzione, condizione, area, paese; ITL $\rightarrow$ paese Italia), ancorati all'1/1/2024, con 4 assunzioni dichiarate e numerate.

14 Ricettario: esecuzione della pipeline

Sequenza completa da zero a `popolazione_K7C_naz.csv`. Prerequisiti: `env ml` attivo; repo `maxent-popsynth-pcd` clonato in `~/progetti/`; `pip install lxml openpyxl`. Script in `~/progetti/gsp/scr`. Le fasi 0–4 sono **generiche per qualunque comune** (parametro `<codice>`, ITTER107); le fasi 5–8 sono generiche nel disegno ma gli script attuali hanno tre punti parametrizzati su Brescia, elencati in §14.1.

Fase 0 — catalogo (una tantum, riusabile).

```
python istat_catalog.py # scarica e indicizza 4884 dataflow
python istat_catalog.py istruzione # esempio di grep esplorativa
```

Fase 1 — tavole comunali (esplorazione staged, poi fetch; ~ 3 min per il throttling).

```
python fetch_comune.py <codice> --explore # strutture: dimensioni,
    territorio
python fetch_comune.py <codice> # 7 tavole -> data/comuni/<codice>
    >/
```

Fase 2 — tavole-vincolo comunali (per ogni ancoraggio che serve; K7C usa `-anno 2024`).

```
python build_constraints.py <codice> --anno 2024
python build_constraints.py <codice> --anno 2025 # opzionale, K6C recente
```

Verificare nel log: pop totale plausibile; `report.md` con MAE del raccordo (atteso ≈ 0 post-2018).

Fase 3 — ConstraintSet K6C e fit (opzionale ma consigliato come regressione).

```
python cs_build.py <codice> --anno 2025
python fit_cs.py <codice> --anno 2025 --eps 1e-8 --min-alpha 2e-4 --no-gibbs
```

Fase 4 — sezioni di censimento (bulk, nessun rate limit).

```
mkdir -p ~/progetti/gsp/data/submun && cd ~/progetti/gsp/data/submun
wget https://esploradati.istat.it/databrowser/DWL/PERMPOP/SUBCOM/
    Dati_regionali_2023.zip
unzip Dati_regionali_2023.zip "Dati_regionali_2023/R<NN>_<Regione>_2023_sezioni
    .xlsx" \
    "Dati_regionali_2023/TRACCIATO FILE REGIONALI.xlsx"
```

Estrarre il comune dal file regionale (filtro `PROCOM`, `xlsx` $\rightarrow$ `csv`) e verificare: n. sezioni, `COM_ASC1` popolata e con quante zone, sezioni fittizie 888888x, P1 vs popolazione attesa.

Fase 5 — tabelle di quartiere.

```
python build_zona_tables.py      # Z1-Z4 + zona_nomi -> data/comuni/<codice>/
                                zona_2023/
```

Audit stampati: totali = comunale, quota stranieri per quartiere (sanity qualitativa).

Fase 6 — ConstraintSet K7C e fit.

```
python cs_build.py <codice> --anno 2024 --livello K7C
python fit_cs.py <codice> --anno 2024 --livello K7C --eps 1e-8 \
    --min-alpha 2e-4 --no-gibbs
```

Nel build verificare: somme blocchi ($Z1-Z3 = 1.0000$), audit Z-vs-Z $\sim 10^{-11}$ e Z-vs-comunale = 0. Nel fit: $MRE_{\alpha>0}$ attesa $\sim 10^{-4}-10^{-3}$; se compare discesa $\rightarrow$ risalita, c'è un margine sovrapposto non armonizzato (§5). Output: `popolazione_K7C.csv`. Per il livello **K8C** (background + origine, senza zona): stessa coppia di comandi con `-livello K8C` (richiede la tavola `cens_migr_backg` in fase 1 — riga `DF_DCSS_MIGR_BACKG_PAR_TV_1_COM` in CORE — e il conseguente `build_constraints`, che produce `c7/c8`; per il livello zona, `build_zona_tables` produce anche `z6` da EM1-6). K9C: dopo la F sparsa. (Facoltativo, caratterizzazione GibbsPCD: stesso comando senza `-no-gibbs`, con `-pool` dimensionato dalla formula del pavimento e `-numba`.)

Fase 7 — nazionalità two-stage.

```
python assign_nationality.py <codice> --anno 2024
```

Verificare: classificazione UE stampata; doppia contabilità comunale $\leftrightarrow$ sezioni; top paesi e paese-top per quartiere. Output finale: `popolazione_K7C_naz.csv`.

14.1 Adattamento a un comune diverso da Brescia

Tre punti oggi parametrizzati su Brescia, da generalizzare (candidati per una v3 degli script):

1. **estrazione sezioni**: il filtro PROCOM dal file regionale è un one-liner manuale; `build_zona_tables.py` e `assign_nationality.py` leggono il path hardcoded `brescia_sezioni_2023.csv`;
2. **mappa nomi ASC** (`ASC_NOMI`): fornita a mano per Brescia; per altri comuni va reperita dal comune stesso (i codici `COM_ASC1` sono nel dato, i nomi no) e l'`assert len==33` parametrizzato;
3. **presenza delle ASC**: verificare che `COM_ASC1` sia popolata per il comune scelto; se il comune non ha partizioni amministrative dichiarate, la zona va costruita per aggregazione spaziale delle sezioni (basi territoriali 2021 + confini scelti).

Con questi tre punti resi parametrici, la pipeline è end-to-end generica: `<codice>  $\rightarrow$  popolazione_K7C_naz.csv`

15 Da fare / prossimi passi

- ☒ Nazionalità two-stage livello 1 — v0.4.
- ☒ Rosa v2 attributi (tre anelli) + background/origine (K8C fittato) — v0.5.
- ☒ Generalizzazione multi-comune (Brescia/Bologna/San Vito) + fix GC (indipendenza spuria cittadinanza-background) + fix Z5-vs-Z2 (K9C Bologna completo) — v0.6.
- ☒ **F sparsa** nel solver esatto: patch al repo, collaudo su Bologna, primo K9C completo su Brescia ($|X| = 5.3 \cdot 10^6$) + nazionalità + additività dell'entropia + quinta verifica del pavimento — v0.7.
- ☐ Confronto sparse-exact vs GibbsPCD sistematico su domini $\geq 10^6$ (materiale già in parte raccolto: Bologna e Brescia K9C).

- ☐ **AVQ**: download microdati pubblici 2024, lettura tracciato; strato condizionali (fiducia istituzionale, stili di vita, titolo godimento casa, pendolarismo post-COVID).
- ☐ Reddito MEF/AdE comunale (anello 1.5, fonte non riconciliata).
- ☐ Check di sostanza K8C/K9C: mappa background×condizione (es. straniero_immigrato vs in_cerca).
- ☐ Run B (pool = popolazione, λ caldi): misura diretta del pavimento stazionario; richiede warm start (subclass del solver) — da ridiscutere prima.
- ☐ Via/civico entro quartiere (macchinario geografico v3).
- ☐ Seed esplicito nel kernel Numba.
- ☐ Variante Caffaro: esclusione sezione fittizia (549) con riscalatura.
- ☐ σ campionarie del censimento; UE/extra-UE come raffinamento della cittadinanza nel CS; famiglie.
- ☐ Aggiornamento annuale: sub-comunale 2024 al rilascio.