

Animarium — documento di design

Synthetic populations of Italian cities v0.4 — 29 luglio 2026 Riferimento dati:

`GSP_popolazioni_full_riferimento_v16.md` (§ citati sotto).

Rispetto alla v0.3: nome fissato. Aggiunta §3.2, la disposizione fisica del file come scelta di progetto. Aggiunta §7.2, il modello di costo ricavato dal passo 2. Riscritta §9 con misure invece che stime. Aggiunta §12, registro dei miglioramenti, con annotati anche quelli scartati e il perche'. Aggiunta §13, diario delle misure.

0. Decisioni prese

	scelta	stato
nome	Animarium — Synthetic populations of Italian cities	fissato
stack	Observable Framework + DuckDB-WASM, applicazione statica	verificato sul campo (§7.2)
destinazione	solo interna per ora	interruttore <code>--pubblico</code> predisposto
riferimento	una serie, valutata al livello spaziale del filtro	§3.4
disposizione del file	tre blocchi di colonne, righe per <code>zona,</code> <code>sezione</code>	verificata (§3.2, §7.2)

`Albo Pretorio`, valutato e scartato come nome del viewer, resta riservato al corpus di comunicazioni istituzionali di SimComm/Caffaro — ordinanze comunali, materiali ATS/ARPA — dove nomina l'oggetto giusto.

1. Scopo, utenti, non-obiettivi

Tre utenti, in ordine di priorita' temporale.

1. **Tu, adesso.** Ispezione, controllo qualita', ricerca di anomalie prima che finiscano in un paper.
2. **I collaboratori** (Tarantino, Pachet, Zucker, il consorzio PRISM). Devono capire cosa possono chiedere ai dati senza leggere mille righe di documentazione. Link permanenti citabili.
3. **Il pubblico.** Fuori portata per ora, ma le decisioni che lo renderebbero possibile costano zero adesso e molto dopo (§7.3).

Non-obiettivi dichiarati, da scrivere nella pagina Metodo:

- non e' uno strumento di stima locale: nessun numero e' una misura del quartiere reale;
- non genera popolazioni: consuma i `_full` gia' prodotti;
- non fa inferenza causale ne' previsione.

2. Il principio guida: livello di garanzia

Ogni numero mostrato appartiene a una di **quattro classi**, visibile sempre.

classe	badge	attributi	cosa garantisce
V — vincolato	pieno	anello 1	marginali e incroci del constraint set, $MRE \approx 4 \cdot 10^{-4}$
A — allocato	mezzo pieno	<code>sezione</code> , <code>eta_anni</code> , <code>via</code> , <code>civico</code> , <code>lon/lat</code>	allocazione esatta per sezione (MAE 0,74-1,58), sotto le assunzioni (8)-(10)
C — condizionato	contorno	<code>paese</code> , <code>area</code>	vincolato ai margini censuari, struttura geografica secondo il tier
D — donato	tratteggiato	le 21 AVQ	nessuna informazione geografica (assunzione 6)

Qualunque variazione spaziale di una variabile di classe **D** e' **interamente compositiva per costruzione**. L'app lo dice dove il numero appare, non altrove.

Numerosita' efficace. Le statistiche AVQ poggiano sui **donatori distinti**, non sugli individui: a Bologna il riuso medio e' 84×, quindi 500 individui possono nascere da ~6 donatori. Tutte le bande di incertezza sulle AVQ usano `n_eff`. Richiede `donor_id` nel bundle — dipendenza aperta (§11).

3. Modello dei dati

3.1 Un bundle, non l'albero di lavoro

Il viewer **non legge mai** `~/progetti/gsp/data/comuni/...`. Legge un bundle versionato, prodotto da uno script di export. E' cio' che rende l'app pubblicabile senza modifiche: in locale e in rete gira sugli stessi byte.

bundle/	fuori dal repo git, ricostruibile
manifest.json	
qualita.json	
comuni/	
036023/	
pop.parquet	42 colonne, 10 row group
rif_comune.parquet	referimento livello 0 (§3.4)
rif_zona.parquet	referimento livello 1
rif_sezione.parquet	referimento livello 2
sezioni.topojson	
zone.topojson	
regioni/	
emilia_romagna.topojson	

Il bundle sta fuori dal repo. Si ricostruisce in un comando; il repo contiene codice, schema del manifest e script di build.

3.2 Disposizione fisica del file — e' una scelta di progetto

Misurata nel passo 2 (§7.2), non ereditata dal CSV. Cinque decisioni, tutte verificate:

(a) Colonne ordinate per uso, in tre blocchi. DuckDB-WASM legge **intervalli di byte contigui**, non colonne: chiedere tre colonne o cinque dello stesso blocco costa identico. I blocchi li definiamo noi.

A	filtri e marginali	zona, quartiere, sesso, eta, stato_civile, cittadinanza, istruzione, condizione, background, origine_genitori, paese, area, eta_anni, quinq,
	sezione	
B	AVQ	le 21 _num
C	pesanti (mappa)	id, indirizzo_fonte, via, civico, lon, lat

Chi esplora paga A. Chi apre il pannello fiducia paga B. Chi apre la mappa a punti paga C. Nessuno paga cio' che non guarda.

(b) Righe ordinate per `(zona, sezione)`. Il filtro piu' frequente dell'interfaccia e' la zona; con l'ordinamento per sola sezione non poteva nulla. Misurato: il filtro su una zona legge il **22%** di quanto legge la stessa query senza filtro. Le sezioni restano contigue dentro la zona, quindi la selezione a lazo continua a potare.

(c) Row group da 20.000 righe — dieci per Modena. Compromesso fra granularita' della potatura e peso del footer, che a dieci gruppi e' 0,073 MB.

(d) `id` in `DELTA_BINARY_PACKED`. Era la colonna piu' pesante del file (0,79 MB, il 15%): successione strettamente crescente, il dizionario fallisce e zstd non morde. Dopo la codifica

sta sotto i 90 KB.

(e) (lon)/(lat) in (BYTE_STREAM_SPLIT). Guadagno modesto (0,65 → 0,59 MB) perche' le coordinate sono al piu' 60.488 valori distinti su 184.597 righe, e il dizionario ne stava gia' sfruttando la ripetizione. Si tiene, ma la motivazione originale era sbagliata.

Risultato su Modena: CSV 57,76 MB → Parquet **3,123 MB (5,4%)**. Dieci capoluoghi emiliani stanno in una trentina di megabyte.

blocco	peso	quota
A filtri e marginali	0,675 MB	21,6%
B AVQ	1,411 MB	45,2%
C pesanti	0,980 MB	31,4%
footer	0,073 MB	2,3%

3.3 Colonne aggiunte dall'export

colonna	stato
(id)int32	fatto, delta-encoded
(quinq)int8	fatto, ma candidato alla rimozione (§12)
(donor_id)	atteso dalla pipeline — blocca (n_eff)
(donor_anno)int16	atteso — rende ricostruibile il <i>planned missing</i> , e ha permesso di eliminare 21 colonne AVQ grezze
(cella_avq)	atteso — rende ispezionabile il collasso gerarchico
(macroeta), (istr4)	attesi — sono le variabili su cui girano davvero le AVQ
(lon_j), (lat_j)	da fare in (build_bundle)

Le AVQ grezze sono state eliminate: (non_applicabile) contro mancante e' una distinzione che non serve riga per riga, perche' il *planned missing* dipende dall'annata del donatore e non dall'individuo. Si recupera per intero con (donor_anno). Il blocco B e' sceso da 2,659 a 1,411 MB.

3.4 Il riferimento — una serie, tre livelli, tre stati

Regola del livello. Riferimento valutato al livello spaziale piu' fine compatibile col filtro. Tre livelli e una ricaduta:

filtro attivo	riferimento
nessuno, o solo attributi non spaziali	censimento comunale
un quartiere o un insieme di zone	tavole di zona (<code>zona_2023/</code>) + fonti comunali dove esistono
una selezione di sezioni	<code>P1</code> , <code>ST1</code> , <code>ST16/19</code> , <code>ST25-30</code> , <code>P30-45</code> <code>P67-82</code>
zona ^ attributi assenti dalla tavola	ricaduta al comune, dichiarata

Regola dello stato. Ogni coppia (attributo × livello) sta in uno di tre stati, mostrato come badge:

stato	significato	come si legge lo scarto
verifica	il valore reale a quel livello e' entrato nella pipeline	accordo garantito. Uno scarto e' un bug, non un risultato
validazione esterna	esiste e non e' stato usato	informativo, con linea di base 1-2% (anagrafe contro censimento)
assente	nessun dato osservato a quel livello	dichiarato, ricaduta al livello superiore

Lo stato **non si mantiene a mano**: `constraints_2024/manifest.json` dichiara gia' fonte e tipo di ogni blocco, `enrich.py` dichiara le colonne usate come pesi. `build_bundle.py` deriva la classificazione da li'.

Dove la validazione esterna c'e': solo nelle fonti comunali anagrafiche di zona, mai usate come *livelli* (il tier ne usa la forma come seed, con margini censuari). Sono i numeri di §10 del riferimento: Modena 0,982-1,007 sulla popolazione per quartiere; Primo Maggio 0,329 contro 0,293.

Dove non c'e', e va detto. A livello di sezione **tutto l'osservato e' usato**: `P30-P45` e `P67-P82` non sono un dato accessorio, sono il **peso stesso** dell'allocazione,

$$w(\sigma) = (\sum_{k \in e} P_{\{s,k\}}(\sigma)) \times [q_{\{s,e\}}(\sigma) \text{ se straniero, } 1-q \text{ se italiano }]$$

Non esiste quindi alcun test out-of-sample dell'assunzione (8): il dato per farlo non c'e', che e' il motivo per cui l'assunzione e' dichiarata.

Le tre sorgenti non spaziali: censimento comunale per l'anello 1, `paese`, `area`; ISTAT eta' singola per `eta_anni`; **AVQ regionale pesata** per le 21 di classe D, con intervallo di confidenza. Per queste ultime la marginale sintetica comunale e la stima regionale differiscono **esattamente per composizione**, quindi la riga di scomposizione di §4.2 spiega lo scarto per intero: una verifica gratuita su ogni pannello.

4. Le viste

Cinque pagine: **Citta'**, **Esplora**, **Individuo**, **Confronta**, **Metodo**.

4.1 Esplora — i filtri

Colonna sinistra filtri, corpo marginali, mappa a destra o sotto. Crossfilter.

Filtri di v1, dodici: `zona` (multiselezione o dalla mappa), `sezione` (solo via lazo), `sezzo`, `eta`, `stato_civile`, `cittadinanza`, `istruzione`, `condizione`, `background`, `origine_genitori`, `paese`, `area`, `eta_anni`.

Le AVQ non sono filtri in v1, sono variabili mostrate: filtrare su `FIDUCIA` e guardare la mappa produce una figura che sembra dire qualcosa sulla geografia della fiducia e non lo dice.

Barra di stato: `n` · % della citta' · `n_eff` donatori · sezioni toccate · livello del riferimento attivo · badge rosso se `n < 200` o `n_eff < 30`.

4.2 Marginali

Una serie sintetica, fino a due marcatori:

elemento	resa
sintetico	barre piene, colore d'accento
riferimento censuario	rombo pieno — stato <i>verifica</i>
riferimento comunale	rombo vuoto — stato <i>validazione esterna</i>

Non si leggono allo stesso modo: sul rombo pieno lo scarto atteso e' zero e ogni deviazione e' un guasto; sul vuoto lo scarto atteso e' l'1-2% dello sfasamento anagrafe-censimento, e cio' che eccede e' segnale.

Senza filtro spaziale il riferimento comunale e' anche **il valore atteso sotto indipendenza** fra attributo mostrato e filtro, quindi lo scarto e l'associazione. Con filtro spaziale diventa un confronto quartiere per quartiere. Due usi dello stesso pannello, da etichettare.

Modalita' Δ: scarti dal riferimento con banda $\sqrt{(p(1-p)/n)}$, e n_{eff} per la classe D.

Riga di scomposizione (classi C e D):

AMBIENTE, Fiumicello vs riferimento: $\Delta = -0,07$
spiegato dalla composizione: $-0,07$ (100%)
residuo areale: $0,00$

Pannello fiducia istituzionale: dodici medie su asse 0-10, con i riferimenti nazionali AVQ 2024 come tacche fisse (vigili del fuoco 8,10 · forze dell'ordine 6,70 · ASL 6,34 · Comune 5,13 · Regione 4,65) e le fasce di copertura come tratteggio. Sotto, la matrice di correlazione con $min_periods$, che riproduce la struttura a due fattori.

4.3 Mappa

Quattro modalita': **Individui** (punti con jitter), **Sezioni** (il default analitico), **Zone**, **Esagoni** H3.

La metrica di default non e' il conteggio — un conteggio filtrato riproduce la densita' di popolazione. In ordine: **quota**, **lift**, **z**, conteggio. Con quota e lift serve shrinkage empirico-bayesiano, o almeno lo sbiadimento delle sezioni sotto ~30 individui filtrati.

Affiancamento sintetico/reale: sulle sezioni e' **verifica**, non validazione — quelle colonne sono i pesi dell'allocazione. Sulle zone contro fonte comunale e' validazione vera, ed e' li' che la mappa dice qualcosa di nuovo.

Dettagli da gestire: convivenze (50-630) al centroide di zona, escluse dai punti per default; $indirizzo_fonte = "zona"$ idem; jitter radiale deterministico ~8 m sui civici condivisi; tiles Protomaps self-hosted, nessuna chiave API.

4.4 Individuo

Quaranta campi per anello, ciascuno col badge di garanzia, con la catena di provenienza inclusa la colonna P che ha determinato la sezione. E' lo strumento di debug piu' efficace che esista, ed e' **gia' il prompt della persona** per il tier 2.

4.5 Confronta

Livello A — comune (sicuro): marginali affiancati, tabella carta d'identita' di §10.

Livello B — distribuzione fra sezioni (il livello giusto): le sezioni sono unita' ISTAT di disegno omogeneo, i 4 quartieri di Modena e i 33 di Brescia no. ECDF o ridgeline, piu' la decomposizione della varianza ($5,9\times \rightarrow 43,5\times$) in forma grafica.

Livello C — zone (con avviso): partizioni non confrontabili.

Avviso obbligatorio sulle AVQ: Parma, Bologna e Modena condividono lo stesso pool di 4.629 donatori emiliani, quindi ogni differenza AVQ fra le tre e' integralmente compositiva.

Brescia attinge a un pool diverso (8.111), e un confronto Brescia-Bologna mescola composizione e differenza di pool.

4.6 Metodo e qualita'

- MRE per comune; MAE per sezione come scatter osservato-sintetico;
- copertura AVQ nelle tre fasce, nota sul *planned missing*;
- riuso dei donatori, col tetto strutturale (99,7-100% del pool);
- **le sette assunzioni** in elenco cliccabile: cliccando la (8) si illuminano gli attributi che ne dipendono, ovunque nell'app;
- tier del paese, coi numeri di §6 (2,08-2,57 volte l'ipotesi nulla al quartiere; 1,01-1,04 alla sezione, cioe' nulla, correttamente);
- provenienza dei nomi di zona e l'incidente di Bologna;
- **i due diagnostici di §13**, con le mappe dei residui.

5. Interazione e stato

Crossfilter completo; stato interamente nell'URL:

```
/esplora/017029?zona=17029012,17029015&sezzo=F&istruzione=laurea_o_its  
&mostra=AMBIENTE,PUNTIFI10&mappa=sezioni&metrica=lift
```

Serve a mandare una vista a Tarantino in una riga, citare una figura in un paper con un link riproducibile, ricostruire in un secondo lo stato in cui hai visto qualcosa di strano.

Esportazioni con provenienza incorporata: PNG/SVG, CSV dei marginali con riferimento e stato, permalink, GeoJSON degli aggregati.

6. Grafica

Estetica dell'anagrafe: registro amministrativo reso in modo contemporaneo. Serif per titoli e numeri grandi, sans neutro per l'interfaccia, **monospaziato con cifre tabulari per tutte le cifre**. Un solo accento per il sintetico; i riferimenti in neutro scuro, distinti per *forma* (rombo pieno o vuoto) e non per tinta, così la distinzione verifica/validazione sopravvive alla stampa in bianco e nero. Densità alta, small multiples piccoli e numerosi. Base chiara per le coropleti, scura per i punti. Transizioni brevi sui cambi di filtro; nient'altro si muove.

7. Architettura

7.1 Gli strumenti

strato	strumento	stato
bundle	Python: pandas, geopandas, duckdb, pyarrow, mapshaper	<code>to_parquet.py</code> fatto
impalcatura	Observable Framework	da avviare
query	DuckDB-WASM 1.29	verificato
grafici	Observable Plot	
mappa	MapLibre GL + deck.gl	
geometrie	TopoJSON + mapshaper	
hosting	nessuno per ora; <code>serve_range.py</code> in locale	

7.2 Il modello di costo — risultato del passo 2

Le tre domande del cancello hanno tutte risposto affermativa, e la misura ha prodotto qualcosa di piu' utile delle risposte singole: **una formula che permette di calcolare il costo di un pannello prima di scriverlo.**

```
costo(query) = footer +  $\sum$  peso(blocco toccato)  $\times$  (row group non potati / totale)
```

Con footer 0,073 · A 0,675 · B 1,411 · C 0,980 su Modena, sette misure su otto cadono entro il 20% della previsione (§13.2).

Tre corollari, tutti controintuitivi e tutti verificati:

1. **Il numero di colonne richieste e' irrilevante.** Q1 ne chiede tre e Q2 cinque dello stesso blocco: costano **identico**, 0,792 MB. L'unita' di lettura e' il blocco.
2. **La potatura per riga funziona in modo pulito:** un row group su dieci costa il 10,7% del totale.
3. **La potatura spaziale funziona**, ma solo grazie all'ordinamento per `zona`: il filtro su un quartiere costa il 22% della stessa query senza filtro. Con l'ordinamento per sola sezione avrebbe letto tutto.

Conseguenza per il design: il vincolo che avevo previsto in §9 della v0.3 — «serve `agg_sezioni.parquet` per coprire la prima schermata» — **e' sparito**. La prima schermata costa 0,79 MB e arriva in poco piu' di un secondo. L'aggregato precalcolato resta utile ma non e' piu' strutturale.

7.3 Cosa costa zero adesso e molto dopo

1. **interruttore** `--pubblico` in `build_bundle.py`: rimuove `via` e `civico`, aggancia i punti al centroide dell'edificio. Va scritto ora anche se non si usera';
2. **etichettatura**: banner «individuo sintetico», watermark negli export PNG, campo di provenienza in ogni CSV;
3. **nessuna dipendenza da servizi con chiave API**, mappa inclusa.

Ogni individuo sintetico sta a un civico ANNCSU esistente, e su Brescia il contesto Caffaro rende la prima cosa meno teorica che altrove.

8. Estensibilita'

Aggiungere una citta' non deve toccare il codice dell'interfaccia. Tutto cio' che varia sta in `manifest.json`, generato da `G.COMUNI`: codice, nome, slug, regione, pool AVQ regionale, livello ASC e sua etichetta, numero di zone, tier, attributi presenti, riferimenti per livello col rispettivo stato, numeri di qualita'.

```
to_parquet.py {CODICE}
build_bundle.py {CODICE}
verifica_bundle.py {CODICE}
```

Controlli obbligatori: totali coincidenti col censimento; campo `nomi_verificati`: `[metodo_a, metodo_b]` **obbligatorio**, altrimenti il bundle non si costruisce; poligoni pari alle zone attese; nessun individuo fuori dal poligono comunale; copertura AVQ nelle fasce; `donor_id` presente e riuso coerente; stato di ogni riferimento derivato e non scritto a mano.

Emilia-Romagna. I prerequisiti regionali sono gia' pagati: ogni capoluogo costa la mezz'ora di §12 del riferimento. Piacenza, Reggio, Ferrara, Ravenna, Forli', Cesena, Rimini portano la regione a dieci comuni, ~1,8 milioni di individui e **~30 MB di bundle**.

Con dieci citta' la decomposizione tra/dentro su dieci partizioni di taglia diversa diventa una figura che oggi non esiste in nessun paper. Non e' un obiettivo di v1, ma la struttura del bundle la prevede.

9. Prestazioni — misurate, non stimate

Su Modena, 184.597 individui, Parquet 3,123 MB, server locale.

operazione	misurato
inizializzazione DuckDB-WASM (a caldo)	0,69-0,77 s
footer, pagato una volta per sessione	0,073 MB
esplorazione demografica, prima query	0,79 MB · ~1,3 s
ogni filtro successivo sullo stesso blocco	0 byte · 100-220 ms
filtro su una zona	0,23 MB · ~0,6 s
pannello fiducia istituzionale	0,82 MB
mappa a punti	0,92 MB
sessione piena, tutto visitato	~2,5 MB

Meno di due fotografie. Il vincolo di progetto non e' piu' la banda ma il tempo di inizializzazione, che e' fisso e indipendente dai dati.

10. Fasi

F0 — i due diagnostici. ✓ fatto su Modena e Parma. Risultati in §13.1. Restano Bologna e Brescia.

F1 — smoke test dello stack. ✓ fatto. Tutte e tre le domande risolte, modello di costo in §7.2, misure in §13.2.

F2 — bundle. In corso. `to_parquet.py` fatto e verificato; `build_bundle.py` da scrivere: manifest, aggregati per sezione, geometrie, riferimenti coi tre stati. **Rischio principale:** `donor_id`.

F3 — Esplora, senza mappa. Filtri, marginali, regola del livello, tre stati, modalita' Δ, scomposizione. Un comune. Qui si decidono tipografia, badge e palette.

F4 — mappa. Quattro modalita', metriche, shrinkage, affiancamento, selezione spaziale.

F5 — le altre citta' e il manifest. L'estensibilita' va provata aggiungendo il quarto comune senza toccare l'interfaccia.

F6 — Individuo, Metodo, Confronta, e la grafica in senso proprio.

11. Questioni aperte

1. `donor_id`: recuperabile dai file esistenti, o richiede di rilanciare `assign_avq.py` sui quattro comuni? Blocca F2 e tutta la statistica su `n_eff`. Se va rilanciato, aggiungere

nello stesso passaggio (`donor_anno`), (`cella_avq`) e il livello di collasso.

2. **AVQ filtrabili**: solo mostrate in v1, o filtrabili dietro interruttore?
3. **Fonti comunali di zona**: quali sono disponibili come *livelli*, oltre a quelle gia' usate come seed? Determina quanta validazione esterna l'app puo' offrire.
4. **Emilia-Romagna**: quanti capoluoghi nei prossimi mesi, e la vista regionale entra o resta predisposta?
5. **Modena e i 37 rioni**: se entrassero in pipeline, la vista Zone di Modena passerebbe da inutile a interessante.
6. **Le due riparazioni di §13.1** vanno fatte, e in che ordine rispetto al viewer?

12. Registro dei miglioramenti

Fatti, con effetto misurato

	effetto
colonne in tre blocchi per uso	Q5 da 2,297 a 0,915 MB
righe per (<code>zona</code> , <code>sezione</code>)	filtro di zona al 22% invece che al 100%
(<code>id</code>) DELTA_BINARY_PACKED	0,79 MB → <0,09 MB
(<code>lon</code>)(<code>lat</code>) BYTE_STREAM_SPLIT	0,65 → 0,59 MB (motivazione originale sbagliata)
AVQ grezze eliminate	blocco B 2,659 → 1,411 MB
row group 50k → 20k	potatura piu' fine, footer 0,049 → 0,073 MB
file 5,22 → 3,12 MB	

Proposti, non ancora fatti

- **rimuovere** (`quinq`) dal Parquet: 0,089 MB, il 13% del blocco caldo, ed e' (`least(eta_anni // 5, 15)`) in SQL. Serviva ai diagnostici, che pero' girano in Python sul CSV;
- **rimuovere** (`quartiere`): e' l'etichetta di (`zona`), un dizionario da 4-33 voci che sta gia' nel manifest. Con (`quinq`), porta A da 0,675 a ~0,55 MB, cioe' -18% su cio' che si legge a ogni sessione;
- (`donor_anno`) al posto delle AVQ grezze eliminate, per ricostruire la distinzione fra (`non_applicabile`) e *planned missing*;
- **riga «aggregazione tipica» in** (`to_parquet.py`): e' fuorviante. Suggerisce che il costo sia la somma delle colonne richieste, mentre e' il blocco. Va sostituita dalla tabella dei tre blocchi.

Scartati, col motivo — per non ripensarci

- **spezzare il blocco AVQ** in fiducia e sanita'. Q4 ha la sovralettura peggiore (0,75 MB netti per una colonna da 0,090), ma **Q4 non e' una query realistica**: nell'interfaccia la fiducia istituzionale e' un pannello che mostra tutte e dodici le `PUNTIFI` insieme, e leggerebbe il sotto-blocco comunque. Spezzare aiuterebbe solo chi chiede una sola variabile sanitaria, che e' il caso raro;
- **AVQ in int8 con sentinelle**. Ogni `PUNTIFI` pesa gia' 0,090 MB su 184.597 righe, cioe' mezzo byte a riga: con dodici valori distinti il dizionario e' a 4 bit, praticamente all'ottimo teorico. Non c'e' niente da guadagnare;
- `agg_sezioni.parquet` **come requisito strutturale** per la prima schermata. Serviva a mascherare un costo d'ingresso che non esiste (§7.2). Resta come comodita', non come necessita';
- **coordinate in float64**. float32 da ~0,4 m di precisione, piu' che sufficiente per la resa cartografica.

13. Diario delle misure

13.1 F0 — i due diagnostici (Modena e Parma)

(a) **Il seam quinquennale**. Riaggregazione del sintetico alle sedici classi ISTAT contro `P{30+k}`/`P{67+k}`, per sezione e sesso.

Risultato negativo pulito: il MAE grezzo del seam e' indistinguibile dagli altri.

Normalizzando per la dimensione di classe — la regola di §11.1 del riferimento — le due classi del seam finiscono **nei primi tre posti su sedici in entrambe le citta'** (Modena `5-9` 1° e `10-14` 3°; Parma `10-14` 1° e `5-9` 2°). Per caso vale $\sim 6 \cdot 10^{-4}$. Ma l'eccesso e' del 40%, non di un ordine di grandezza: **l'ipotesi di uniformita' non e' una sorgente d'errore dominante**.

Risultato sistematico, non previsto: dentro ciascuno dei cinque bin veri, il sintetico pende verso il **giovane**, con la prima classe in positivo e l'ultima in negativo. **Dieci prove su dieci** fra le due citta', 0,10–0,44 punti percentuali.

	Modena	Parma
15-24	+0,158 / -0,158	+0,186 / -0,186
25-34	+0,110 / -0,110	+0,278 / -0,278
35-49	+0,351 / -0,438	+0,234 / -0,260
50-64	+0,101 / -0,097	+0,201 / -0,131
65-74	+0,199 / -0,199	+0,209 / -0,209

Nella regione infantile il verso **si inverte**: `10-14` sovrarappresentata di +0,37 (Modena) e +0,35 (Parma). E' l'unico posto dove opera la frazione $4/5-1/5$, e ha una direzione precisa — **il sintetico mette troppo pochi novenni**: la quota vera dei novenni dentro il quinquennio 5-

9 non e' un quinto. Indiziato per il resto: l'assunzione (9), la forma dell'anagrafe comunale entro il bin.

Terzo fatto, il piu' grosso: i totali di bin del constraint set SDMX non coincidono con gli stessi bin aggregati dalle colonne P — fino a +1,42% (Parma, (15-24)) e -1,02% (Modena, (75+)).

Non replica in segno fra le due citta', quindi non e' calendario ma rumore fra due prodotti censuari. Il controllo obbligatorio «totale SDMX = (P1)» e' esatto al singolo abitante e non puo' vederlo.

(b) Coerenza fra eta' esatta e istruzione.

	violazioni	quota
Modena	4.867	2,64%
Parma	5.434	2,74%

Concentrate nei bin (9-14) (18,8% e 22,2%) e (15-24) (16,5% e 16,1%), zero altrove. Il vincolo sull'istruzione usa la classe grossa (y9-24), l'IPF con soglie distribuisce i titoli su tutto l'arco, e (eta_anni) arriva dopo in modo indipendente.

Riparazione proposta: permutare (istruzione) fra individui entro (zona, sesso, bin). E' esattamente cio' che e' vincolato, e l'assunzione (8) dichiara (sezione $\perp$ istruzione), quindi non si perde nulla di garantito.

Nota sulla variazione fra quartieri: la quota grezza varia (Parma 2,04% a 3,19% su 13 quartieri) ma **deve** variare, perche' e' la quota di 9-24enni moltiplicata per il tasso interno. Il test corretto e' il tasso condizionato sugli individui a rischio, aggiunto allo script.

(c) Due record impossibili gia' a livello di bin, entrambi a Parma, zero a Modena: (diploma) a 2 anni (bin (0-8), fuori dall'universo dell'istruzione, che parte da 9 anni) e (post_laurea) a 13 (bin (9-14), soglia 22). Sono 10^{-5} , massa residua del fit, non un errore sistematico.

Riparazione proposta: aggiungere alle esclusioni $\alpha=0$ le otto coppie ((bin, istruzione) impossibili — (0-8) $\times$ {elementare, media, diploma, laurea_o_its, post_laurea} e (9-14) $\times$ {diploma, laurea_o_its, post_laurea}. Effetto collaterale: cambia il conteggio delle celle escluse, quindi la formula di controllo di §12 del riferimento va aggiornata.

Previsione da raccogliere su Bologna e Brescia: se e' massa residua del fit, il numero scala col supporto (Modena (|x|)=645.120 $\rightarrow$ 0 record; Parma 2.096.640 $\rightarrow$ 2; Bologna 2.903.040 $\rightarrow$?; Brescia 5.322.240 $\rightarrow$?).

13.2 F1 — smoke test DuckDB-WASM (Modena, file riordinato)

Otto query isolate, ognuna contro un'istanza appena creata.

	misurato	modello	scarto
Q0 <code>count(*)</code>	0,073	0,073	esatto
Q1 3 colonne di A	0,792	0,748	+6%
Q2 5 colonne di A	0,792	0,748	+6%
Q3 A+id, 1 row group su 10	0,167	0,141	+18%
Q3N A+id, tutti	0,948	0,748	+27%
Q4 zona + <code>PUNTIFI10_num</code>	0,823	0,600	+37%
Q5 <code>lon</code> , <code>lat</code>	0,915	1,053	-13%
Q6 filtro su una zona	0,230	0,208	+11%

Rapporti chiave: **Q3/Q3N = 10,7%** (un row group su dieci, esatto); **Q6/Q2 = 21,8%** (due row group su dieci).

Tempi a caldo 100–220 ms; inizializzazione 0,69–0,77 s.

Errore di metodo commesso e corretto: la prima misura di Q3 era contaminata, perche' le query di una stessa sessione si scaldano a vicenda — Q1 aveva gia' letto il blocco A, quindi Q2 e' costata **zero byte** e Q3 misurava solo il residuo. Da qui la modalita' isolata e la query di controllo Q3N a colonne pari. La contaminazione, letta come fenomeno invece che come errore, e' esattamente cio' che ha rivelato la struttura a blocchi.