

Animarium — documento di design

Synthetic populations of Italian cities v0.5 — 29 luglio 2026 Riferimento dati:

GSP_popolazioni_full_riferimento_v16.md (§ citati sotto).

Rispetto alla v0.4: `donor_id` risolta e non piu' bloccante (§3.3, §13.3). `n_eff` ricalcolato con la formula di Kish e per universo di variabile: i numeri sono molto peggiori e la regola di allarme era rovesciata (§2, §4.1). Aggiunta §0.1, il metodo di lavoro. Aggiunta §14, cosa tutto questo significa per SimComm. Invertite F2 e F3 (§10).

0. Decisioni prese

	scelta	stato
nome	Animarium — Synthetic populations of Italian cities	fissato
stack	Observable Framework + DuckDB-WASM, statico	verificato (§7.2)
destinazione	solo interna per ora	<code>--pubblico</code> predisposto
riferimento	una serie, valutata al livello spaziale del filtro	§3.4
disposizione del file	tre blocchi di colonne, righe per <code>zona, sezione</code>	verificata (§3.2)
<code>donor_id</code>	ricostruito dalla firma AVQ, senza rilanciare la pipeline	verificato (§13.3)

`Albo Pretorio`, scartato come nome del viewer, resta riservato al corpus di comunicazioni istituzionali di SimComm/Caffaro, dove nomina l'oggetto giusto.

0.1 Il metodo, che si e' rivelato piu' importante del piano

Ogni errore scoperto in questo progetto e' venuto a galla nello stesso modo: **confrontando con una configurazione in cui la risposta e' nota**. E' la §11.1 del documento di riferimento, e vale come regola di ingegneria oltre che di statistica.

confronto	cosa ha rivelato
Q5 contro Q0	la potatura delle colonne esiste (fattore 47)
Q3 contro Q3N	la potatura per riga, a colonne pari
Q6 contro Q2	l'ordinamento per zona serve (22% invece di 100%)
MAE grezzo contro MAE normalizzato	il seam e' elevato, ma non dominante
distinti contro Kish	<code>n_eff</code> sbagliato di un fattore 2,8
ramo tier contro ramo comunale (§11.2 rif.)	due bug latenti, invisibili su un ramo solo

Corollario operativo: nessun numero entra nel design senza il suo confronto. Un valore assoluto senza termine di paragone non e' una misura, e' un'impressione.

Nota di onesta'. Delle previsioni quantitative fatte in questa sessione, circa meta' sono state falsificate dalla misura: il seam come sorgente d'errore dominante, il guadagno di `BYTE_STREAM_SPLIT`, Q5 a 2,1 MB, Kish a 3.000, la soglia d'allarme su `n_eff` basso. Questo documento va letto come una lista di ipotesi da falsificare, non come specifiche.

1. Scopo, utenti, non-obiettivi

Tre utenti, in ordine di priorita' temporale: tu adesso, i collaboratori (Tarantino, Pachet, Zucker, PRISM), il pubblico in seguito.

Non-obiettivi, da scrivere nella pagina Metodo:

- non e' uno strumento di stima locale: nessun numero e' una misura del quartiere reale;
- non genera popolazioni: consuma i `_full` gia' prodotti;
- non fa inferenza causale ne' previsione.

2. Il principio guida: livello di garanzia

Quattro classi, visibili sempre.

classe	badge	attributi	cosa garantisce
V — vincolato	pieno	anello 1	$MRE \approx 4 \cdot 10^{-4}$ sul constraint set
A — allocato	mezzo pieno	sezione , eta_anni , indirizzo, coordinate	MAE 0,74-1,58 per sezione, sotto le assunzioni (8)-(10)
C — condizionato	contorno	paese , area	margini censuari, geografia secondo il tier
D — donato	tratteggiato	le 21 AVQ	nessuna informazione geografica (assunzione 6)

Qualunque variazione spaziale di una variabile di classe D e' **interamente compositiva per costruzione**.

2.1 Numerosita' efficace — i numeri veri

Misurati (§13.3), non piu' stimati. n_{eff} di Kish, $n^2 / \Sigma m^2$:

	individui	firme distinte	n_{eff}	banda ×
Modena, comune	184.597	4.199	1.520	11,0
Bologna, comune	390.098	4.207	1.599	15,6

Tre fatti che cambiano il design:

(a) n_{eff} **non cresce con la popolazione**. Bologna ha il doppio degli abitanti di Modena e lo stesso n_{eff} : il tetto e' il pool regionale, non la citta'. La banda di confidenza su una media AVQ comunale e' **11-16 volte** piu' larga di quella ingenua.

(b) n_{eff} **satura anche filtrando**. A Modena passa da 1.520 sull'intera citta' a 1.514 sul quartiere piu' grande a 1.442 sul terzo. Filtrare riduce n e quasi mai i donatori, quindi **il rapporto n/n_{eff} e' massimo per la citta' intera** e cala stringendo. La correzione serve di piu' dove il numero sembra piu' autorevole, e quasi per niente sulle fette piccole.

(c) **Un solo n_{eff} per il blocco AVQ non esiste**. Le 21 variabili hanno universi che vanno dal 100% di SALUTE al 13,6% di BMIMIN. La firma piu' riusata (1511 individui a Modena, 2900 a Bologna) e' quasi certamente quella dei minori, per i quali BMI, le dodici PUNTIFI e VOTOUSL sono non applicabili: la 21-upla si riduce a quattro o cinque valori e donatori realmente diversi diventano indistinguibili. Quegli individui **non partecipano** al calcolo di PUNTIFI10, quindi penalizzarne la banda con la loro coda e' un errore di universo.

Regola: `n_eff` si calcola **per variabile, sui soli individui che quella variabile ce l'hanno**. Da verificare col blocco 5 di `verifica_donor.py` (§11, punto 2).

3. Modello dei dati

3.1 Un bundle, non l'albero di lavoro

Il viewer non legge mai `~/progetti/gsp/data/comuni/...`, legge un bundle versionato prodotto da uno script di export. E' cio' che rende l'app pubblicabile senza modifiche.

```
bundle/                                fuori dal repo git, ricostruibile
  manifest.json
  qualita.json
  comuni/036023/
    pop.parquet                        42 colonne, 10 row group, 3,12 MB
    rif_comune.parquet · rif_zona.parquet · rif_sezione.parquet
    sezioni.topojson · zone.topojson
  regioni/emilia_romagna.topojson
```

3.2 Disposizione fisica del file — e' una scelta di progetto

DuckDB-WASM legge **intervalli di byte contigui**, non colonne: chiedere tre colonne o cinque dello stesso blocco costa identico. I blocchi li definiamo noi. Cinque decisioni, tutte verificate:

(a) Colonne in tre blocchi per uso.

```
A  filtri e marginali  zona, quartiere, sesso, eta, stato_civile,
                               cittadinanza, istruzione, condizione, background,
                               origine_genitori, paese, area, eta_anni, quinq,
sezione
B  AVQ                  le 21 _num
C  pesanti (mappa)      id, indirizzo_fonte, via, civico, lon, lat
```

(b) **Righe per** `zona, sezione`: il filtro su una zona legge il **22%** di quanto legge la stessa query senza filtro. Le sezioni restano contigue dentro la zona, quindi il lazo continua a potare.

(c) **Row group da 20.000 righe** — dieci per Modena, footer 0,073 MB.

(d) **id in** `DELTA_BINARY_PACKED`: da 0,79 MB (la colonna piu' pesante del file) a meno di 0,09.

(e) **lon/lat in** `BYTE_STREAM_SPLIT`: 0,65 → 0,59 MB. Guadagno modesto perche' le coordinate sono al piu' 60.488 valori distinti e il dizionario ne stava gia' sfruttando la ripetizione. Si tiene, ma la motivazione originale era sbagliata.

Risultato su Modena: CSV 57,76 MB → Parquet **3,123 MB (5,4%)**.

blocco	peso	quota
A filtri e marginali	0,675 MB	21,6%
B AVQ	1,411 MB	45,2%
C pesanti	0,980 MB	31,4%
footer	0,073 MB	2,3%

3.3 Colonne aggiunte dall'export

colonna	stato
<code>(id)</code> int32	fatto, delta-encoded
<code>(quinq)</code> int8	fatto, candidato alla rimozione (§12)
<code>(donor_id)</code>	risolto: ricostruito dalla firma AVQ (§13.3)
<code>(donor_anno)</code> int16	desiderabile, non bloccante — ricostruirebbe il <i>planned missing</i>
<code>(cella_avq)</code>	desiderabile — stimabile in parte dal blocco 3 di <code>(verifica_donor.py)</code> , appena si leggono le definizioni vere di <code>(macroeta)</code> e <code>(istr4)</code>
<code>(lon_j)</code> , <code>(lat_j)</code>	da fare in <code>(build_bundle)</code>

`(donor_id)` **non richiede di rilanciare** `(assign_avq.py)`. L'hot-deck copia tutte e 21 le variabili in blocco dallo stesso donatore, quindi **la 21-upla di valori e' la firma del donatore**. Nel pool emiliano 418 donatori (il 9%) hanno 21-uple indistinguibili — differenza identica a Modena e Bologna, quindi proprieta' del pool e non della citta'. L'errore va nella **direzione prudente**: `(n_eff)` esce sottostimato, quindi le bande escono ~5% troppo larghe.

Le **AVQ grezze sono state eliminate** dal Parquet: `(non_applicabile)` contro mancante non serve riga per riga, perche' il *planned missing* dipende dall'annata del donatore. Blocco B da 2,659 a 1,411 MB.

3.4 Il riferimento — una serie, tre livelli, tre stati

Regola del livello: riferimento valutato al livello spaziale piu' fine compatibile col filtro — comune, zona, sezione — con ricaduta **dichiarata**.

Regola dello stato:

stato	significato	come si legge lo scarto
verifica	il valore reale a quel livello e' entrato nella pipeline	uno scarto e' un bug, non un risultato
validazione esterna	esiste e non e' stato usato	informativo, linea di base 1-2% (anagrafe contro censimento)
assente	nessun dato osservato	dichiarato, ricaduta al livello superiore

Lo stato si **deriva** da `constraints_2024/manifest.json` e dalle colonne che `enrich.py` usa come pesi. Non si mantiene a mano.

Dove la validazione esterna c'e': solo nelle fonti comunali anagrafiche di zona, mai usate come *livelli*. Modena 0,982-1,007 sulla popolazione per quartiere; Primo Maggio 0,329 contro 0,293.

Dove non c'e': a livello di sezione tutto l'osservato e' usato. `P30-P45`/`P67-P82` sono il **peso** stesso dell'allocazione. Non esiste alcun test out-of-sample dell'assunzione (8).

Sorgenti non spaziali: censimento comunale per l'anello 1, `paese`, `area`; ISTAT eta' singola per `eta_anni`; **AVQ regionale pesata** per le 21 di classe D. Per queste ultime la marginale sintetica comunale e la stima regionale differiscono esattamente per composizione: la riga di scomposizione lo spiega per intero, su ogni pannello.

4. Le viste

Cinque pagine: **Citta', Esplora, Individuo, Confronta, Metodo**.

4.1 Esplora — i filtri

Dodici filtri in v1: `zona`, `sezione` (solo via lazo), `sezzo`, `eta`, `stato_civile`, `cittadinanza`, `istruzione`, `condizione`, `background`, `origine_genitori`, `paese`, `area`, `eta_anni`.

Le AVQ non sono filtri in v1, sono variabili mostrate.

Barra di stato: `n` · % della citta' · sezioni toccate · livello del riferimento attivo · `n/n_eff` e il **fattore di banda per la variabile AVQ mostrata**.

Correzione rispetto alla v0.4. Avevo previsto un badge rosso su `n_eff < 30`. E' la regola sbagliata: `n_eff` satura e non scende quasi mai, mentre il rapporto `n/n_eff` esplode proprio sulle sottopopolazioni grandi (Bologna comune: 244). **Il badge va acceso su `n/n_eff` alto, non su `n_eff` basso.** Resta utile una soglia su `n` piccolo, ma per la ragione diversa del rumore campionario.

4.2 Marginali

Una serie sintetica, fino a due marcatori: **rombo pieno** per il censimento (stato *verifica*, scarto atteso zero, ogni deviazione e' un guasto), **rombo vuoto** per la fonte comunale (stato *validazione esterna*, scarto atteso 1-2%, cio' che eccede e' segnale).

Senza filtro spaziale il riferimento comunale e' anche **il valore atteso sotto indipendenza**, quindi lo scarto e l'associazione. Con filtro spaziale diventa un confronto quartiere per quartiere.

Modalita' Δ con banda $\sqrt{(p(1-p)/n)}$, e per la classe D con n_{eff} **della variabile mostrata** (§2.1c).

Riga di scomposizione (classi C e D):

```
AMBIENTE, Fiumicello vs riferimento:   $\Delta = -0,07$   
    spiegato dalla composizione:  -0,07  (100%)  
    residuo areale:                0,00
```

Pannello fiducia istituzionale: dodici medie su asse 0-10, riferimenti nazionali AVQ 2024 come tacche fisse (vigili del fuoco 8,10 · forze dell'ordine 6,70 · ASL 6,34 · Comune 5,13 · Regione 4,65), fasce di copertura come tratteggio, matrice di correlazione con min_periods sotto.

4.3 Mappa

Individui (punti con jitter), **Sezioni** (default analitico), **Zone**, **Esagoni H3**.

La metrica di default non e' il conteggio: in ordine **quota**, **lift**, **z**, conteggio. Shrinkage empirico-bayesiano, o almeno sbiadimento sotto ~30 individui filtrati.

Affiancamento sintetico/reale: sulle sezioni e' **verifica**; sulle zone contro fonte comunale e' validazione vera.

Da gestire: convivenze al centroide di zona escluse dai punti per default; $\text{indirizzo_fonte} = \text{"zona"}$ idem; jitter radiale deterministico ~8 m; tiles Protomaps self-hosted, nessuna chiave API.

4.4 Individuo

Quaranta campi per anello col badge di garanzia, catena di provenienza inclusa la colonna P che ha determinato la sezione, e **la firma AVQ con quanti altri individui la condividono** — che rende visibile in un caso concreto cio' che §2.1 dice in aggregato. E' gia' il prompt della persona per il tier 2.

4.5 Confronta

A — comune (sicuro). **B — distribuzione fra sezioni** (il livello giusto: unita' ISTAT omogenee, mentre 4 quartieri di Modena e 33 di Brescia non sono confrontabili), con la decomposizione della varianza $5,9 \times \rightarrow 43,5 \times$ in forma grafica. **C — zone**, con avviso.

Avviso obbligatorio sulle AVQ: Parma, Bologna e Modena condividono lo stesso pool di 4.629 donatori, quindi ogni differenza AVQ fra le tre e' integralmente compositiva. Brescia attinge a un pool diverso, e un confronto Brescia-Bologna mescola composizione e differenza di pool.

4.6 Metodo e qualita'

MRE per comune · MAE per sezione come scatter · copertura AVQ nelle tre fasce · **riuso dei donatori e n_{eff} per variabile** · le sette assunzioni in elenco cliccabile che illumina gli attributi dipendenti · tier del paese coi numeri di §6 · provenienza dei nomi di zona e l'incidente di Bologna · i diagnostici di §13.1.

5. Interazione e stato

Crossfilter completo, stato interamente nell'URL:

```
/esplora/017029?zona=17029012&sezzo=F&istruzione=laurea_o_its  
&mostra=AMBIENTE,PUNTIFI10&mappa=sezioni&metrica=lift
```

Esportazioni con provenienza incorporata.

6. Grafica

Estetica dell'anagrafe: serif per titoli e numeri grandi, sans neutro per l'interfaccia, monospaziato con cifre tabulari per tutte le cifre. Un accento per il sintetico; riferimenti in neutro scuro distinti per **forma** (rombo pieno o vuoto), cosi' la distinzione verifica/validazione sopravvive alla stampa in bianco e nero. Densita' alta, small multiples. Base chiara per le coropleti, scura per i punti.

7. Architettura

7.1 Gli strumenti

strato	strumento	stato
bundle	Python: pandas, geopandas, duckdb, pyarrow, mapshaper	<code>to_parquet.py</code> fatto
impalcatura	Observable Framework	da avviare
query	DuckDB-WASM 1.29	verificato
grafici	Observable Plot	
mappa	MapLibre GL + deck.gl	
hosting	nessuno; <code>serve_range.py</code> in locale	

7.2 Il modello di costo

$$\text{costo(query)} = \text{footer} + \sum \text{peso}(\text{blocco toccato}) \times (\text{row group non potati} / \text{totale})$$

Footer 0,073 · A 0,675 · B 1,411 · C 0,980. Sette misure su otto entro il 20% (§13.2).

Tre corollari verificati:

1. **Il numero di colonne richieste e' irrilevante.** Tre colonne o cinque dello stesso blocco costano identico (0,792 MB). L'unita' e' il blocco.
2. **Potatura per riga pulita:** un row group su dieci costa il 10,7%.
3. **Potatura spaziale**, ma solo grazie all'ordinamento per `zona`: 22%.

Conseguenza: il vincolo previsto in v0.3 — «serve `agg_sezioni.parquet` per la prima schermata» — **e' sparito**. La prima schermata costa 0,79 MB.

7.3 Cosa costa zero adesso e molto dopo

1. interruttore `--pubblico` in `build_bundle.py` (toglie `via` e `civico`, aggancia i punti al centroide dell'edificio);
2. etichettatura: banner «individuo sintetico», watermark negli export, campo di provenienza in ogni CSV;
3. nessuna dipendenza da servizi con chiave API.

Ogni individuo sta a un civico ANNCSU esistente, e su Brescia il contesto Caffaro rende la prima cosa meno teorica che altrove.

8. Estensibilita'

Tutto cio' che varia sta in `manifest.json`, generato da `G.COMUNI`.

```
to_parquet.py {CODICE} → build_bundle.py {CODICE} → verifica_bundle.py {CODICE}
```

Controlli obbligatori: totali coincidenti col censimento; `[nomi_verificati: [metodo_a, metodo_b]]` **obbligatorio**; poligoni pari alle zone attese; nessun individuo fuori dal poligono comunale; copertura AVQ nelle fasce; stato di ogni riferimento derivato e non scritto a mano.

Emilia-Romagna: i prerequisiti regionali sono pagati, ogni capoluogo costa la mezz'ora di §12 del riferimento. Dieci comuni ≈ 1,8 milioni di individui e ~**30 MB di bundle**.

9. Prestazioni — misurate

Modena, 184.597 individui, Parquet 3,123 MB, server locale.

operazione	misurato
init DuckDB-WASM (a caldo)	0,69-0,77 s
footer, una volta per sessione	0,073 MB
esplorazione demografica, prima query	0,79 MB · ~1,3 s
ogni filtro successivo sullo stesso blocco	0 byte · 100-220 ms
filtro su una zona	0,23 MB · ~0,6 s
pannello fiducia istituzionale	0,82 MB
mappa a punti	0,92 MB
sessione piena	~2,5 MB

Il vincolo non e' piu' la banda ma il tempo di inizializzazione, fisso e indipendente dai dati.

10. Fasi

F0 — i due diagnostici. ✓ Modena e Parma (§13.1). Restano Bologna e Brescia.

F1 — smoke test dello stack. ✓ Tutte e tre le domande risolte (§13.2).

F2 — `donor_id`. ✓ Risolto senza toccare la pipeline (§13.3).

F3 — bundle minimo + primo pannello. ← invertito rispetto alla v0.4.

Invece di scrivere `build_bundle.py` completo — manifest, tre tavole di riferimento, geometrie, tre stati — costruire il **bundle minimo che serve a un pannello solo**: il Parquet che già esiste, più un manifest ridotto a etichette e ordini delle modalità. Poi fare il pannello dei marginali su Modena.

Ragione: abbiamo quattro versioni di design, un modello di costo, quattro script diagnostici e **zero grafici**. L'apparato epistemico è cresciuto più della cosa che deve annotare. Sarà il pannello a dire cosa serve davvero nel manifest, invece di indovinarlo adesso. Il rischio dell'ordine precedente era scrivere lo schema alla cieca e riscriverlo tre volte; il rischio di questo è rifare un po' di lavoro sul bundle, che costa molto meno.

F4 — bundle completo: riferimenti coi tre stati, geometrie, aggregati.

F5 — mappa.

F6 — le altre città e il manifest. L'estensibilità va provata aggiungendo il quarto comune senza toccare l'interfaccia.

F7 — Individuo, Metodo, Confronta, e la grafica in senso proprio.

11. Questioni aperte

1. **Definizioni vere di** `macroeta` e `istr4` in `assign_avq.py`. Senza, il blocco 3 di `verifica_donor.py` è illeggibile — le mappature usate sono mie invenzioni — e `cella_avq` non è stimabile. **Blocca l'unica cosa che resta da capire sulle AVQ.**
 2. **Blocchi 5 e 6 di** `verifica_donor.py`: `n_eff` per universo di variabile, e identità della firma più riusata. Danno i numeri veri per §2.1.
 3. **AVQ filtrabili**: solo mostrate in v1, o filtrabili dietro interruttore?
 4. **Fonti comunali di zona**: quali disponibili come *livelli*? Determina quanta validazione esterna l'app può offrire.
 5. **Emilia-Romagna**: quanti capoluoghi, e la vista regionale entra in v1?
 6. **Modena e i 37 rioni**: se entrassero in pipeline, la vista Zone di Modena passerebbe da inutile a interessante.
 7. **Le due riparazioni di §13.1** — permutazione di `istruzione` entro (zona, sesso, bin), ed esclusioni $\alpha=0$ sulle coppie impossibili — vanno fatte e in che ordine rispetto al viewer?
 8. **Campionamento degli agenti per firma** invece che per individuo (§14).
-

12. Registro dei miglioramenti

Fatti, con effetto misurato

	effetto
colonne in tre blocchi per uso	Q5 da 2,297 a 0,915 MB
righe per (zona, sezione)	filtro di zona al 22% invece del 100%
(id) DELTA_BINARY_PACKED	0,79 MB → <0,09 MB
(lon)/(lat) BYTE_STREAM_SPLIT	0,65 → 0,59 MB (motivazione originale sbagliata)
AVQ grezze eliminate	blocco B 2,659 → 1,411 MB
row group 50k → 20k	potatura piu' fine, footer 0,049 → 0,073 MB
(donor_id) dalla firma	sblocca (n_eff) senza rilanciare la pipeline
(n_eff) di Kish invece dei distinti	il numero cambia di un fattore 2,8
file 5,22 → 3,12 MB	

Proposti

- **rimuovere** (quinq) (0,089 MB, il 13% del blocco caldo): e' (least(eta_anni // 5, 15)) in SQL;
- **rimuovere** (quartiere): e' l'etichetta di (zona), sta nel manifest. Con (quinq), porta A da 0,675 a ~0,55 MB;
- (donor_anno) per ricostruire la distinzione fra (non_applicabile) e *planned missing*;
- **sostituire la riga «aggregazione tipica»** in (to_parquet.py): suggerisce che il costo sia la somma delle colonne richieste, mentre e' il blocco.

Scartati, col motivo — per non ripensarci

- **spezzare il blocco AVQ** in fiducia e sanita'. Q4 ha la sovralettura peggiore, ma **non e' una query realistica**: il pannello fiducia mostra tutte e dodici le (PUNTIFI) insieme e leggerebbe il sotto-blocco comunque;
- **AVQ in int8 con sentinelle**: ogni (PUNTIFI) pesa gia' mezzo byte a riga, il dizionario e' a 4 bit, praticamente all'ottimo teorico;
- (agg_sezioni.parquet) **come requisito strutturale**: mascherava un costo d'ingresso che non esiste. Resta come comodita';
- **coordinate in float64**: float32 da ~0,4 m basta per la resa cartografica;
- **rilanciare** (assign_avq.py) per (donor_id): la firma lo ricostruisce.

13. Diario delle misure

13.1 F0 — i due diagnostici (Modena e Parma)

(a) **Il seam quinquennale.** MAE grezzo indistinguibile dalle altre classi; normalizzando per dimensione di classe le due classi del seam finiscono **nei primi tre posti su sedici in entrambe le città** (per caso $\sim 6 \cdot 10^{-4}$). Ma l'eccesso e' del 40%: **l'ipotesi di uniformita' non e' una sorgente d'errore dominante.**

Risultato sistematico non previsto: dentro ciascuno dei cinque bin veri il sintetico pende verso il **giovane**, prima classe in positivo e ultima in negativo, **dieci prove su dieci**, 0,10-0,44 pp.

	Modena	Parma
15-24	+0,158 / -0,158	+0,186 / -0,186
25-34	+0,110 / -0,110	+0,278 / -0,278
35-49	+0,351 / -0,438	+0,234 / -0,260
50-64	+0,101 / -0,097	+0,201 / -0,131
65-74	+0,199 / -0,199	+0,209 / -0,209

Nella regione infantile il verso **si inverte**: **10-14** sovrarappresentata di +0,37 e +0,35. E' l'unico posto dove opera la frazione $4/5-1/5$, e ha una direzione precisa — **il sintetico mette troppo pochi novenni**. Indiziato per il resto: l'assunzione (9).

Terzo fatto: i totali di bin SDMX non coincidono con gli stessi bin aggregati dalle colonne P — fino a +1,42% (Parma **15-24**) e -1,02% (Modena **75+**). **Non replica in segno**, quindi rumore fra due prodotti censuari, non calendario. Il controllo «totale SDMX = **P1**» e' esatto e non puo' vederlo.

(b) **Coerenza eta'-istruzione:** 4.867 violazioni a Modena (2,64%), 5.434 a Parma (2,74%), concentrate nei bin **9-14** e **15-24**, zero altrove. *Riparazione:* permutare **istruzione** entro (zona, sesso, bin).

(c) **Due record impossibili gia' al livello del bin**, entrambi a Parma, zero a Modena: **diploma** a 2 anni e **post_laurea** a 13. Sono 10^{-5} , massa residua del fit. *Riparazione:* otto coppie **(bin, istruzione)** fra le esclusioni $\alpha=0$.

Previsione da raccogliere: se e' massa residua, il numero scala col supporto (Modena $645.120 \rightarrow 0$; Parma $2.096.640 \rightarrow 2$; Bologna $2.903.040 \rightarrow ?$; Brescia $5.322.240 \rightarrow ?$).

13.2 F1 — smoke test DuckDB-WASM (Modena, file riordinato)

	misurato	modello	scarto
Q0 <code>count(*)</code>	0,073	0,073	esatto
Q1 3 colonne di A	0,792	0,748	+6%
Q2 5 colonne di A	0,792	0,748	+6%
Q3 A+id, 1 rg su 10	0,167	0,141	+18%
Q3N A+id, tutti	0,948	0,748	+27%
Q4 zona + <code>PUNTIFI10_num</code>	0,823	0,600	+37%
Q5 <code>lon</code> , <code>lat</code>	0,915	1,053	-13%
Q6 filtro su una zona	0,230	0,208	+11%

$Q3/Q3N = 10,7\% \cdot Q6/Q2 = 21,8\%$. Tempi a caldo 100–220 ms.

Errore di metodo commesso e corretto: la prima misura di Q3 era contaminata, perche' le query di una sessione si scaldano a vicenda — Q1 aveva gia' letto il blocco A, quindi Q2 e' costata **zero byte**. Da qui la modalita' isolata e la query di controllo a colonne pari. La contaminazione, letta come fenomeno invece che come errore, e' cio' che ha rivelato la struttura a blocchi.

13.3 F2 — `donor_id` dalla firma AVQ

Firme distinte: Modena 4.199 contro 4.617 donatori dichiarati, Bologna 4.207 contro 4.625.

Differenza identica, -418: proprieta' del pool emiliano, non delle citta'. Verificabile contando le 21-uple distinte nel pool AVQ, che dovrebbe dare ~4.211.

Coerenza interna: $4.617/4.199 = 1,0995$ e $riuso\ 44,0/40,0 = 1,100$.

`n_eff` di Kish ($(n^2/\Sigma m^2)$), contro il conteggio dei distinti:

	individui	distinti	Kish	banda ×
Modena, comune	184.597	4.199	1.520	11,0
Bologna, comune	390.098	4.207	1.599	15,6

Il conteggio dei distinti sbagliava di un fattore 2,8. La ragione: Kish e' una statistica di secondo momento e vive nella coda che i quantili non vedono. La firma piu' riusata — 1511

individui a Modena, 2900 a Bologna — vale da sola **circa il 10% del peso statistico dell'intera città**'.

Limite noto: quella firma e' quasi certamente quella dei minori, per i quali la 21-upla si riduce a quattro o cinque valori. I numeri $\times 11,0$ e $\times 15,6$ sono quindi calcolati sull'universo sbagliato: vanno rifatti per variabile (§11, punto 2) prima di entrare in §2.1 come definitivi.

14. Cosa significa per SimComm

Il risultato di §13.3 pesa piu' sul tier 2 che su Animarium, e vale la pena annotarlo qui perche' e' emerso da qui.

La diversita' psicologica effettiva di una popolazione di agenti non e' quella dei suoi individui: e' quella di ~1.500 donatori, e non cresce prendendo una città piu' grande. Per una campagna da 120 agenti probabilmente non morde. Ma qualunque affermazione sulla *distribuzione* — «in questa popolazione sintetica il 23% diffida del Comune» — ha errore standard fissato da 1.500, non da 184.597.

Il secondo ordine e' piu' insidioso. Due agenti che condividono la firma hanno profili psicologici **identici**, non simili: stessa fiducia istituzionale, stessa percezione ambientale, stessa salute percepita. In una simulazione LLM le loro risposte sono correlate per costruzione e non sono evidenza indipendente. Con riusi medi di 40–93, in un campione casuale di 120 agenti da Bologna la probabilita' di collisioni non e' trascurabile.

Domanda di disegno sperimentale, non di implementazione: conviene campionare gli agenti per firma invece che per individuo? Garantirebbe profili distinti al prezzo di distorcere le quote demografiche — che sono esattamente cio' che il tier 1 esiste per garantire. Il compromesso fra rappresentativita' demografica e indipendenza psicologica va deciso, e dichiarato nel paper.

Se non altro, va misurato: in una campagna gia' eseguita, quante coppie di agenti condividevano la firma?