

Animarium — documento di design

Synthetic populations of Italian cities v0.6 — 30 luglio 2026 Riferimento dati:

`GSP_popolazioni_full_riferimento_v16.md` (§ citati sotto).

Rispetto alla v0.5: il pannello esiste. §3.4 riscritta — il riferimento censuario si estrae da `cs_K9C.json`, non da fonti esterne. §4.2 corretta: i marcatori sono tre e la tacca NON si sposta. §4.3 riscritta sulla mappa effettivamente costruita. Ritirato un risultato di §13.1 che era rumore. Nuova §13.4 con l'anatomia del constraint set e i test sul pool.

0. Decisioni prese

	scelta	stato
nome	Animarium — Synthetic populations of Italian cities	fissato
stack	pagina statica + DuckDB-WASM, senza scaffold	verificato (§7.2)
destinazione	solo interna per ora	<code>--pubblico</code> predisposto
riferimento	censimento estratto da <code>cs_K9C.json</code>	fatto (§3.4)
disposizione del file	tre blocchi di colonne, righe per <code>zona</code> , <code>sezione</code>	verificata (§3.2)
<code>donor_id</code>	ricostruito dalla firma AVQ	verificato, non ancora nel Parquet
mappa	griglia da <code>lon</code> / <code>lat</code> , nessuna geometria	fatta (§4.3)

0.1 Il metodo

Ogni errore di questo progetto e' emerso **confrontando con una configurazione a risposta nota** — la §11.1 del riferimento, che si e' rivelata una regola di ingegneria oltre che di statistica.

confronto	esito
Q5 contro Q0	la potatura delle colonne esiste (fattore 47)
Q3 contro Q3N	potatura per riga, a colonne pari: 10,7%
Q6 contro Q2	l'ordinamento per zona serve: 22% invece di 100%
MAE grezzo contro normalizzato	il seam e' elevato, non dominante
distinti contro Kish	<code>n_eff</code> sbagliato di un fattore 2,8
errore relativo contro z-score	il MRE per cella era tutto pavimento di rumore
target del blocco A contro quello del blocco B	ipotesi di incoerenza cross-blocco falsificata

Corollario: nessun numero entra nel design senza il suo confronto.

Bilancio delle previsioni. Circa meta' delle previsioni quantitative fatte finora sono state falsificate dalla misura. Due ritrattazioni sono registrate qui: la discrepanza «fra prodotti censuari» di §13.1, che era rumore di campionamento ($z = 0,24$), e l'incoerenza cross-blocco, che non esiste. Questo documento va letto come una lista di ipotesi da falsificare.

1. Scopo, utenti, non-obiettivi

Tre utenti in ordine temporale: **tu adesso**, i **collaboratori** (Tarantino, Pachet, Zucker, PRISM), il **pubblico** in seguito.

Non-obiettivi, da scrivere nella pagina Metodo:

- non e' uno strumento di stima locale: nessun numero e' una misura del quartiere reale;
- non genera popolazioni: consuma i `_full` gia' prodotti;
- non fa inferenza causale ne' previsione.

2. Livello di garanzia

classe	segno	attributi	cosa garantisce
V — vincolato	■	anello 1	riprodotto entro il rumore di campionamento
A — allocato	▣	sezione, eta_anni, indirizzo, coordinate	esatto per sezione, sotto le assunzioni (8)-(10)
C — condizionato	□	paese, area	margini censuari, geografia secondo il tier
D — donato	▤	le 21 AVQ	nessuna informazione geografica (assunzione 6)

I quattro segni compaiono nella scheda individuo (§4.4), che e' il posto dove la classificazione smette di essere un badge astratto.

2.1 Numerosita' efficace

n_{eff} di Kish, $n^2/\Sigma m^2$, misurato in §13.3:

	individui	firme distinte	n_{eff}	banda ×
Modena	184.597	4.199	1.520	11,0
Bologna	390.098	4.207	1.599	15,6

n_{eff} non cresce con la popolazione — il tetto e' il pool regionale — e satura anche filtrando, quindi n/n_{eff} e' massimo per la citta' intera. La correzione serve di piu' dove il numero sembra piu' autorevole.

Regola (correzione della v0.4): il badge di allarme va acceso su n/n_{eff} alto, non su n_{eff} basso.

Un solo n_{eff} per il blocco AVQ non esiste: le 21 variabili hanno universi dal 100% al 13,6%, e la firma piu' riusata (1511 individui) e' quella dei minori, per cui la 21-upla si riduce a quattro valori. n_{eff} va calcolato per variabile, sul suo universo.

Stato: nessuna AVQ e' ancora mostrata nel pannello, quindi la regola non e' implementata. Diventa vincolante appena si aggiunge il pannello fiducia.

3. Modello dei dati

3.1 Il bundle

bundle/	
comuni.json	indice per il menu delle citta'
comuni/036023/	
pop.parquet	42 colonne, 10 row group, 3,12 MB
manifest.json	etichette, ordini, conteggi non filtrati
referimenti.json	conteggi censuari da cs_K9C.json

Fuori dal repo git, ricostruibile in quattro comandi. Quattro citta': **16,2 MB**.

3.2 Disposizione fisica del file

DuckDB-WASM legge **intervalli di byte contigui, non colonne**: chiedere tre colonne o cinque dello stesso blocco costa identico. I blocchi li definiamo noi.

A	filtri e marginali	zona, quartiere, sesso, eta, stato_civile, cittadinanza,
		istruzione, condizione, background, origine_genitori, paese, area, eta_anni, quinq, sezione
B	AVQ	le 21 _num
C	pesanti (mappa)	id, indirizzo_fonte, via, civico, lon, lat

Righe per (zona, sezione) (il filtro di zona legge il 22%); row group da 20.000; (id) in (DELTA_BINARY_PACKED) (0,79 → <0,09 MB); (lon)/(lat) in (BYTE_STREAM_SPLIT); AVQ grezze eliminate.

Modena: CSV 57,76 MB → Parquet **3,123 MB (5,4%)**. Blocchi: A 0,675 · B 1,411 · C 0,980 · footer 0,073. **Scala linearmente:** Bologna ha 2,11 volte le righe e il blocco A pesa 2,10 volte.

3.3 Colonne aggiunte

colonna	stato
<code>id</code> int32	fatto, delta-encoded, e serve al clic sulla mappa
<code>quinq</code> int8	fatto, candidato alla rimozione (§12)
<code>donor_id</code>	ricostruibile dalla firma AVQ, da aggiungere all'export
<code>donor_anno</code> , <code>cella_avq</code> , <code>macroeta</code> , <code>istr4</code>	desiderabili, non bloccanti
<code>lon_j</code> , <code>lat_j</code>	non servono : il jitter e' deterministico a runtime

3.4 Il riferimento censuario — dal constraint set

L'idea che ha semplificato F4: non servono tavole di zona da fonti esterne, perche' sono gia' in `cs_K9C.json`. Ogni `alpha × N` e' un conteggio censuario.

Regola: dato un filtro F e un attributo mostrato A, il riferimento esiste se e solo se **un blocco completo contiene $F \cup \{A\}$** . Si marginalizza il blocco sulle celle compatibili con F e si raggruppa per A. Fra i candidati si sceglie il piu' piccolo.

Copertura misurata: 67 coppie su 333, il 20%, e — fatto non ovvio — **identica in tutte e quattro le citta'**. E' una proprieta' del template di `build_constraints.py`, non del comune, quindi il pannello si comporta allo stesso modo dappertutto.

filtro	riferimento disponibile per
nessuno	tutti e nove gli attributi
<code>zona</code>	<code>sezzo</code> , <code>eta</code> , <code>istruzione</code> , <code>background</code> , <code>cittadinanza</code>
<code>zona</code>	non per <code>stato_civile</code> , <code>condizione</code> , <code>origine_genitori</code>
<code>sezzo × eta</code>	<code>stato_civile</code> , <code>cittadinanza</code>
qualunque	mai <code>paese</code> , <code>area</code> : non stanno nel constraint set

Blocchi parziali. `eta × istruzione` ha una cella sola, `zona × sesso × eta × condizione` solo gli occupati 15-64. Le celle non elencate **non sono vietate, sono libere**: un riferimento parziale non si normalizza come una distribuzione e non viene mostrato.

Le fonti comunali anagrafiche restano l'unica *validazione esterna* — mai usate come livelli — e non sono ancora nel bundle. Modena 0,982-1,007 sulla popolazione per quartiere; Primo Maggio 0,329 contro 0,293.

4. Le viste

4.1 Esplora — i filtri

Non c'e' una colonna di controlli: si filtra cliccando le barre. I filtri attivi sono pillole rimovibili. E' venuto piu' corto di una sidebar, non piu' lungo.

Ogni pannello applica tutti i filtri tranne il proprio — correzione emersa usandolo: senza, cliccando «Femmine» il pannello Sesso mostrava 100% Femmine. Conseguenza da spiegare: filtrando un quartiere, il pannello Quartiere torna a mostrare tutta la citta'.

Undici attributi. paese troncato alle prime 15 modalita' su 100-151; tutti gli altri interi, **inclusi i 33 quartieri di Brescia** — il troncamento a soglia globale li tagliava, ed era un difetto.

Ordine delle modalita' stabile fra citta': dichiarato dove esiste una progressione naturale (corso di vita per lo stato civile, rapporto col mercato del lavoro per la condizione, gradiente migratorio per il background), alfabetico altrove. L'ordine per frequenza rendeva i pannelli di due citta' non affiancabili.

Barra di stato: sintetici · censuari con lo scarto · % della citta'.

4.2 Marginali — tre marcatori

	cos'e'	come si legge lo scarto
barra	la sottopopolazione filtrata	—
tacca (linea con testa)	la citta' intera	associazione: e' il valore atteso sotto indipendenza fra attributo e filtro
rombo	il censimento al livello del filtro	errore del modello: per gli incroci vincolati ci si aspetta rumore

Correzione della v0.5. Il design diceva che il riferimento «si sposta al livello della zona» sotto filtro spaziale. E' sbagliato: i marginali di zona dell'anello 1 stanno nel constraint set, quindi il rombo si incollerebbe alla barra e non si vedrebbe mai niente muoversi. La tacca **non si sposta**; il rombo si **aggiunge**. Sono due letture diverse e servono entrambe.

Dove il rombo non c'e', il pannello sbiadisce il titolo e dichiara «nessun dato censuario per questo incrocio». Non e' una mancanza: e' la distinzione fra osservato e modello, resa visibile filtro per filtro.

Ogni pannello riporta **lo scarto massimo fra sintetico e censimento** sulla distribuzione mostrata: e' lo stato *verifica* con un numero, calcolato dal vivo.

Modalita' Δ con banda $\sqrt{p(1-p)/n}$ al 95%. Per le AVQ dovra' usare n_{eff} della variabile (§2.1), quando ci saranno.

Export: CSV e LaTeX (`booktabs`), con filtro e n in commento) di tutte e tre le serie; SVG per pannello, costruito a mano senza librerie, nell'estetica di §6.

4.3 Mappa — come e' fatta davvero

Nessuna geometria. La griglia si calcola aggregando lon/lat al volo: niente TopoJSON, niente shapefile, niente da preparare. Era la parte che sembrava piu' costosa di F5 ed e' sparita.

Proiezione Web Mercator, necessaria per allineare le tiles.

Due modi.

Quota — frazione del filtro sul totale locale, su celle di ~150 m regolabili su tre livelli. Celle sotto 25 abitanti in grigio: su venti persone una quota e' rumore. E' l'unico modo informativo.

Punti — individui campionati (tetto 10k-120k), con jitter **deterministico dall'** id di ± 7 m, sopra uno strato grigio di 40.000 punti della citta' intera. Lo strato di base distingue «qui non ce n'e' del filtro» da «qui non abita nessuno». Il jitter deve essere deterministico o il clic non puo' colpire quello che si vede.

Modo densita' rimosso. Contava gli individui per cella, quindi riproduceva la densita' di popolazione: qualunque filtro illuminava il centro. Rimosso invece che etichettato.

Navigazione: rotella per lo zoom sul cursore, trascinamento, $adatta$. Il clic apre la scheda solo se il puntatore si e' mosso meno di 4 px.

Base cartografica opzionale — CARTO chiaro (default), OpenStreetMap, nessuna. Con un velo chiaro al 42% sopra, altrimenti i dati si perdono nel disegno stradale.

Debito verso §7.3. OSM e CARTO non chiedono chiavi API ma sono servizi esterni: violano la condizione che tiene il progetto pubblicabile senza dipendenze. Per l'uso interno vanno bene. Per la rete la strada e' un estratto $.pmtiles$ di Protomaps servito da noi (§12). L'opzione «nessuna» resta in elenco perche' si veda sempre che i dati stanno in piedi da soli.

Costo: la mappa legge il blocco C, ~1 MB, e viene attivata solo su richiesta. Chi guarda i marginali non lo paga mai.

4.4 Scheda individuo

Si apre cliccando un punto. Quaranta campi per anello, **ciascuno col proprio segno di garanzia**, e le AVQ con il conteggio di quante sono presenti sulle 21 — che su un minore crolla a quattro o cinque, ed e' la spiegazione visiva del collasso delle firme in §13.3.

Costo: `(id)` e' ordinato e delta-encoded, quindi `(WHERE id = N)` pota fino a un row group. ~0,15 MB la prima volta, zero dopo.

In fondo, **il rendering testuale della persona** — «Come la vedrebbe un agente del tier 2: donna di 43 anni, coniugata, diploma, occupata; abita in via...; valuta 5 su 10 la fiducia nel Comune». Non e' decorativo: e' il materiale da cui SimComm costruisce il prompt, e affiancato ai segni di garanzia rende visibile quanta parte di quella persona e' dato.

Banner fisso e non chiudibile: **INDIVIDUO SINTETICO — NON ESISTE**. Quell' individuo sta a un civico ANNCSU vero (§7.3).

4.5 Confronta — da fare

A — comune (sicuro). **B — distribuzione fra sezioni** (il livello giusto), con la decomposizione della varianza $5,9 \times \rightarrow 43,5 \times$. **C — zone**, con avviso.

Avviso obbligatorio sulle AVQ: Parma, Bologna e Modena condividono lo stesso pool di 4.629 donatori, quindi ogni differenza AVQ fra le tre e' integralmente compositiva.

4.6 Metodo e qualita' — da fare

MRE e z-score per blocco (§13.4) · copertura AVQ · riuso dei donatori e `(n_eff)` per variabile · le sette assunzioni cliccabili · tier del paese · l'incidente dei nomi di zona di Bologna · i diagnostici di §13.1 · **la tabella di copertura di §3.4**, che rende quantitativo il livello di garanzia.

5. Interazione e stato

Crossfilter completo; stato interamente nell'URL, mappa e modo inclusi:

`?comune=017029&zona=17029012&istruzione=laurea_o_its&mappa=1&modo=punti`

6. Grafica

Estetica dell'anagrafe. Serif per titoli, monospaziato con cifre tabulari per tutte le cifre, un solo accento per il sintetico. I riferimenti in neutro scuro distinti per **forma** — tacca con testa triangolare contro rombo — cosi' la distinzione sopravvive alla stampa in bianco e nero di una figura.

7. Architettura

7.1 Strumenti

Nessuno scaffold. Pagina singola servita da `serve_range.py`, DuckDB-WASM da CDN, nessuna libreria di grafici: le barre sono HTML/CSS, l'SVG d'export e' a mano, la mappa e' canvas. **Observable Framework** resta **rimandato** per lo stesso motivo per cui era rimandato il bundle completo: e' infrastruttura, e conviene conoscerne la forma dopo.

7.2 Il modello di costo

$$\text{costo(query)} = \text{footer} + \sum \text{peso(blocco)} \times (\text{row group non potati} / \text{totale})$$

Tre corollari verificati: il numero di colonne richieste e' irrilevante (l'unita' e' il blocco); la potatura per riga costa il 10,7%; la potatura spaziale il 22%, ma solo grazie all'ordinamento per `zona`.

Prestazioni misurate: init 0,7 s · prima query 0,79 MB e ~1,3 s · **filtri successivi 0 byte e 100-220 ms** · sessione piena ~2,5 MB.

7.3 Cosa costa zero adesso e molto dopo

1. interruttore `--pubblico` in `build_bundle.py`;
2. etichettatura: banner, watermark, provenienza nei CSV — **fatto** per la scheda individuo;
3. **nessuna dipendenza da servizi esterni** — oggi violato dalla base cartografica, con la via d'uscita nota (`.pmtiles`, §12).

8. Estensibilita'

Aggiungere una citta':

```
to_parquet.py {C} --drop-avq-raw → manifest_min.py {C}
                                   → build_riferimenti.py {C} → build_indice.py
```

Provato: le quattro citta' girano con lo stesso codice, e la tabella di copertura esce identica. L'interfaccia non e' mai stata toccata per aggiungere un comune — che era la prova richiesta.

Dieci capoluoghi emiliani ≈ 1,8 milioni di individui e ~**30 MB di bundle**.

9. Prestazioni — misurate

operazione	misurato
init DuckDB-WASM	0,69-0,77 s
prima query, marginali	0,79 MB · ~1,3 s
filtri successivi	0 byte · 100-220 ms
filtro su una zona	0,23 MB
mappa (blocco C, su richiesta)	~1 MB
scheda individuo	~0,15 MB la prima, 0 dopo
sessione piena	~2,5 MB

10. Fasi

F0 ✓ i due diagnostici, su Modena e Parma (§13.1). **F1 ✓** smoke test dello stack (§13.2). **F2 ✓** `donor_id` dalla firma AVQ (§13.3). **F3 ✓** bundle minimo e pannello dei marginali. **F4 ✓** riferimento censuario dal constraint set, con la tabella di copertura. **F5** ☐ mappa: quota e punti fatti, navigazione e base cartografica fatte. Restano le geometrie di sezione e zona, se serviranno.

Prossime, in ordine di dipendenza:

F6 — `donor_id` nel Parquet e pannello AVQ con `n_eff` per variabile. E' il pezzo mancante della catena dell'onesta': oggi le AVQ compaiono solo nella scheda individuo, dove il problema non si pone.

F7 — Confronta fra città, livelli A e B.

F8 — Metodo: la pagina che rende l'app difendibile.

F9 — grafica in senso proprio, e pubblicazione.

11. Questioni aperte

- Definizioni vere di** `macroeta` e `istr4` in `assign_avq.py`. Senza, `cella_avq` non e' stimabile e il blocco 3 di `verifica_donor.py` resta illeggibile.
- `n_eff` per universo di variabile (blocchi 5 e 6 di `verifica_donor.py`): danno i numeri veri per §2.1.
- Definizione di MRE** in `fit_cs.py`. La formula del riferimento, $\text{mean}(\text{sqrt}((1-\alpha)/(\alpha N)))$, e' la **deviazione standard** dell'errore relativo; il valore

assoluto medio vale $\sqrt{2/\pi} = 0,798$ volte tanto. Strumento e paper devono usare la stessa definizione.

4. `sexo × background × origine_genitori`: |z| fino a 4,0, replicato (§13.4). Ipotesi: l'esclusione $\alpha=0$ post-hoc sposta massa e i target del blocco non reggono piu'. Da verificare.
5. **Fonti comunali di zona**: quali disponibili come *livelli*? Sono l'unica validazione esterna, e nel bundle non ci sono ancora.
6. **Emilia-Romagna**: quanti capoluoghi, e la vista regionale?
7. **Le riparazioni della pipeline** (§13.1): permutazione di `istruzione` entro (zona, sesso, bin), e le **26 esclusioni $\alpha=0$** . Post-hoc entrambe, nessuna rigenerazione necessaria.
8. **Campionamento degli agenti per firma** invece che per individuo (§14).

12. Registro dei miglioramenti

Fatti

	effetto
colonne in tre blocchi per uso	Q5 da 2,297 a 0,915 MB
righe per <code>zona, sezione</code>	filtro di zona al 22%
<code>id</code> DELTA_BINARY_PACKED	0,79 → <0,09 MB
AVQ grezze eliminate	blocco B 2,659 → 1,411 MB
<code>donor_id</code> dalla firma	sblocca <code>n_eff</code> senza rilanciare la pipeline
<code>n_eff</code> di Kish	il numero cambia di un fattore 2,8
z-score invece dell'errore relativo	il MRE per cella era tutto rumore
riferimento da <code>cs_K9C.json</code>	F4 senza fonti esterne
<code>zona</code> etichettata coi quartieri	un pannello invece di due gemelli
troncamento per attributo	Brescia non perde piu' 18 quartieri su 33
ordine stabile fra città	pannelli affiancabili
crossfilter che esclude la propria dimensione	il pannello non collassa su se' stesso
jitter deterministico	punti fermi, e quindi cliccabili
	file 5,22 → 3,12 MB

Proposti

- **base cartografica** (`.pmtiles`): un estratto Protomaps dell'Emilia-Romagna e della Lombardia orientale, servito dal bundle. Toglie l'unica dipendenza esterna del progetto e rende l'app archiviabile per intero. Ordine di grandezza da tenere presente: qualche decina di MB per regione, cioè **piu' di tutti i Parquet messi insieme** — quindi va su un host separato, non su Pages. E' la stessa scelta di hosting che §3.1 prevede quando l'Emilia-Romagna arriva a dieci comuni, ma arriva prima;
- **rimuovere** (`quinq`) (0,089 MB, 13% del blocco caldo): e' (`least(eta_anni // 5, 15)`) in SQL;
- **rimuovere** (`quartiere`): e' l'etichetta di (`zona`) e ora sta nel manifest;
- (`donor_id`) e (`donor_anno`) nell'export;
- sostituire la riga «aggregazione tipica» in (`to_parquet.py`), che suggerisce che il costo sia la somma delle colonne richieste mentre e' il blocco;
- correggere (`MRE att`) in (`verifica_vincoli.py`) col fattore ($\sqrt{2/\pi}$), e stampare (`sd(z)`) per blocco al posto di (`z_max`).

Scartati, col motivo

- **spezzare il blocco AVQ**: Q4 ha la sovralettura peggiore ma **non e' una query realistica** — il pannello fiducia legge tutte e dodici le (`PUNTIFI`);
- **AVQ in int8**: il dizionario e' gia' a 4 bit, all'ottimo teorico;
- (`agg_sezioni.parquet`) **come requisito**: mascherava un costo d'ingresso che non esiste;
- **modo densita' nella mappa**: riproduce la densita' di popolazione;
- **geometrie per la mappa**: la griglia da (`lon`)/(`lat`) basta;
- (`lon_j`)/(`lat_j`) **nel Parquet**: il jitter deterministico si calcola a runtime;
- **rigenerare le popolazioni** per i 3 record impossibili: sono 3 su 970.000, la correzione e' post-hoc, e rigenerare invaliderebbe tutte le misure e i (`donor_id`).

13. Diario delle misure

13.1 F0 — i due diagnostici (Modena e Parma)

(a) **Seam quinquennale**. MAE grezzo indistinguibile; normalizzando per dimensione di classe le due classi del seam finiscono **nei primi tre posti su sedici in entrambe le citta'** ($p \approx 6 \cdot 10^{-4}$). Ma l'eccesso e' del 40%: **l'ipotesi di uniformita' non e' dominante**.

Sistematico e non previsto: dentro ciascuno dei cinque bin veri il sintetico pende verso il **giovane, dieci prove su dieci**, 0,10–0,44 pp. La distribuzione dentro il bin non e' vincolata da niente — il constraint set fissa il totale, il quinquennio viene dalle colonne P, l'anno dall'anagrafe — quindi l'indiziato e' l'assunzione (9). Nella regione infantile il verso si inverte: (`10-14`) sovrarappresentata di +0,37 e +0,35, e li' opera la frazione $4/5-1/5$.

Ritirato. La v0.5 riportava come terzo risultato una discrepanza «fino a 1,42% fra due prodotti censuari». Era **rumore di campionamento**: il target del constraint set e le colonne P coincidono, e lo scarto della popolazione dal proprio target vale $z = 0,24$ su Modena e $0,64$ su Parma.

(b) Coerenza eta'-istruzione: 2,64% a Modena, 2,74% a Parma, concentrate nei bin (9-14) e (15-24). *Riparazione:* permutare (istruzione) entro (zona, sesso, bin).

(c) Combinazioni impossibili: (diploma) a 2 anni e (post_laurea) a 13 (Parma), (altra_condizione) a 0 anni (Modena). Tre record su 970.000.

13.2 F1 — smoke test DuckDB-WASM

Otto query isolate; sette su otto entro il 20% del modello di costo. $Q3/Q3N = 10,7\%$, $Q6/Q2 = 21,8\%$. Tempi a caldo 100-220 ms.

Errore di metodo corretto: la prima misura di Q3 era contaminata, perche' le query di una sessione si scaldano a vicenda. La contaminazione, letta come fenomeno invece che come errore, e' cio' che ha rivelato la struttura a blocchi.

13.3 F2 — (donor_id) dalla firma AVQ

Firme distinte: Modena 4.199 contro 4.617 donatori, Bologna 4.207 contro 4.625. **Differenza identica, -418:** proprieta' del pool emiliano, e l'errore va nella **direzione prudente**.

(n_eff) di Kish 1.520 e 1.599 — il conteggio dei distinti sbagliava di $2,8\times$, perche' Kish e' una statistica di secondo momento e vive nella coda. La firma piu' riusata vale da sola **~10% del peso statistico della citta'**.

Limite: quella firma e' dei minori, per cui la 21-upla si riduce a quattro valori. I numeri $\times 11,0$ e $\times 15,6$ sono calcolati sull'universo sbagliato e vanno rifatti per variabile.

13.4 Anatomia del constraint set e stato del pool

Sedici blocchi, identici in tutte e quattro le citta'. Undici completi, cinque parziali. I parziali sono i **complementi fuori universo**: (eta × istruzione) = la sola cella ((0-8, nessun_titolo)); (eta × condizione) = ((0-8, non_applicabile) e ((9-14, non_applicabile)); (zona × sesso × eta × condizione) = i soli occupati 15-64. Sommano a 1 a coppie col blocco completo corrispondente.

Il punto metodologico, materiale da paper GibbsPCD. Quando l'ISTAT **esclude per universo**, la cella non compare nella tavola. Quando il censimento **osserva zero**, la cella compare con valore zero. Per MaxEnt le due cose sono **opposte**: una cella assente e' *non vincolata*, una cella a zero e' *vietata*. La prova che il meccanismo funziona quando il dato c'e': (cittadinanza × background) ha 6 zeri espliciti e (sesso × eta × stato_civile) ne ha 2 — e nessuno di questi e' violato. Le **26 coppie** logicamente impossibili di eta' × condizione ed eta' × istruzione **non sono vincolate da nessun blocco**, ed e' per questo che tre record ci sono finiti dentro.

Il pool e' un campione pulito.

	Modena	Parma	atteso
$sd(z)$	1,030	1,031	1,000
media(z)	-0,021	+0,005	0
$ z $ medio	0,829	0,810	0,798
$ z > 2$	4,45%	5,49%	4,55%
zeri hard violati	0	0	0

$sd(z)^2 = 1,06$ e' il **fattore di inflazione della varianza**: il pool di 184.597 individui vale ~174.000 estrazioni indipendenti. E' la prima quantificazione del mixing della catena, e si legge senza glossario.

Un blocco anomalo, replicato: $(\text{sexo} \times \text{background} \times \text{origine_genitori})$, con $|z|$ medio 1,16 e 1,05 contro 0,80 dei blocchi demografici, e picchi da -3,90 a +4,00. Le celle a **genitori misti perdono massa**, quelle a genitori omogenei la guadagnano. Ipotesi: l'esclusione $\alpha=0$ post-hoc sul supporto sottrae massa e la redistribuzione favorisce le celle grandi.

14. Cosa significa per SimComm

La **diversita' psicologica effettiva di una popolazione di agenti non e' quella dei suoi individui**: e' quella di ~1.500 donatori, e non cresce prendendo una citta' piu' grande. Per 120 agenti probabilmente non morde; per qualunque affermazione sulla *distribuzione* l'errore standard e' fissato da 1.500.

Il **secondo ordine e' piu' insidioso**. Due agenti che condividono la firma hanno profili **identici**, non simili: in una simulazione LLM le loro risposte sono correlate per costruzione e non sono evidenza indipendente. Con riusi medi di 40-93, in un campione di 120 agenti da Bologna le collisioni non sono trascurabili.

Domanda di disegno sperimentale: conviene campionare gli agenti **per firma** invece che per individuo? Garantirebbe profili distinti al prezzo di distorcere le quote demografiche — che sono esattamente cio' che il tier 1 esiste per garantire. Va deciso e dichiarato nel paper.

Se non altro, va misurato: in una campagna gia' eseguita, quante coppie di agenti condividevano la firma?

La *scheda individuo di §4.4 rende questa sezione tangibile*: due punti vicini sulla mappa con la stessa fiducia, la stessa salute e lo stesso BMI sono due individui che condividono il donatore. E' n_{eff} che si vede a occhio nudo.