

Popolazioni sintetiche GSP — documento di riferimento

Versione 1.0 — 28 luglio 2026 Descrive i file `popolazione_K9C_avq_full.csv` per Brescia, Parma e Bologna: come caricarli, cosa contengono, come sono stati costruiti, quali limiti dichiarati portano con sé e dove trovare i dati reali per il confronto.

1. I file

```
~/progetti/gsp/data/comuni/{COMUNE}/constraints_2024/popolazione_K9C_avq_full.c
```

comune	codice	indivuidi	attributi
Brescia	017029	198.259	28
Parma	034027	198.121	28
Bologna	037006	390.098	28

Totale 786.478 individui sintetici, ciascuno con indirizzo civico e coordinate geografiche.

Caricamento

Ci sono tre trappole di tipo. Questo snippet le gestisce tutte:

```
python
```

```

import pandas as pd, os

def carica(comune, anno=2024):
    f = os.path.expanduser(
        f"~/progetti/gsp/data/comuni/{comune}/constraints_{anno}/"
        f"popolazione_K9C_avq_full.csv")
    p = pd.read_csv(f, low_memory=False, dtype={
        "zona": "string",          # 34027001: NON leggere come int
        "sezione": "string",       # 340270000994: 12 cifre
        "civico": "string",        # '19A': numero + esponente
    })
    # Le variabili AVQ sono codici numerici mescolati a 'non_applicabile'.
    for c in ["AMBIENTE", "FIDUCIA", "SALUTE", "CRONI", "FUMO",
              "MH", "BMI", "BMIMIN", "CPESO"]:
        p[c + "_num"] = pd.to_numeric(p[c], errors="coerce")
    return p

COMUNI = {"017029": "Brescia", "034027": "Parma", "037006": "Bologna"}

```

Trappole:

1. `zona` e `sezione` sono codici, non numeri. Letti come `int64` funzionano ma perdono la natura di chiave; letti come `float` diventano notazione scientifica.
2. Le nove variabili AVQ sono **stringhe** perché mescolano codici numerici e `non_applicabile` — tranne `SALUTE`, che è `int64` perché è l'unica senza missing strutturali. Non applicare la stessa conversione a tutte senza verificare.
3. `area` usa `NaN` per gli italiani, non `non_applicabile`. Le convenzioni per "assente" sono tre e non sono state uniformate (§6).

2. Gli attributi

2.1 Anello 1 — MaxEnt (vincolati)

Dieci attributi le cui marginali e incroci riproducono il constraint set censuario con $MRE \approx 4 \cdot 10^{-4}$.

colonna	modalità	note
zona	codice a 8 cifre	quartiere o zona statistica, §3
quartiere	stringa	denominazione della zona
sezzo	M, F	
eta	0-8, 9-14, 15-24, 25-34, 35-49, 50-64, 65-74, 75+	bin del constraint set
stato_civile	celibe_nubile, coniugato_unito, divorziato_sciolto, vedovo	unioni civili collassate in coniugato_unito
cittadinanza	ITL, FRG	giuridica; FRG include gli apolidi (= FRGAPO) SDMX = ST1 sezioni)
istruzione	nessun_titolo, elementare, media, diploma, laurea_o_its, post_laurea	laurea_o_its = triennale + ITS; post_laurea = magistrale + ciclo unico + dottorato
condizione	occupato, in_cerca, studente, casalinga, percettore_pensioni, altra_condizione, non_applicabile	non_applicabile = under 15 (categoria sostantiva)
background	italiano_nativo, italiano_rientrato, naturalizzato_g2, naturalizzato_immigrato, straniero_g2, straniero_immigrato	background migratorio: non coincide con cittadinanza
origine_genitori	entrambi_italiani, madre_italiana_padre_straniero, madre_straniera_padre_italiano, entrambi_stranieri, non_applicabile	

Metà delle 30 combinazioni (background × origine_genitori) è logicamente impossibile ed è esclusa dal supporto per costruzione.

2.2 Anello 2 — condizionali post-hoc

colonna	modalità	fonte
<code>area</code>	<code>UE</code> , <code>EXTRA_UE</code> , <code>NaN</code> (italiani)	<code>ST17/18/20/21</code> della sezione
<code>paese</code>	143-151 paesi + <code>Italia</code>	censimento comunale, <code>cens_stranieri_paesi</code>
<code>AMBIENTE</code>	1-4 + <code>non_applicabile</code>	AVQ regionale
<code>FIDUCIA</code>	1-2 + <code>non_applicabile</code>	AVQ
<code>SALUTE</code>	1-5	AVQ, nessun missing
<code>CRONI</code>	1-2 + <code>non_applicabile</code>	AVQ
<code>FUMO</code>	1-3 + <code>non_applicabile</code>	AVQ
<code>MH</code>	continua 0-100 + <code>non_applicabile</code>	AVQ, indice SF-12 salute mentale
<code>BMI</code>	1-4 + <code>non_applicabile</code>	AVQ, adulti
<code>BMIMIN</code>	1-2 + <code>non_applicabile</code>	AVQ, solo minori (~13,6%)
<code>CPESO</code>	1-5 + <code>non_applicabile</code>	AVQ, percezione del peso

Le nove variabili AVQ arrivano in blocco dallo stesso donatore (hot-deck), quindi le correlazioni interne sono preservate per costruzione. Non sono campionate indipendentemente.

Universi diversi per variabile. `BMIMIN` copre il 13,6% della popolazione, `CRONI` il 93,8%, `SALUTE` il 100%. Non esiste un sottoinsieme di righe completo su tutte: ogni combinazione di variabili definisce una popolazione analizzabile diversa. Per le correlazioni usare `DataFrame.corr(min_periods=...)`, che fa cancellazione pairwise — un `dropna()` listwise su tutte e nove restituisce **zero righe** (`BMIMIN` e `FIDUCIA` hanno universi complementari).

Codifiche AVQ — stato di conoscenza. Le etichette sono state inferite dai marginali, non lette dal codebook:

	inferenza	confidenza
SALUTE	1 = molto bene ... 5 = molto male	alta
FUMO	1 = fumatore, 2 = ex, 3 = mai	alta
BMI	1 = sottopeso ... 4 = obeso	alta
MH	SF-12, più alto = meglio	alta
CRONI	1 = nessuna, 2 = almeno una	media
BMIMIN	1 = normo/sotto, 2 = sovrappeso/obeso	media
AMBIENTE	scala a 4 punti, direzione ignota	bassa
CPESO	scala a 5 punti, costruito ignoto	bassa
FIDUCIA	binaria, ~28% positivi	da verificare, §7

2.3 Anello 3 — risoluzione fine

colonna	tipo	descrizione
sezione	codice a 12 cifre	sezione di censimento (SEZ21_ID), basi territoriali 2021)
eta_anni	0-100	età esatta in anni
via	stringa	odonimo ANNCSU
civico	stringa	numero + esponente (12 , 19A)
lon , lat	float, EPSG:4258	coordinate del civico ($\approx$ WGS84)
indirizzo_fonte	sezione / zona / convivenza	provenienza dell'indirizzo

indirizzo_fonte è la colonna di qualità:

	sezione	zona	convivenza
Brescia	99,62%	200	545
Parma	99,74%	39	479
Bologna	99,83%	36	633

- sezione: civico estratto dentro la sezione assegnata (caso normale);
- zona: la sezione è popolata ma priva di civici ANNCSU → civico preso altrove nel quartiere;
- convivenza: sezione fittizia (888888x) (senza tetto, convivenze anagrafiche). **Nessun indirizzo**, coordinate = centroide della zona. Profilo demografico anomalo: a Parma 80% maschi, 73% stranieri.

3. Livello territoriale — non è uniforme fra comuni

ISTAT pubblica fino a tre livelli di sub-aree amministrative ((COM_ASC1/2/3)), ma la disponibilità e la cardinalità variano per comune. Il livello è **fissato nel registro di build_zona_tables.py** e **enrich.py**, non scelto da riga di comando.

comune	livello	zone	abitanti/zona	sezioni
Brescia	(COM_ASC1) (quartieri)	33	6.008	1.822
Parma	(COM_ASC1) (quartieri)	13	15.240	1.357
Bologna	(COM_ASC2) (zone statistiche)	18	21.672	2.224

Bologna usa ASC2 perché i suoi 6 quartieri ASC1 sono troppo pochi; ASC3 (90 aree) è inutilizzabile per la coda di zone minuscole (la più piccola ha 13 abitanti). Parma pubblica solo ASC1.

Conseguenza per il confronto: la granularità zonale non è comparabile fra le tre città (fattore 3,6 fra Brescia e Bologna). Va condizionata, non presa al valore facciale.

Quartieri di Parma

34027001 Parma Centro	34027006 San Pancrazio	34027011 Cittadella
34027002 Oltretorrente	34027007 San Leonardo	34027012 Montanara
34027003 Molinetto	34027008 Cortile San Martino	34027013 Vigatto
34027004 Pablo	34027009 Lubiana	
34027005 Golese	34027010 San Lazzaro	

Le denominazioni di Brescia e Bologna stanno nei registri di `build_zona_tables.py` e nel file `zona_2023/*_nomi.csv`.

4. La pipeline in breve

<code>fetch_comune.py</code>	SDMX ISTAT -> 11 tavole censuarie comunali	
<code>build_sezioni.py</code>	file regionale -> {comune}_sezioni_2023.csv	
<code>build_zona_tables.py</code>	sezioni -> Z1..Z4, Z6 al livello ASC scelto	
<code>build_constraints.py</code>	tavole -> constraint set (blocchi c1..c10)	
<code>cs_build.py</code>	-> supporto X + vincoli (cs_K9C.json)	
<code>fit_cs.py</code>	-> MaxEnt esatto -> popolazione_K9C.csv	
<code>assign_nationality.py</code>	-> + paese	anello 2
<code>assign_avq.py</code>	-> + 9 variabili AVQ	
<code>enrich.py</code>	-> + sezione, area, eta_anni, indirizzo, lon/lat	
		anello 3

Anello 1 (MaxEnt). Massima entropia con vincoli censuari, risolta con solver esatto (L-BFGS su matrice sparsa). Il quartiere è il livello più fine a cui il censimento pubblica gli *incroci* necessari. $|X| = 161.280 \times n_{\text{zone}}$ (2,1 M per Parma, 2,9 M per Bologna, 5,3 M per Brescia). $MRE(\alpha > 0) \approx 4 \cdot 10^{-4}$, indipendente da $|X|$ su tre ordini di grandezza.

Anello 2 (condizionali). Attributi non censuari iniettati post-hoc: nazionalità dal censimento comunale, variabili psicografiche e di salute per hot-deck dai microdati AVQ regionali.

Anello 3 (risoluzione fine). Sotto il quartiere esistono solo marginali di sezione, sfruttati come condizionali. Allocazione esatta (largest remainder) a ogni stadio, mai campionamento multinomiale.

Perché l'allocazione esatta conta

MAE della popolazione per sezione: **1,4-1,6** su medie di 109-175 abitanti. Un campionamento multinomiale darebbe $\approx 9,6$. Il fattore 6,6 viene dall'allocazione esatta dentro ogni gruppo; il residuo è l'accumulo di arrotondamenti su una trentina di gruppi per sezione, quindi **non cresce con la popolazione**.

5. Validazione

Confronto sintetico vs censimento, cella per cella su tutte le sezioni:

	sezioni	MAE pop.	corr	MAE stranieri	corr
Brescia	1.822	1,58	0,9998	0,98	0,9990
Parma	1.357	1,45	0,9999	1,12	0,9985
Bologna	2.224	1,36	0,9999	1,11	0,9982

I totali comunali coincidono esattamente con il censimento (198.259 / 198.121 / 390.098). Gli scarti sui totali di stranieri (+53, +74, +54) sono entro 0,5 σ del rumore multinomiale di estrazione della popolazione, non dell'anello 3.

Struttura spaziale: la sezione conta molto più della zona

Decomposizione della varianza della quota UE fra stranieri, al netto della discretizzazione dei piccoli conteggi:

	var tra zone	var reale dentro	sovradispersione	rapporto
Brescia (33 zone)	0,00168	0,00991	2,89×	5,9×
Parma (13 zone)	0,00110	0,01249	3,50×	11,3×
Bologna (18 zone)	0,00072	0,01124	3,04×	15,7×

Lettura: la composizione UE/extra-UE varia poco fra quartieri e molto fra sezioni dentro lo stesso quartiere. **Condizionare sul quartiere perde l'85-94% del segnale compositivo.** Il risultato è monotono nella dimensione media delle zone ed è confermato su tre partizioni diverse.

Nota metodologica: i conteggi censuari sono enumerazione completa, non stime. La sovradispersione ($\approx 3\times$) misura struttura spaziale reale, non rumore campionario.

6. Limiti e assunzioni dichiarate

Assunzioni di indipendenza condizionale

n.	assunzione	dove
(4)	`paese $\perp$ zona	(area, sesso)`
(6)	`target AVQ $\perp$ tutto	(sesso, macroetà, istruzione4, regione)`
(8)	`sezione $\perp$ (istruzione, condizione, background)	(zona, sesso, età3, cittadinanza)`
(9)	entro il quinquennio, l'età segue la distribuzione comunale per anno singolo	anello 3
(10)	l'indirizzo è uniforme fra i civici della sezione (ANNCSU non dà residenti per civico)	anello 3
(11)	nessuna struttura familiare : ogni individuo ha indirizzo indipendente	anello 3

Limiti della risoluzione per età

- **L'istruzione ha risoluzione effettiva di 4 classi d'età, non 8.** Il vincolo censuario usa $Y9-24$, $Y25-49$, $Y50-64$, Y_{GE65} . Dentro ogni classe la distribuzione è ottenuta per IPF con soglie minime di conseguimento del titolo ($elementare$ 10, $media$ 13, $diploma$ 18, $laurea_o_its$ 20, $post_laurea$ 22): i margini censuari sono preservati e le combinazioni impossibili azzerate.
- **Resta sovrastimata $media$ nel bin $9-14$:** la licenza media si consegue a 14 anni, quindi riguarda circa un sesto del bin, ma la distribuzione entro il bin è uniforme per età.
- **Effetto coorte perso fra $65-74$ e $75+$:** Y_{GE65} li rende indistinguibili, mentre nella realtà gli ultrasessantacinquenni hanno istruzione sensibilmente più bassa.
- **Il background migratorio ha risoluzione di zona,** non di sezione: sotto il quartiere non esiste alcun dato.

Convenzioni per "assente" — non uniformate

forma	dove
<code>non_applicabile</code> (stringa)	<code>condizione</code> , <code>origine_genitori</code> , 8 delle 9 AVQ
<code>NaN</code>	<code>area</code> , <code>via</code> , <code>civico</code>
nessuna	<code>SALUTE</code> , <code>paese</code> (= <code>Italia</code> per gli italiani)

`non_applicabile` è a volte una **categoria sostantiva** (la condizione professionale degli under-15) e a volte un **missing** (il `BMIMIN` degli adulti). Vanno distinti caso per caso.

7. Punti aperti

- **Codebook AVQ.** Le codifiche di `AMBIENTE` e `CPESO` non sono note; le altre sono inferite dai marginali. Da risolvere sui codebook ufficiali nei microdati.
- `FIDUCIA` potrebbe essere il costruito sbagliato. È binaria con ~28% di risposte positive, che è il profilo tipico della **fiducia interpersonale generalizzata** ("gran parte della gente è degna di fiducia"), non della fiducia istituzionale. Se confermato, per il lavoro sulla comunicazione del rischio servono variabili diverse — AVQ ne rileva alcune, oppure si passa a ESS per batterie validate.
- **Struttura familiare.** `cens_posizione_famiglia` è scaricata ma non usata; è la fonte naturale per introdurre i nuclei.
- **Convivenze.** Riprodotte con scarto del $\pm 2-5\%$, il peggiore fra tutte le celle: un tilt moltiplicativo su classi larghe fatica su un profilo così estremo. Se le convivenze diventeranno rilevanti, serve un trattamento dedicato.
- **K10C.** Esiste solo per Brescia, con `settore` come decimo attributo, e porta ancora l'istruzione **pre-correzione**: va rigenerato se usato.

8. Dove sono i dati reali, per il confronto

Per confrontare marginali sintetiche e reali:

{COMUNE}/constraints_2024/

cs_K9C.json vincoli con alpha target, categories, domain_sizes, zona_nomi. E' la verita' di riferimento dell'anello

1.

targets_K9C.json tabelle target per blocco (A, B, C, D, E, F, S...)

fit_K9C.json lambdas, MRE, entropia, supporto

manifest.json fonte e tipo (hard/soft) di ogni blocco

{COMUNE}/zona_2023/

z1..z4, z6, nomi marginali censuarie per zona

data/submun/{nome}_sezioni_2023.csv

verita' per sezione: P1 (popolazione), ST1 (stranieri), ST16/ST19 (UE/extra-UE), P30-P45 e P67-P82 (sesso x quinquennio), ST25-ST30 (stranieri per sesso x eta3)

Estrazione degli α target di un blocco:

python

```
import json, os
d = os.path.expanduser("~/progetti/gsp/data/comuni/034027/constraints_2024")
cs = json.load(open(f"{d}/cs_K9C.json"))
vars_, cats = cs["vars"], cs["categories"]
# ogni vincolo: {'attrs': [indici di vars_], 'vals': [indici di cats], 'alpha':
```

Geometrie per la visualizzazione

Le geometrie delle **sezioni** stanno nelle basi territoriali ISTAT:

data/geodata/{regione}/R{NN}_21/SHP/R{NN}_21_WGS84.shp
R03 Lombardia R08 Emilia-Romagna R16 Puglia
CRS: EPSG:32632 – riproiettare a EPSG:4326 per il web

Lo shapefile contiene le colonne `COM_ASC1/2/3`, quindi **i poligoni dei quartieri si ottengono per dissolve delle sezioni** sul livello scelto, senza bisogno di uno shapefile ASC separato:

python

```
import geopandas as gpd
s = gpd.read_file("../R08_21_WGS84.shp")
s = s[s.PRO_COM == 34027]
quartieri = s.dissolve(by="COM_ASC1").reset_index().to_crs("EPSG:4326")
```

Attenzione: lo shapefile regionale contiene **più sezioni** del file dati 2023 (quelle senza popolazione residente pubblicata). Il collegamento su `SEZ21_ID` è però completo: tutte le sezioni dei dati 2023 hanno una geometria.

9. Riepilogo numerico

	Brescia	Parma	Bologna
codice ISTAT	017029	034027	037006
regione (AVQ)	Lombardia (30)	Emilia-Romagna (80)	Emilia-Romagna (80)
popolazione	198.259	198.121	390.098
zone	33 (ASC1)	13 (ASC1)	18 (ASC2)
sezioni	1.822	1.357	2.224
sezioni occupate	1.774	1.313	2.152
civici ANNCSU	49.730	35.826	77.595
stranieri (censimento)	37.478	34.436	58.963
quota stranieri	18,9%	17,4%	15,1%
donatori AVQ	8.111	4.629	4.629
riuso medio donatore	24×	43×	84×
`	X	` K9C	5.322.240

Il riuso dei donatori è un tetto strutturale: nella popolazione di Bologna esistono al massimo 4.629 vettori psicografici distinti, indipendentemente dai 390.098 individui. La diversità dell'anello 2 è limitata dalla taglia del campione AVQ regionale, non dalla popolazione.

Le cifre di validazione dell'anello 3 (MAE, quote di `indirizzo_fonte`) provengono dalle esecuzioni del 28 luglio 2026. Le popolazioni sono state rigenerate dopo la correzione

sull'istruzione: rileggere i log più recenti per i valori aggiornati, che possono differire nell'ultima cifra.