

Popolazioni sintetiche GSP — documento di riferimento

Versione 1.1 — 29 luglio 2026 Descrive i file `popolazione_K9C_avq_full.csv` per Brescia, Parma e Bologna: come caricarli, cosa contengono, come sono stati costruiti, quali limiti dichiarati portano con sé e dove trovare i dati reali per il confronto.

Novità rispetto alla v1.0 (changelog in fondo): modulo condiviso `gsp_common.py`; correzione dei nomi delle zone di Bologna (16 su 18 erano errati); correzione dell'istruzione nei bin infantili; sistema a tier per il condizionale geografico del paese di cittadinanza (**costruito, non ancora collegato**); riconciliazione delle denominazioni di paese fra quattro vocabolari.

1. I file

```
~/progetti/gsp/data/comuni/{COMUNE}/constraints_2024/popolazione_K9C_avq_full.c
```

comune	codice	individui	attributi
Brescia	<code>017029</code>	198.259	28
Parma	<code>034027</code>	198.121	28
Bologna	<code>037006</code>	390.098	28

Totale 786.478 individui sintetici, ciascuno con indirizzo civico e coordinate geografiche.

Caricamento

Ci sono tre trappole di tipo. Questo snippet le gestisce tutte:

```
python
```

```

import pandas as pd, os

def carica(comune, anno=2024):
    f = os.path.expanduser(
        f"~/progetti/gsp/data/comuni/{comune}/constraints_{anno}/"
        f"popolazione_K9C_avq_full.csv")
    p = pd.read_csv(f, low_memory=False, dtype={
        "zona": "string",      # 34027001: NON leggere come int
        "sezione": "string",   # 340270000994: 12 cifre
        "civico": "string",    # '19A': numero + esponente
    })
    for c in ["AMBIENTE", "FIDUCIA", "SALUTE", "CRONI", "FUMO",
              "MH", "BMI", "BMIMIN", "CPESO"]:
        p[c + "_num"] = pd.to_numeric(p[c], errors="coerce")
    return p

```

In alternativa, tutti i percorsi e i registri stanno in `gsp_common.py` (§4):

```

python

import sys, os
sys.path.insert(0, os.path.expanduser("~/progetti/gsp/scripts"))
import gsp_common as G
f = os.path.join(G.path_constraints("034027", 2024),
                 "popolazione_K9C_avq_full.csv")

```

Trappole:

1. `zona` e `sezione` sono codici, non numeri. Letti come `int64` funzionano ma perdono la natura di chiave; letti come `float` diventano notazione scientifica.
2. Le nove variabili AVQ sono **stringhe** perché mescolano codici numerici e `non_applicabile` — tranne `SALUTE`, che è `int64` perché è l'unica senza missing strutturali.
3. `area` usa `NaN` per gli italiani, non `non_applicabile`. Le convenzioni per "assente" sono tre e non sono state uniformate (§7).

2. Gli attributi

2.1 Anello 1 — MaxEnt (vincolati)

Dieci attributi le cui marginali e incroci riproducono il constraint set censuario con $MRE \approx 4 \cdot 10^{-4}$.

colonna	modalità	note
zona	codice a 8 cifre	quartiere o zona statistica, §3
quartiere	stringa	denominazione della zona
sezzo	M, F	
eta	0-8, 9-14, 15-24, 25-34, 35-49, 50-64, 65-74, 75+	bin del constraint set
stato_civile	celibe_nubile, coniugato_unito, divorziato_sciolto, vedovo	unioni civili collassate in coniugato_unito
cittadinanza	ITL, FRG	giuridica; FRG include gli apolidi (= FRGAPO) SDMX = ST1 sezioni)
istruzione	nessun_titolo, elementare, media, diploma, laurea_o_its, post_laurea	laurea_o_its = triennale + ITS; post_laurea = magistrale + ciclo unico + dottorato
condizione	occupato, in_cerca, studente, casalinga, percettore_pensioni, altra_condizione, non_applicabile	non_applicabile = under 15 (categoria sostantiva)
background	italiano_nativo, italiano_rientrato, naturalizzato_g2, naturalizzato_immigrato, straniero_g2, straniero_immigrato	background migratorio: non coincide con cittadinanza
origine_genitori	entrambi_italiani, madre_italiana_padre_straniero, madre_straniera_padre_italiano, entrambi_stranieri, non_applicabile	

Metà delle 30 combinazioni (background × origine_genitori) è logicamente impossibile ed è esclusa dal supporto per costruzione.

2.2 Anello 2 — condizionali post-hoc

colonna	modalità	fonte
<code>area</code>	<code>UE</code> , <code>EXTRA_UE</code> , <code>NaN</code> (italiani)	<code>ST17/18/20/21</code> della sezione
<code>paese</code>	143-151 paesi + <code>Italia</code>	censimento comunale (§6: il condizionale geografico è pronto ma non collegato)
<code>AMBIENTE</code>	1-4 + <code>non_applicabile</code>	AVQ regionale
<code>FIDUCIA</code>	1-2 + <code>non_applicabile</code>	AVQ
<code>SALUTE</code>	1-5	AVQ, nessun missing
<code>CRONI</code>	1-2 + <code>non_applicabile</code>	AVQ
<code>FUMO</code>	1-3 + <code>non_applicabile</code>	AVQ
<code>MH</code>	continua 0-100 + <code>non_applicabile</code>	AVQ, indice SF-12 salute mentale
<code>BMI</code>	1-4 + <code>non_applicabile</code>	AVQ, adulti
<code>BMIMIN</code>	1-2 + <code>non_applicabile</code>	AVQ, solo minori (~13,6%)
<code>CPESO</code>	1-5 + <code>non_applicabile</code>	AVQ, percezione del peso

Le nove variabili AVQ arrivano in blocco dallo stesso donatore (hot-deck), quindi le correlazioni interne sono preservate per costruzione.

Il pool di donatori è **regionale**: 8.111 per la Lombardia, 4.629 per l'Emilia-Romagna. Il condizionamento è su `(sesso × macroetà × istruzione4)`, con collasso gerarchico progressivo (prima l'istruzione, poi l'età) quando la cella è rada. Su Parma il 94,8% resta al livello pieno, il 5,2% scende a `(sesso × macroetà)`, nessuno arriva al marginale regionale.

Universi diversi per variabile. `BMIMIN` copre il 13,6% della popolazione, `CRONI` il 93,8%, `SALUTE` il 100%. Non esiste un sottoinsieme di righe completo su tutte. Per le correlazioni usare `DataFrame.corr(min_periods=...)`, che fa cancellazione pairwise — un `dropna()` listwise su tutte e nove restituisce **zero righe** (`BMIMIN` e `FIDUCIA` hanno universi complementari).

Codifiche AVQ — stato di conoscenza. Inferite dai marginali, non lette dal codebook:

	inferenza	confidenza
SALUTE	1 = molto bene ... 5 = molto male	alta
FUMO	1 = fumatore, 2 = ex, 3 = mai	alta
BMI	1 = sottopeso ... 4 = obeso	alta
MH	SF-12, più alto = meglio	alta
CRONI	1 = nessuna, 2 = almeno una	media
BMIMIN	1 = normo/sotto, 2 = sovrappeso/obeso	media
AMBIENTE	scala a 4 punti, direzione ignota	bassa
CPESO	scala a 5 punti, costruito ignoto	bassa
FIDUCIA	binaria, ~28% positivi	da verificare, §8

2.3 Anello 3 — risoluzione fine

colonna	tipo	descrizione
sezione	codice a 12 cifre	sezione di censimento (SEZ21_ID), basi territoriali 2021)
eta_anni	0-100	età esatta in anni
via	stringa	odonimo ANNCSU
civico	stringa	numero + esponente (12 , 19A)
lon , lat	float, EPSG:4258	coordinate del civico ($\approx$ WGS84)
indirizzo_fonte	sezione / zona / convivenza	provenienza dell'indirizzo

indirizzo_fonte è la colonna di qualità:

	sezione	zona	convivenza
Brescia	99,62%	200	545
Parma	99,74%	39	479
Bologna	99,83%	36	633

- `sezione`: civico estratto dentro la sezione assegnata (caso normale);
- `zona`: la sezione è popolata ma priva di civici ANNCSU → civico preso altrove nel quartiere;
- `convivenza`: sezione fittizia `888888x` (senza tetto, convivenze anagrafiche). **Nessun indirizzo**, coordinate = centroide della zona. Profilo demografico anomalo: a Parma 80% maschi, 73% stranieri.

3. Livello territoriale — non è uniforme, e i codici si sovrappongono

ISTAT pubblica fino a tre livelli di sub-aree amministrative (`COM_ASC1/2/3`), ma disponibilità e cardinalità variano per comune. Il livello è **fissato nel registro di `gsp_common.py`**, non scelto da riga di comando.

comune	livello	zone	abitanti/zona	sezioni
Brescia	<code>COM_ASC1</code> (quartieri)	33	6.008	1.822
Parma	<code>COM_ASC1</code> (quartieri)	13	15.240	1.357
Bologna	<code>COM_ASC2</code> (zone statistiche)	18	21.672	2.224

Bologna usa ASC2 perché i suoi 6 quartieri ASC1 sono troppo pochi; ASC3 (90 aree) è inutilizzabile per la coda di zone minuscole (la più piccola ha 13 abitanti). Parma pubblica solo ASC1.

Conseguenza per il confronto: la granularità zonale non è comparabile fra le tre città (fattore 3,6 fra Brescia e Bologna).

3.1 I codici ASC si sovrappongono fra livelli

I livelli sono numerati **indipendentemente**. A Bologna `COM_ASC1` va da `37006011` a `37006016` e `COM_ASC2` da `37006001` a `37006018`: sei codici esistono a entrambi i livelli con significati diversi.

```
37006011  come ASC1 -> Borgo Panigale-Reno  (quartiere, 61.149 ab.)
37006011  come ASC2 -> Marconi                (zona statistica, 14.687 ab.)
```

Il codice da solo non identifica la zona: l'informazione sta nella colonna da cui proviene. Un merge sul solo codice riesce e restituisce il nome sbagliato, senza errori né valori mancanti. La guardia `G.verificalivello()` intercetta il caso in cui i codici di una popolazione non appartengano al livello atteso.

3.2 Incidente: i nomi delle zone di Bologna erano errati

Fino al 29/07/2026 il dizionario `codice → nome` di Bologna era **permutato**: 16 codici su 18 portavano il nome di un'altra zona. Nessun controllo strutturale poteva vederlo — una permutazione resta una biiezione perfetta — e la gerarchia zona→quartiere, costruita a mano sopra quei nomi, era coerente con sé stessa.

L'errore è emerso quando il consolidamento ha sostituito la mappa cablata con una **derivata dalle sezioni**, e le due hanno divergato. L'identificazione ha usato due vincoli indipendenti che concordano: la struttura della gerarchia (gruppi di taglia 3, 3, 4, 2, 4, 2, che si sovrappongono in un solo modo) e i conteggi di stranieri per zona degli open data comunali (rapporto anagrafe/censimento ~1,05 costante).

I codici ASC2 di Bologna seguono l'**ordine alfabetico** dei nomi, ignorando gli spazi (per questo `San Ruffillo`, `Santa Viola`, `San Vitale` finiscono in quell'ordine).

Lezione operativa: le denominazioni delle zone vanno verificate contro una fonte esterna prima di fidarsene. I dati numerici erano tutti corretti — popolazione, stranieri, varianze, MAE — perché calcolati sui codici; sbagliate erano solo le etichette leggibili, cioè esattamente ciò che finisce in mappe e tabelle.

Quartieri di Parma

```
34027001 Parma Centro      34027006 San Pancrazio      34027011 Cittadella
34027002 Oltretorrente     34027007 San Leonardo      34027012 Montanara
34027003 Molinetto         34027008 Cortile San Martino 34027013 Vigatto
34027004 Pablo             34027009 Lubiana
34027005 Golese            34027010 San Lazzaro
```

Le denominazioni di Brescia e Bologna stanno in `gsp_common.py` (`ASC_NOMI_BRESCIA`, `ASC1_NOMI_BOLOGNA`, `ASC2_NOMI_BOLOGNA`).

4. `gsp_common.py` — registro e primitive condivise

Consolida i cinque registri di comuni che erano duplicati in altrettanti script. Principio: nel registro sta **solo ciò che non è derivabile**; il codice ISTAT contiene già provincia e comune, e

i percorsi sono formule.

python

```
import gsp_common as G

G.info("034027")          # voce di registro
G.procom("034027")        # 34027
G.cod_prov("034027")      # "034"
G.cod_avq("034027")       # 80   (codice REGMf nei microdati AVQ)
G.livello_col("037006")   # "COM_ASC2"
G.zona_nomi("037006")     # {codice: nome} del livello in uso
G.path_sezioni("034027")  # ../submun/parma_sezioni_2023.csv
G.path_civici("034027")   # ../034_parma_civici_sezioni_asc.csv
G.path_constraints("034027", 2024)
G.largest_remainder(n, pesi) # allocazione esatta
G.norm_code(serie, comune)  # codice zona -> chiave normalizzata
G.norm_nome("S. Leonardo")  # "sleonardo"
G.paesi_censuari("034027")  # {nome normalizzato: codice ISO}
G.risolvi_paese(etichetta, rif) # etichetta locale -> codice censuario
```

Self-test contro i file su disco:

bash

```
python scripts/gsp_common.py --check
python scripts/gsp_common.py --dump-nomi 037006 # nomi zona da zona_2023/
```

Verifica per ogni comune: file sezioni presente, numero di zone al livello dichiarato uguale a quello atteso, corrispondenza biunivoca codici↔nomi, presenza dei civici e delle directory di lavoro.

Il consolidamento è stato eseguito come **refactor puro**, verificato per identità byte-a-byte dell'output su ogni script migrato.

5. La pipeline

fetch_comune.py	SDMX ISTAT -> 11 tavole censuarie comunali	
build_sezioni.py	file regionale -> {comune}_sezioni_2023.csv	
join_civici_sezioni.py	ANNCSU + shapefile -> civili agganciati alle sezioni	
build_zona_tables.py	sezioni -> Z1..Z4, Z6 al livello ASC scelto	
build_constraints.py	tavole -> constraint set (blocchi c1..c10)	
cs_build.py	-> supporto X + vincoli (cs_K9C.json)	
fit_cs.py	-> MaxEnt esatto -> popolazione_K9C.csv	
assign_nationality.py	-> + paese	anello 2
assign_avq.py	-> + 9 variabili AVQ	
enrich.py	-> + sezione, area, eta_anni, indirizzo, lon/lat	
		anello 3

Anello 1 (MaxEnt). Massima entropia con vincoli censuari, solver esatto (L-BFGS su matrice sparsa). Il quartiere è il livello più fine a cui il censimento pubblica gli *incroci* necessari. $|X| = 161.280 \times n_{\text{zone}}$. $\text{MRE}(\alpha > 0) \approx 4 \cdot 10^{-4}$, indipendente da $|X|$ su tre ordini di grandezza.

Anello 2 (condizionali). Attributi non censuari iniettati post-hoc.

Anello 3 (risoluzione fine). Sotto il quartiere esistono solo marginali di sezione, sfruttati come condizionali. Allocazione esatta (largest remainder) a ogni stadio, mai campionamento multinomiale.

Perché l'allocazione esatta conta

MAE della popolazione per sezione: **1,4-1,6** su medie di 109-175 abitanti. Un campionamento multinomiale darebbe $\approx 9,6$. Il fattore 6,6 viene dall'allocazione esatta dentro ogni gruppo; il residuo è l'accumulo di arrotondamenti su una trentina di gruppi per sezione, quindi **non cresce con la popolazione**.

Copertura regionale

`join_civici_sezioni.py` è generico per regione:

```
bash

python scripts/join_civici_sezioni.py emilia_romagna
python scripts/join_civici_sezioni.py lombardia
python scripts/join_civici_sezioni.py puglia
```

Il bounding box di validità delle coordinate è derivato dallo shapefile, i codici provincia dai dati, i nomi da `G.PROVINCE_NOMI`. Un contatore segnala i civili che ANNCSU attribuisce a un

comune ma che cadono geometricamente in sezioni di un altro (42 a Brescia, 14 a Parma, 0 a Bologna): vengono scartati a valle.

6. Condizionale geografico del paese — sistema a tier

Stato: costruito e validato, NON ancora collegato a `enrich.py`. I file `_full.csv` attuali hanno `paese` condizionato al solo `(area, sesso)` comunale, come da assunzione (4).

Diversi comuni pubblicano la cittadinanza a livello sub-comunale, con risoluzione molto diversa. Il modulo `opendata_paese.py` li normalizza in un formato unico.

tier	livello	fonte	comune
0	comune	solo censimento	default, ogni comune nuovo
1	quartiere	33 CSV, senza sesso, ~19 paesi + residuale	Brescia
2	zona	parquet con sesso, 155 paesi	Bologna
3	sezione	microdati individuali, 147 paesi	Parma

Formulazione

Le fonti locali sono **anagrafiche** e di data diversa dal censimento (Bologna 1/1/2024, Parma 1/1/2025, Brescia non dichiarata). Se ne usa la **forma**, non i livelli:

seed	$T_0(p,s,g)$	= struttura locale
margin 1	somma_g	$T(p,s,g)$ = censimento comunale (paese, sesso)
margin 2	somma_ps	$T(p,s,g)$ = popolazione straniera censuaria di g

Due margini censuari con lo stesso totale: sistema sempre risolubile, IPF converge in 9-88 iterazioni con scarto $\sim 1e-11$. Imporre anche i conteggi locali renderebbe i margini incompatibili (l'anagrafe conta 40.090 stranieri a Brescia, il censimento 37.478) e l'IPF non convergerebbe.

Il gruppo residuale entra nel seed: la sua massa si distribuisce sui paesi non nominati *in quel geo* proporzionalmente alla quota nazionale. Per Brescia il residuale cambia contenuto da quartiere a quartiere — è il complemento della top-19 locale — e l'IPF lo gestisce senza inventare informazione.

Con la fonte assente il seed è la sola quota nazionale replicata ovunque, e il risultato coincide **esattamente** con il tier 0.

Riconciliazione delle denominazioni

Quattro vocabolari diversi, riconciliati da (G.SINONIMI_PAESE) (tabella nazionale, unica per tutte le città) e (G.NON_PAESI):

	agganciati	residuo
Brescia	89,2%	4.346 = (ALTRE CITTADINANZE), tetto strutturale della fonte
Bologna	100,0%	7 persone in paesi assenti dal censimento
Parma	100,0%	13 persone

(G.AGGREGATI_PAESE) elenca i codici che **non** sono paesi. Il filtro va fatto per esclusione e non per forma del codice: i paesi hanno di norma un ISO alpha-2, ma non sempre ((X95) Kosovo, (XSD_S) Sud Sudan), e alcuni aggregati **hanno** forma alpha-2 — in particolare (EU) (Unione europea), che è la somma dei 27 già presenti singolarmente e gonfiava il margine censuario del 21%.

Quanto porta la geografia

Distanza in variazione totale fra la composizione per paese di ciascuna unità e quella comunale, pesata per popolazione. Il valore grezzo **non è confrontabile fra tier**: cresce meccanicamente al calare della numerosità di cella. Va rapportato alla stessa metrica sotto ipotesi nulla (composizione comunale, stesse numerosità).

	unità	stranieri/unità	osservata	nulla	eccesso
Bologna	18 zone	3.275	0,179	0,068	2,64
Brescia	33 quartieri	1.136	0,188	0,102	1,85
Parma	1.357 sezioni	30	0,569	0,447	1,27

Sulle distanze grezze Parma sembra tre volte più informativa; sull'eccesso è l'ultima. Il suo 0,569 è per il 79% discretizzazione: 30 stranieri su 146 nazionalità producono composizioni estreme anche in assenza di segregazione.

Questo non rende l'assegnazione di Parma peggiore: la tabella (T) incorpora la struttura vera a livello di sezione, e l'IPF applica già lo shrinkage corretto verso la composizione comunale nelle celle rade. La metrica aggregata non sa distinguere segnale da discretizzazione, ed è un limite della metrica, non del condizionale.

Principio, seconda occorrenza nel progetto: una metrica che scala con la numerosità di cella non è confrontabile fra configurazioni diverse. Vale per la distanza compositiva

come per il pavimento MRE del PCD (vedi `nota_mre_floor_v01.tex`).

I microdati di Parma: condizionale o validazione

I microdati anagrafici di Parma (202.111 righe, una per residente) contengono `SEZ21`, `Cittad`, `ETA`, `Sesso`, `Ncomp` (ampiezza del nucleo) e `Relpar` (relazione di parentela). `SEZ21_ID = "34027" + SEZ21.zfill(7)`, con aggancio al 99,9% degli individui.

Vanno separati **per variabile**, altrimenti si valida il modello contro i dati che lo hanno generato:

uso	variabili
condizionale	<code>Cittad × SEZ21 × Sesso</code>
validazione esterna, mai usate per generare	<code>ETA × SEZ21</code> ; <code>Ncomp</code> , <code>Relpar</code> ; co-occorrenza di nazionalità nella stessa sezione; <code>Tipores</code>

È l'unica occasione di **validazione esterna vera** che il progetto abbia: finora si è verificata solo la coerenza interna, cioè che la popolazione riproduca i vincoli imposti.

7. Limiti e assunzioni dichiarate

Assunzioni di indipendenza condizionale

n.	assunzione	dove
(4)	`paese ⊥ geografia	(area, sesso)`
(6)	`target AVQ ⊥ tutto	(sesso, macroetà, istruzione4, regione)`
(8)	`sezione ⊥ (istruzione, condizione, background)	(zona, sesso, età3, cittadinanza)`
(9)	entro il quinquennio, l'età segue la distribuzione comunale per anno singolo	anello 3
(10)	l'indirizzo è uniforme fra i civici della sezione	anello 3
(11)	nessuna struttura familiare	anello 3 — attaccabile con i microdati di Parma

Limiti della risoluzione per età

- L'istruzione ha risoluzione effettiva di 4 classi d'età, non 8. Il vincolo censuario usa `Y9-24`, `Y25-49`, `Y50-64`, `Y_GE65`. Dentro ogni classe la distribuzione è ottenuta per

IPF con soglie minime di conseguimento (`elementare` 10, `media` 13, `diploma` 18, `laurea_o_its` 20, `post_laurea` 22): i margini censuari sono preservati e le combinazioni impossibili azzerate. *Prima della correzione del 29/07/2026 il 32,8% dei 9-14enni risultava diplomato o laureato: il MaxEnt applicava alla classe `y9-24` una distribuzione uniforme per età.*

- **Resta sovrastimata `media` nel bin `9-14`:** la licenza media si consegue a 14 anni, quindi riguarda circa un sesto del bin.
- **Effetto coorte perso fra `65-74` e `75+`:** `Y_GE65` li rende indistinguibili.
- **Il background migratorio ha risoluzione di zona,** non di sezione.

Convenzioni per "assente" — non uniformate

forma	dove
<code>non_applicabile</code> (stringa)	<code>condizione</code> , <code>origine_genitori</code> , 8 delle 9 AVQ
<code>NaN</code>	<code>area</code> , <code>via</code> , <code>civico</code>
nessuna	<code>SALUTE</code> , <code>paese</code> (= <code>Italia</code> per gli italiani)

`non_applicabile` è a volte una **categoria sostantiva** (la condizione professionale degli under-15) e a volte un **missing** (il `BMIMIN` degli adulti).

8. Punti aperti

- **Collegare i tier a `enrich.py`.** `opendata_paese.tabella_paese()` restituisce `T(paese, sesso, geo)`; va sostituita a `tab_paesi()`, con il paese ristretto ai paesi dell'`area` già assegnata dalla sezione, e le tre popolazioni rigenerate.
- **Codebook AVQ.** `AMBIENTE` e `CPESO` non sono note.
- **`FIDUCIA` potrebbe essere il costrutto sbagliato.** Binaria con ~28% di positivi: è il profilo della **fiducia interpersonale generalizzata**, non della fiducia istituzionale — che è il costrutto centrale per la comunicazione del rischio. Da verificare sul codebook; in alternativa aggiungere le variabili AVQ di fiducia istituzionale, o passare a ESS.
- **Struttura familiare.** `Ncomp` e `Relpar` dei microdati di Parma, più `cens_posizione_famiglia` (scaricata e mai usata) per gli altri comuni.
- **Convivenze.** Riprodotte con scarto $\pm 2-5\%$, il peggiore fra tutte le celle: un tilt moltiplicativo su classi larghe fatica su un profilo così estremo.
- **K10C.** Esiste solo per Brescia, con `settore` come decimo attributo, e porta ancora l'istruzione **pre-correzione**: va rigenerato se usato.
- **San Vito dei Normanni (`074017`):** registrato, civici presenti, file sezioni non ancora generato. `COM_ASC1` ha un solo valore, quindi resterà un comune **senza articolazione**

zonale ("livello": None)).

9. Dove sono i dati reali, per il confronto

```
{COMUNE}/constraints_2024/
  cs_K9C.json          vincoli con alpha target, categories, domain_sizes,
                       zona_nomi. E' la verita' di riferimento dell'anello
1.
  targets_K9C.json     tabelle target per blocco (A, B, C, D, E, F, S...)
  fit_K9C.json         lambdas, MRE, entropia, supporto
  manifest.json        fonte e tipo (hard/soft) di ogni blocco

{COMUNE}/zona_2023/
  z1..z4, z6, zona_nomi  marginali censuarie per zona

data/submun/{slug}_sezioni_2023.csv
  verita' per sezione: P1 (popolazione), ST1 (stranieri), ST16/ST19
  (UE/extra-UE), P30-P45 e P67-P82 (sesso x quinquennio),
  ST25-ST30 (stranieri per sesso x eta3)

data/opendata/{COMUNE}/
  fonti comunali per il condizionale geografico del paese (§6)
```

Estrazione degli α target:

```
python

import json, os, sys
sys.path.insert(0, os.path.expanduser("~/progetti/gsp/scripts"))
import gsp_common as G
cs = json.load(open(os.path.join(G.path_constraints("034027", 2024),
                                "cs_K9C.json")))
vars_, cats = cs["vars"], cs["categories"]
# ogni vincolo: {'attrs': [indici di vars_], 'vals': [indici di cats], 'alpha':
```

Geometrie per la visualizzazione

```
data/geodata/{regione}/R{NN}_21/SHP/R{NN}_21_WGS84.shp
  R03 Lombardia    R08 Emilia-Romagna    R16 Puglia
  CRS: EPSG:32632 – riproiettare a EPSG:4326 per il web
```

Lo shapefile contiene le colonne `COM_ASC1/2/3`, quindi i **poligoni delle zone si ottengono per dissolve delle sezioni**, senza uno shapefile ASC separato:

python

```
import geopandas as gpd, sys, os
sys.path.insert(0, os.path.expanduser("~/progetti/gsp/scripts"))
import gsp_common as G

col = G.livello_col("034027")
s = gpd.read_file(G.path_shp("emilia_romagna"))
s = s[s.PRO_COM == G.procom("034027")]
zone = s.dissolve(by=col).reset_index().to_crs("EPSG:4326")
zone["nome"] = zone[col].astype("Int64").astype(str).map(G.zona_nomi("034027"))
```

Per Bologna `G.livello_col("037006")` è `COM_ASC2`: un dissolve su `COM_ASC1` darebbe 6 poligoni invece di 18, e i codici — che si sovrappongono fra livelli (§3.1) — mapperebbero comunque su dei nomi, sbagliati.

Attenzione: lo shapefile regionale contiene **più sezioni** del file dati 2023 (quelle senza popolazione residente pubblicata). Il collegamento su `SEZ21_ID` è però completo: tutte le sezioni dei dati 2023 hanno geometria.

10. Riepilogo numerico

	Brescia	Parma	Bologna
codice ISTAT	017029	034027	037006
regione (AVQ)	Lombardia (30)	Emilia-Romagna (80)	Emilia-Romagna (80)
popolazione	198.259	198.121	390.098
zone	33 (ASC1)	13 (ASC1)	18 (ASC2)
sezioni	1.822	1.357	2.224
sezioni occupate	1.774	1.313	2.152
civici ANNCSU	49.730	35.826	77.595
stranieri (censimento)	37.478	34.436	58.963
quota stranieri	18,9%	17,4%	15,1%
donatori AVQ	8.111	4.629	4.629
riuso medio donatore	24×	43×	84×
supporto X K9C	5.322.240	2.096.640	2.903.040
tier paese (§6)	1	3	2

Il riuso dei donatori è un tetto strutturale: nella popolazione di Bologna esistono al massimo 4.629 vettori psicografici distinti, indipendentemente dai 390.098 individui. La diversità dell'anello 2 è limitata dalla taglia del campione AVQ regionale, non dalla popolazione.

Validazione per sezione

	sezioni	MAE pop.	corr	MAE stranieri	corr
Brescia	1.822	1,58	0,9998	0,98	0,9990
Parma	1.357	1,45	0,9999	1,12	0,9985
Bologna	2.224	1,36	0,9999	1,11	0,9982

I totali comunali coincidono esattamente con il censimento. Gli scarti sui totali di stranieri (+53, +74, +54) sono entro 0,5 σ del rumore multinomiale di estrazione della popolazione,

non dell'anello 3.

Struttura spaziale: la sezione conta molto più della zona

Decomposizione della varianza della quota UE fra stranieri, al netto della discretizzazione dei piccoli conteggi:

	var tra zone	var reale dentro	sovradisersione	rapporto
Brescia (33 zone)	0,00168	0,00991	2,89×	5,9×
Parma (13 zone)	0,00110	0,01249	3,50×	11,3×
Bologna (18 zone)	0,00072	0,01124	3,04×	15,7×

Condizionare sul quartiere perde l'85-94% del segnale compositivo. Il risultato è monotono nella dimensione media delle zone ed è confermato su tre partizioni diverse.

Validazione esterna puntuale

L'unico confronto finora eseguito contro fonti indipendenti:

	fonte comunale	sintetico (cens. 2023)	rapporto
Primo Maggio (Brescia), quota stranieri	0,329	0,293	1,12
Bologna, quota UE fra stranieri	0,214	0,213	1,00

Un fatto rilevante per il progetto Caffaro

Classifica di Brescia per quota di stranieri:

Fiumicello	0,368	Buffalora	0,088
Centro Storico Nord	0,314	Villaggio Violino	0,073
Primo Maggio	0,293		

Fiumicello, uno dei due quartieri della **ZonaCaffaro**, è quello con la più alta quota di stranieri della città — il doppio della media comunale. Lingua, canali informativi e fiducia nelle istituzioni sono fortemente differenziati su quell'asse, ma l'anello 2 condiziona **FIDUCIA** e **AMBIENTE** su sesso, età e istruzione e **non** su cittadinanza: oggi la popolazione sintetica di Fiumicello ha attitudini indistinguibili da quelle di Mompiano a parità di profilo demografico.

Changelog

v1.1 — 29/07/2026 Consolidamento in `gsp_common.py`, eseguito come refactor puro e verificato per identità byte-a-byte su ogni script migrato. Correzione dei nomi delle zone di Bologna (§3.2) e dell'istruzione nei bin infantili (§7). Sistema a tier per il condizionale geografico del paese, costruito e validato ma non ancora collegato (§6).

`join_civici_sezioni.py` generalizzato a tre regioni. Nuove sezioni: §3.1 codici ASC sovrapposti, §4 modulo comune, §6 tier.

v1.0 — 28/07/2026 Prima stesura.

Le cifre di validazione dell'anello 3 (MAE, quote di `indirizzo_fonte`, decomposizione della varianza) provengono dalle esecuzioni del 28 luglio 2026, precedenti la correzione dell'istruzione e dei nomi di Bologna. Le costanti strutturali non cambiano; i MAE possono differire nell'ultima cifra. Rileggere i log più recenti per i valori aggiornati.