

Popolazioni sintetiche GSP — documento di riferimento

Versione 1.2 — 29 luglio 2026 Descrive i file `popolazione_K9C_avq_full.csv` per Brescia, Parma e Bologna: come caricarli, cosa contengono, come sono stati costruiti, quali limiti dichiarati portano con sé e dove trovare i dati reali per il confronto.

Novità rispetto alla v1.1: il condizionale geografico del paese di cittadinanza è **collegato e attivo** su tutte e tre le città (§6); §10 riporta i numeri delle esecuzioni correnti; aggiunta la §11 sul principio dell'ipotesi nulla.

1. I file

```
~/progetti/gsp/data/comuni/{COMUNE}/constraints_2024/popolazione_K9C_avq_full.c
```

comune	codice	individui	attributi
Brescia	017029	198.259	28
Parma	034027	198.121	28
Bologna	037006	390.098	28

Totale 786.478 individui sintetici, ciascuno con indirizzo civico e coordinate geografiche.

Caricamento

Ci sono tre trappole di tipo. Questo snippet le gestisce tutte:

```
python
```

```
import pandas as pd, os

def carica(comune, anno=2024):
    f = os.path.expanduser(
        f"~/progetti/gsp/data/comuni/{comune}/constraints_{anno}/"
        f"popolazione_K9C_avq_full.csv")
    p = pd.read_csv(f, low_memory=False, dtype={
        "zona": "string",      # 34027001: NON leggere come int
        "sezione": "string",   # 340270000994: 12 cifre
        "civico": "string",    # '19A': numero + esponente
    })
    for c in ["AMBIENTE", "FIDUCIA", "SALUTE", "CRONI", "FUMO",
              "MH", "BMI", "BMIMIN", "CPESO"]:
        p[c + "_num"] = pd.to_numeric(p[c], errors="coerce")
    return p
```

In alternativa, tutti i percorsi e i registri stanno in `gsp_common.py` (§4):

```
python

import sys, os
sys.path.insert(0, os.path.expanduser("~/progetti/gsp/scripts"))
import gsp_common as G
f = os.path.join(G.path_constraints("034027", 2024),
                 "popolazione_K9C_avq_full.csv")
```

Trappole:

1. `zona` e `sezione` sono codici, non numeri. Letti come `int64` funzionano ma perdono la natura di chiave; letti come `float` diventano notazione scientifica.
2. Le nove variabili AVQ sono **stringhe** perché mescolano codici numerici e `non_applicabile` — tranne `SALUTE`, che è `int64` perché è l'unica senza missing strutturali.
3. `area` usa `NaN` per gli italiani, non `non_applicabile`. Le convenzioni per "assente" sono tre e non sono state uniformate (§7).

2. Gli attributi

2.1 Anello 1 — MaxEnt (vincolati)

Dieci attributi le cui marginali e incroci riproducono il constraint set censuario con $MRE \approx 4 \cdot 10^{-4}$.

colonna	modalità	note
zona	codice a 8 cifre	quartiere o zona statistica, §3
quartiere	stringa	denominazione della zona
sezzo	M, F	
eta	0-8, 9-14, 15-24, 25-34, 35-49, 50-64, 65-74, 75+	bin del constraint set
stato_civile	celibe_nubile, coniugato_unito, divorziato_sciolto, vedovo	unioni civili collassate in coniugato_unito
cittadinanza	ITL, FRG	giuridica; FRG include gli apolidi (= FRGAPO) SDMX = ST1 sezioni)
istruzione	nessun_titolo, elementare, media, diploma, laurea_o_its, post_laurea	laurea_o_its = triennale + ITS; post_laurea = magistrale + ciclo unico + dottorato
condizione	occupato, in_cerca, studente, casalinga, percettore_pensioni, altra_condizione, non_applicabile	non_applicabile = under 15 (categoria sostantiva)
background	italiano_nativo, italiano_rientrato, naturalizzato_g2, naturalizzato_immigrato, straniero_g2, straniero_immigrato	background migratorio: non coincide con cittadinanza
origine_genitori	entrambi_italiani, madre_italiana_padre_straniero, madre_straniera_padre_italiano, entrambi_stranieri, non_applicabile	

Metà delle 30 combinazioni (background × origine_genitori) è logicamente impossibile ed è esclusa dal supporto per costruzione.

2.2 Anello 2 — condizionali post-hoc

colonna	modalità	fonte
<code>area</code>	<code>UE</code> , <code>EXTRA_UE</code> , <code>NaN</code> (italiani)	<code>ST17/18/20/21</code> della sezione
<code>paese</code>	143-151 paesi + <code>Italia</code>	censimento comunale × fonte comunale geografica (§6)
<code>AMBIENTE</code>	1-4 + <code>non_applicabile</code>	AVQ regionale
<code>FIDUCIA</code>	1-2 + <code>non_applicabile</code>	AVQ
<code>SALUTE</code>	1-5	AVQ, nessun missing
<code>CRONI</code>	1-2 + <code>non_applicabile</code>	AVQ
<code>FUMO</code>	1-3 + <code>non_applicabile</code>	AVQ
<code>MH</code>	continua 0-100 + <code>non_applicabile</code>	AVQ, indice SF-12 salute mentale
<code>BMI</code>	1-4 + <code>non_applicabile</code>	AVQ, adulti
<code>BMIMIN</code>	1-2 + <code>non_applicabile</code>	AVQ, solo minori (~13,6%)
<code>CPESO</code>	1-5 + <code>non_applicabile</code>	AVQ, percezione del peso

Le nove variabili AVQ arrivano in blocco dallo stesso donatore (hot-deck), quindi le correlazioni interne sono preservate per costruzione.

Il pool di donatori è **regionale**: 8.111 per la Lombardia, 4.629 per l'Emilia-Romagna. Il condizionamento è su `(sesso × macroetà × istruzione4)`, con collasso gerarchico progressivo (prima l'istruzione, poi l'età) quando la cella è rada. Su Parma il 94,8% resta al livello pieno, il 5,2% scende a `(sesso × macroetà)`, nessuno arriva al marginale regionale.

Universi diversi per variabile. `BMIMIN` copre il 13,6% della popolazione, `CRONI` il 93,8%, `SALUTE` il 100%. Non esiste un sottoinsieme di righe completo su tutte. Per le correlazioni usare `DataFrame.corr(min_periods=...)`, che fa cancellazione pairwise — un `dropna()` listwise su tutte e nove restituisce **zero righe** (`BMIMIN` e `FIDUCIA` hanno universi complementari).

Codifiche AVQ — stato di conoscenza. Inferite dai marginali, non lette dal codebook:

	inferenza	confidenza
SALUTE	1 = molto bene ... 5 = molto male	alta
FUMO	1 = fumatore, 2 = ex, 3 = mai	alta
BMI	1 = sottopeso ... 4 = obeso	alta
MH	SF-12, più alto = meglio	alta
CRONI	1 = nessuna, 2 = almeno una	media
BMIMIN	1 = normo/sotto, 2 = sovrappeso/obeso	media
AMBIENTE	scala a 4 punti, direzione ignota	bassa
CPESO	scala a 5 punti, costruito ignoto	bassa
FIDUCIA	binaria, ~28% positivi	da verificare, §8

2.3 Anello 3 — risoluzione fine

colonna	tipo	descrizione
sezione	codice a 12 cifre	sezione di censimento (SEZ21_ID), basi territoriali 2021)
eta_anni	0-100	età esatta in anni
via	stringa	odonimo ANNCSU
civico	stringa	numero + esponente (12 , 19A)
lon , lat	float, EPSG:4258	coordinate del civico ($\approx$ WGS84)
indirizzo_fonte	sezione / zona / convivenza	provenienza dell'indirizzo

indirizzo_fonte è la colonna di qualità:

	sezione	zona	convivenza
Brescia	197.511 (99,62%)	199	549
Parma	197.601 (99,74%)	39	481
Bologna	389.432 (99,83%)	36	630

- **sezione**: civico estratto dentro la sezione assegnata (caso normale);
- **zona**: la sezione è popolata ma priva di civici ANNCSU → civico preso altrove nel quartiere;
- **convivenza**: sezione fittizia (888888x) (senza tetto, convivenze anagrafiche). **Nessun indirizzo**, coordinate = centroide della zona. Profilo demografico anomalo: a Parma 80% maschi, 73% stranieri.

3. Livello territoriale — non è uniforme, e i codici si sovrappongono

ISTAT pubblica fino a tre livelli di sub-aree amministrative (`COM_ASC1/2/3`), ma disponibilità e cardinalità variano per comune. Il livello è **fissato nel registro di `gsp_common.py`**, non scelto da riga di comando.

comune	livello	zone	abitanti/zona	sezioni
Brescia	<code>COM_ASC1</code> (quartieri)	33	6.008	1.822
Parma	<code>COM_ASC1</code> (quartieri)	13	15.240	1.357
Bologna	<code>COM_ASC2</code> (zone statistiche)	18	21.672	2.224

Bologna usa ASC2 perché i suoi 6 quartieri ASC1 sono troppo pochi; ASC3 (90 aree) è inutilizzabile per la coda di zone minuscole (la più piccola ha 13 abitanti). Parma pubblica solo ASC1.

Conseguenza per il confronto: la granularità zonale non è comparabile fra le tre città (fattore 3,6 fra Brescia e Bologna).

3.1 I codici ASC si sovrappongono fra livelli

I livelli sono numerati **indipendentemente**. A Bologna `COM_ASC1` va da `37006011` a `37006016` e `COM_ASC2` da `37006001` a `37006018`: sei codici esistono a entrambi i livelli con significati diversi.

```
37006011  come ASC1 -> Borgo Panigale-Reno  (quartiere, 61.149 ab.)
37006011  come ASC2 -> Marconi                (zona statistica, 14.687 ab.)
```

Il codice da solo non identifica la zona: l'informazione sta nella colonna da cui proviene. Un merge sul solo codice riesce e restituisce il nome sbagliato, senza errori né valori mancanti. La guardia `G.verificalivello()` intercetta il caso in cui i codici di una popolazione non appartengano al livello atteso.

3.2 Incidente: i nomi delle zone di Bologna erano errati

Fino al 29/07/2026 il dizionario `codice → nome` di Bologna era **permutato**: 16 codici su 18 portavano il nome di un'altra zona. Nessun controllo strutturale poteva vederlo — una permutazione resta una biiezione perfetta — e la gerarchia zona→quartiere, costruita a mano sopra quei nomi, era coerente con sé stessa.

L'errore è emerso quando il consolidamento ha sostituito la mappa cablata con una **derivata dalle sezioni**, e le due hanno divergato. L'identificazione ha usato due vincoli indipendenti che concordano: la struttura della gerarchia (gruppi di taglia 3, 3, 4, 2, 4, 2, che si sovrappongono in un solo modo) e i conteggi di stranieri per zona degli open data comunali (rapporto anagrafe/censimento ~1,05 costante).

I codici ASC2 di Bologna seguono l'**ordine alfabetico** dei nomi, ignorando gli spazi (per questo `San Ruffillo`, `Santa Viola`, `San Vitale` finiscono in quell'ordine).

Lezione operativa: le denominazioni delle zone vanno verificate contro una fonte esterna prima di fidarsene. I dati numerici erano tutti corretti — popolazione, stranieri, varianze, MAE — perché calcolati sui codici; sbagliate erano solo le etichette leggibili, cioè esattamente ciò che finisce in mappe e tabelle.

Quartieri di Parma

```
34027001 Parma Centro      34027006 San Pancrazio      34027011 Cittadella
34027002 Oltretorrente     34027007 San Leonardo      34027012 Montanara
34027003 Molinetto         34027008 Cortile San Martino 34027013 Vigatto
34027004 Pablo             34027009 Lubiana
34027005 Golese            34027010 San Lazzaro
```

Le denominazioni di Brescia e Bologna stanno in `gsp_common.py` (`ASC_NOMI_BRESCIA`, `ASC1_NOMI_BOLOGNA`, `ASC2_NOMI_BOLOGNA`).

4. `gsp_common.py` — registro e primitive condivise

Consolida i cinque registri di comuni che erano duplicati in altrettanti script. Principio: nel registro sta **solo ciò che non è derivabile**; il codice ISTAT contiene già provincia e comune, e

i percorsi sono formule.

python

```
import gsp_common as G

G.info("034027")          # voce di registro
G.procom("034027")        # 34027
G.cod_prov("034027")      # "034"
G.cod_avq("034027")       # 80   (codice REGMf nei microdati AVQ)
G.livello_col("037006")   # "COM_ASC2"
G.zona_nomi("037006")     # {codice: nome} del livello in uso
G.path_sezioni("034027")  # ../submun/parma_sezioni_2023.csv
G.path_civici("034027")   # ../034_parma_civici_sezioni_asc.csv
G.path_constraints("034027", 2024)
G.largest_remainder(n, pesi) # allocazione esatta
G.norm_code(serie, comune)  # codice zona -> chiave normalizzata
G.norm_nome("S. Leonardo")  # "sleonardo"
G.paesi_censuari("034027")  # {nome normalizzato: codice ISO}
G.etichette_paese("034027") # {codice ISO: etichetta ISTAT}
G.risolvi_paese(etichetta, rif) # etichetta locale -> codice censuario
G.EU27_ISO                # 27 codici ISO alpha-2 dell'Unione
```

Self-test contro i file su disco:

bash

```
python scripts/gsp_common.py --check
python scripts/gsp_common.py --dump-nomi 037006 # nomi zona da zona_2023/
```

Verifica per ogni comune: file sezioni presente, numero di zone al livello dichiarato uguale a quello atteso, corrispondenza biunivoca codici↔nomi, presenza dei civici e delle directory di lavoro.

Il consolidamento è stato eseguito come **refactor puro**, verificato per identità byte-a-byte dell'output su ogni script migrato.

5. La pipeline

fetch_comune.py	SDMX ISTAT -> 11 tavole censuarie comunali	
build_sezioni.py	file regionale -> {comune}_sezioni_2023.csv	
join_civici_sezioni.py	ANNCSU + shapefile -> civili agganciati alle sezioni	
build_zona_tables.py	sezioni -> Z1..Z4, Z6 al livello ASC scelto	
build_constraints.py	tavole -> constraint set (blocchi c1..c10)	
cs_build.py	-> supporto X + vincoli (cs_K9C.json)	
fit_cs.py	-> MaxEnt esatto -> popolazione_K9C.csv	
assign_nationality.py	-> + paese (comunale)	anello 2
assign_avq.py	-> + 9 variabili AVQ	
enrich.py	-> + sezione, area, paese (geografico),	
usa_opendata_paese.py	eta_anni, indirizzo, lon/lat	anello 3

Anello 1 (MaxEnt). Massima entropia con vincoli censuari, solver esatto (L-BFGS su matrice sparsa). Il quartiere è il livello più fine a cui il censimento pubblica gli *incroci* necessari. $|X| = 161.280 \times n_{\text{zone}}$. $\text{MRE}(\alpha > 0) \approx 4 \cdot 10^{-4}$, indipendente da $|X|$ su tre ordini di grandezza.

Anello 2 (condizionali). Attributi non censuari iniettati post-hoc. `assign_nationality.py` assegna un `paese` provvisorio a livello comunale; `enrich.py` lo **ri-assegna** con il condizionale geografico (§6).

Anello 3 (risoluzione fine). Sotto il quartiere esistono solo marginali di sezione, sfruttati come condizionali. Allocazione esatta (largest remainder) a ogni stadio, mai campionamento multinomiale.

Perché l'allocazione esatta conta

MAE della popolazione per sezione: **1,36-1,58** su medie di 109-175 abitanti. Un campionamento multinomiale darebbe $\approx 9,6$. Il fattore $\sim 6,5$ viene dall'allocazione esatta dentro ogni gruppo; il residuo è l'accumulo di arrotondamenti su una trentina di gruppi per sezione, quindi **non cresce con la popolazione**.

Copertura regionale

`join_civici_sezioni.py` è generico per regione:

```
bash

python scripts/join_civici_sezioni.py emilia_romagna
python scripts/join_civici_sezioni.py lombardia
python scripts/join_civici_sezioni.py puglia
```

Bounding box derivato dallo shapefile, codici provincia ricavati dai dati, nomi da `G.PROVINCE_NOMI`. Un contatore segnala i civici che ANNCSU attribuisce a un comune ma che cadono geometricamente in sezioni di un altro (42 a Brescia, 14 a Parma, 0 a Bologna): scartati a valle.

6. Condizionale geografico del paese — attivo

Il censimento pubblica la cittadinanza di dettaglio solo a livello comunale. Diverse amministrazioni la pubblicano a livello sub-comunale, con risoluzione molto diversa; `opendata_paese.py` le normalizza e `enrich.py` le usa per assegnare `paese`.

tier	livello	fonte	comune
0	comune	solo censimento	default, ogni comune nuovo
1	quartiere	33 CSV, senza sesso, ~19 paesi + residuale	Brescia
2	zona	parquet con sesso, 155 paesi	Bologna
3	sezione	microdati individuali	Parma

Il flag `--no-tier` di `enrich.py` ripristina il comportamento comunale, ed è quello con cui è stato prodotto il confronto qui sotto.

Copertura: 100% dalla geografia su tutte e tre le città, zero fallback. Non è fortuna: il peso di sezione per gli stranieri è $P \times q$ con $q = ST/P$, quindi nessuno straniero può atterrare dove il censimento non ne conta, e le celle della tabella sono sempre popolate.

Formulazione

Le fonti locali sono **anagrafiche** e di data diversa dal censimento (Bologna 1/1/2024, Parma 1/1/2025, Brescia non dichiarata). Se ne usa la **forma**, non i livelli:

seed	$T0(p,s,g)$	=	struttura locale
margin 1	somma_g	$T(p,s,g)$	= censimento comunale (paese, sesso)
margin 2	somma_ps	$T(p,s,g)$	= popolazione straniera censuaria di g

Due margini censuari con lo stesso totale: sistema sempre risolubile, IPF converge in 9-88 iterazioni con scarto $\sim 1e-11$. Imporre anche i conteggi locali renderebbe i margini incompatibili (l'anagrafe conta 40.090 stranieri a Brescia, il censimento 37.478) e l'IPF non convergerebbe.

Il gruppo residuale entra nel seed: la sua massa si distribuisce sui paesi non nominati *in quel geo* proporzionalmente alla quota nazionale. Per Brescia il residuale cambia contenuto

da quartiere a quartiere — è il complemento della top-19 locale — e l'IPF lo gestisce senza inventare informazione.

Con la fonte assente il seed è la sola quota nazionale replicata ovunque, e il risultato coincide **esattamente** con il tier 0.

In assegnazione, `[area]` viene prima ed è già a risoluzione di sezione; `[paese]` è poi estratto dai soli paesi di quell'area (`[G.EU27_ISO]` per codice ISO, non per etichetta), con allocazione esatta.

Riconciliazione delle denominazioni

Quattro vocabolari diversi, riconciliati da `[G.SINONIMI_PAESE]` (tabella nazionale, unica per tutte le città) e `[G.NON_PAESI]`:

	agganciati	residuo
Brescia	89,2%	4.346 = <code>[ALTRE_CITTADINANZE]</code> , tetto strutturale della fonte
Bologna	100,0%	7 persone in paesi assenti dal censimento
Parma	100,0%	13 persone

`[G.AGGREGATI_PAESE]` elenca i codici che **non** sono paesi. Il filtro va fatto per esclusione e non per forma del codice: i paesi hanno di norma un ISO alpha-2, ma non sempre (`[X95]` Kosovo, `[XSD_S]` Sud Sudan), e alcuni aggregati **hanno** forma alpha-2 — in particolare `[EU]` (Unione europea), che è la somma dei 27 già presenti singolarmente e gonfiava il margine censuario del 21%.

Quanto porta la geografia

Frazione di stranieri sintetici che cambia nazionalità passando dal condizionale comunale a quello geografico, in distanza di variazione totale. Confrontata con la stessa quantità sotto **ipotesi nulla** (due permutazioni indipendenti della stessa popolazione: nessuna struttura geografica, stesse numerosità di cella).

	--	osservata	nulla	eccesso
Brescia	per quartiere	0,197	0,094	2,08
	per sezione	0,408	0,393	1,04
Parma	per quartiere	0,156	0,074	2,10
	per sezione	0,530	0,412	1,29
Bologna	per quartiere	0,169	0,066	2,57
	per sezione	0,421	0,417	1,01

Tre letture.

A livello di quartiere l'informazione è sostanziale e simile ovunque: tutte e tre spostano circa 2,1-2,6 volte quanto si sposterebbe per caso. In termini concreti, ~7.400 stranieri sintetici di Brescia, ~5.400 di Parma e ~10.000 di Bologna hanno una nazionalità diversa da prima, e il cambiamento è informativo.

Una fonte povera ma geograficamente risolta vale quanto una ricca. Brescia (19 paesi nominati più un residuo del 10,8%, senza sesso) ottiene 2,08 contro il 2,57 di Bologna (155 paesi con sesso). Per i comuni futuri è la conclusione operativa: basta una tabella $\boxed{\text{paese} \times \text{quartiere}}$, anche troncata alle prime venti nazionalità.

Brescia e Bologna a livello di sezione danno 1,04 e 1,01, cioè nulla — correttamente, perché il loro condizionale si ferma alla zona. Questo **valida la metrica per via negativa**: l'ipotesi nulla predice entro l'1-4% il comportamento di due sistemi che sappiamo privi di quel segnale. Il 1,29 di Parma è quindi l'unico eccesso reale sotto il quartiere, ed è la misura di ciò che i microdati individuali aggiungono.

Il tier 3 non ripaga la complessità in aggregato: quasi tutto il guadagno di Parma è già catturato al livello di quartiere. Resta però migliore per il singolo individuo, ed è la risoluzione necessaria per qualunque analisi che incroci nazionalità e posizione fine (per esempio la distanza da un perimetro di contaminazione).

I microdati di Parma: condizionale o validazione

I microdati anagrafici di Parma (202.111 righe, una per residente) contengono $\boxed{\text{SEZ21}}$, $\boxed{\text{Cittad}}$, $\boxed{\text{ETA}}$, $\boxed{\text{Sesso}}$, $\boxed{\text{Ncomp}}$ (ampiezza del nucleo) e $\boxed{\text{Relpar}}$ (relazione di parentela). $\boxed{\text{SEZ21_ID} = "34027" + \text{SEZ21.zfill}(7)}$, con aggancio al 99,9% degli individui.

Vanno separati **per variabile**, altrimenti si valida il modello contro i dati che lo hanno generato:

uso	variabili
condizionale	$\text{Cittad} \times \text{SEZ21} \times \text{Sesso}$
validazione esterna, mai usate per generare	$\text{ETA} \times \text{SEZ21}$; Ncomp , Relpar ; co-occorrenza di nazionalità nella stessa sezione; Tipores

È l'unica occasione di **validazione esterna vera** che il progetto abbia: finora si è verificata solo la coerenza interna, cioè che la popolazione riproduca i vincoli imposti.

7. Limiti e assunzioni dichiarate

Assunzioni di indipendenza condizionale

n.	assunzione	dove
(4')	$\text{paese} \perp \text{tutto} \mid (\text{area}, \text{sezzo}, \text{geo})$ — con geo = quartiere, zona o sezione secondo il tier	nazionalità, §6
(6)	$\text{target AVQ} \perp \text{tutto} \mid (\text{sezzo}, \text{macroetà}, \text{istruzione4}, \text{regione})$	AVQ
(8)	$\text{sezione} \perp (\text{istruzione}, \text{condizione}, \text{background}) \mid (\text{zona}, \text{sezzo}, \text{età3}, \text{cittadinanza})$	anello 3
(9)	entro il quinquennio, l'età segue la distribuzione comunale per anno singolo	anello 3
(10)	l'indirizzo è uniforme fra i civici della sezione	anello 3
(11)	nessuna struttura familiare	anello 3 — attaccabile con i microdati di Parma

La (4') sostituisce la vecchia (4) $\text{paese} \perp \text{geografia} \mid (\text{area}, \text{sezzo})$. Per Brescia resta parzialmente in vigore sul 10,8% di stranieri che ricadono nella categoria $\text{ALTRE CITTADINANZE}$: per loro il paese è estratto dalla quota nazionale entro il gruppo residuale del proprio quartiere.

Limiti della risoluzione per età

- L'istruzione ha risoluzione effettiva di 4 classi d'età, non 8.** Il vincolo censuario usa Y9-24 , Y25-49 , Y50-64 , Y_GE65 . Dentro ogni classe la distribuzione è ottenuta per **IPF con soglie minime di conseguimento** (elementare 10, media 13, diploma 18, laurea_o_its 20, post_laurea 22): i margini censuari sono preservati e le

combinazioni impossibili azzerate. *Prima della correzione del 29/07/2026 il 32,8% dei 9-14enni risultava diplomato o laureato: il MaxEnt applicava alla classe (Y9-24) una distribuzione uniforme per età.*

- **Resta sovrastimata (media) nel bin (9-14):** la licenza media si consegue a 14 anni, quindi riguarda circa un sesto del bin.
- **Effetto coorte perso fra (65-74) e (75+):** (Y_GE65) li rende indistinguibili.
- **Il background migratorio ha risoluzione di zona,** non di sezione.

Convenzioni per "assente" — non uniformate

forma	dove
(non_applicabile) (stringa)	(condizione), (origine_genitori), 8 delle 9 AVQ
(NaN)	(area), (via), (civico)
nessuna	(SALUTE), (paese) (= (Italia) per gli italiani)

(non_applicabile) è a volte una **categoria sostantiva** (la condizione professionale degli under-15) e a volte un **missing** (il (BMIMIN) degli adulti).

8. Punti aperti

- **Codebook AVQ.** (AMBIENTE) e (CPESO) non sono note.
- (FIDUCIA) **potrebbe essere il costrutto sbagliato.** Binaria con ~28% di positivi: è il profilo della **fiducia interpersonale generalizzata**, non della fiducia istituzionale — che è il costrutto centrale per la comunicazione del rischio. Da verificare sul codebook; in alternativa aggiungere le variabili AVQ di fiducia istituzionale, o passare a ESS.
- **Provenienza del paese non tracciata.** Non esiste una colonna (paese_fonte) analoga a (indirizzo_fonte): oggi il tier è uniforme per comune (100% dalla geografia), ma se in futuro comparissero fallback andrebbe registrata.
- **Struttura familiare.** (Ncomp) e (Relpar) dei microdati di Parma, più (cens_posizione_famiglia) (scaricata e mai usata) per gli altri comuni.
- **Convivenze.** Riprodotte con scarto $\pm 2-5\%$, il peggiore fra tutte le celle: un tilt moltiplicativo su classi larghe fatica su un profilo così estremo.
- **K10C.** Esiste solo per Brescia, con (settore) come decimo attributo, e porta ancora l'istruzione **pre-correzione**: va rigenerato se usato.
- **San Vito dei Normanni ((074017)):** registrato, civici presenti, file sezioni non ancora generato. (COM_ASC1) ha un solo valore, quindi resterà un comune **senza articolazione zonale** ("livello": None).

- **Confronto fra città.** Le tre popolazioni usano condizionali di risoluzione diversa (tier 1, 2, 3) su partizioni di taglia diversa. Per un confronto rigoroso conviene rigenerarle a una risoluzione comune — il quartiere — dato che a quel livello gli eccessi sono simili (2,1-2,6).

9. Dove sono i dati reali, per il confronto

```
{COMUNE}/constraints_2024/  
    cs_K9C.json          vincoli con alpha target, categories, domain_sizes,  
                        zona_nomi. E' la verita' di riferimento dell'anello  
1.  
    targets_K9C.json     tabelle target per blocco (A, B, C, D, E, F, S...)  
    fit_K9C.json         lambdas, MRE, entropia, supporto  
    manifest.json        fonte e tipo (hard/soft) di ogni blocco  
  
{COMUNE}/zona_2023/  
    z1..z4, z6, zona_nomi    marginali censuarie per zona  
  
data/submun/{slug}_sezioni_2023.csv  
    verita' per sezione: P1 (popolazione), ST1 (stranieri), ST16/ST19  
    (UE/extra-UE), P30-P45 e P67-P82 (sesso x quinquennio),  
    ST25-ST30 (stranieri per sesso x eta3)  
  
data/opendata/{COMUNE}/  
    fonti comunali per il condizionale geografico del paese (§6)
```

Per rigenerare la versione senza condizionale geografico, utile ai confronti:

```
bash  
  
python scripts/enrich.py 037006 --anno 2024 --no-tier \  
    --out popolazione_K9C_avq_full_tier0.csv
```

Estrazione degli α target:

```
python
```

```
import json, os, sys
sys.path.insert(0, os.path.expanduser("~/progetti/gsp/scripts"))
import gsp_common as G
cs = json.load(open(os.path.join(G.path_constraints("034027", 2024),
                                     "cs_K9C.json")))
vars_, cats = cs["vars"], cs["categories"]
# ogni vincolo: {'attrs': [indici di vars_], 'vals': [indici di cats], 'alpha':
```

Geometrie per la visualizzazione

```
data/geodata/{regione}/R{NN}_21/SHP/R{NN}_21_WGS84.shp
R03 Lombardia    R08 Emilia-Romagna    R16 Puglia
CRS: EPSG:32632 – riproiettare a EPSG:4326 per il web
```

Lo shapefile contiene le colonne `COM_ASC1/2/3`, quindi **i poligoni delle zone si ottengono per dissolve delle sezioni**, senza uno shapefile ASC separato:

```
python

import geopandas as gpd, sys, os
sys.path.insert(0, os.path.expanduser("~/progetti/gsp/scripts"))
import gsp_common as G

col = G.livello_col("034027")
s = gpd.read_file(G.path_shp("emilia_romagna"))
s = s[s.PRO_COM == G.procom("034027")]
zone = s.dissolve(by=col).reset_index().to_crs("EPSG:4326")
zone["nome"] = zone[col].astype("Int64").astype(str).map(G.zona_nomi("034027"))
```

Per Bologna `G.livello_col("037006")` è `COM_ASC2`: un dissolve su `COM_ASC1` darebbe 6 poligoni invece di 18, e i codici — che si sovrappongono fra livelli (§3.1) — mapperebbero comunque su dei nomi, sbagliati.

Attenzione: lo shapefile regionale contiene **più sezioni** del file dati 2023 (quelle senza popolazione residente pubblicata). Il collegamento su `SEZ21_ID` è però completo: tutte le sezioni dei dati 2023 hanno geometria.

10. Riepilogo numerico

Esecuzioni del 29 luglio 2026, successive alla correzione dell'istruzione, dei nomi di Bologna e all'attivazione dei tier.

	Brescia	Parma	Bologna
codice ISTAT	017029	034027	037006
regione (AVQ)	Lombardia (30)	Emilia-Romagna (80)	Emilia-Romagna (80)
popolazione	198.259	198.121	390.098
zone	33 (ASC1)	13 (ASC1)	18 (ASC2)
sezioni	1.822	1.357	2.224
sezioni occupate	1.773	1.313	2.152
civici ANNCSU	49.730	35.826	77.595
di cui su base provinciale	415.456	128.366	315.505
stranieri (censimento)	37.478	34.436	58.963
stranieri (sintetici)	37.475	34.434	59.130
quota stranieri	18,9%	17,4%	15,1%
donatori AVQ	8.111	4.629	4.629
riuso medio donatore	24×	43×	84×
supporto X K9C	5.322.240	2.096.640	2.903.040
tier paese (§6)	1 (quartieri)	3 (sezione)	2 (zone)

Il riuso dei donatori è un tetto strutturale: nella popolazione di Bologna esistono al massimo 4.629 vettori psicografici distinti, indipendentemente dai 390.098 individui. La diversità dell'anello 2 è limitata dalla taglia del campione AVQ regionale, non dalla popolazione.

Validazione per sezione

	sezioni	media/sez	MAE pop.	corr	MAE stranieri	corr	MAE UE	corr
Brescia	1.822	108,8	1,58	0,9998	0,98	0,9989	0,13	0,9976
Parma	1.357	146,0	1,43	0,9999	1,13	0,9985	0,16	0,9980
Bologna	2.224	175,4	1,36	0,9999	1,08	0,9983	0,17	0,9982

I totali comunali coincidono esattamente con il censimento. Gli scarti sui totali di stranieri (−3, −2, +167) sono entro 0,7 σ del rumore multinomiale di estrazione della popolazione, non dell'anello 3.

Struttura spaziale: la sezione conta molto più della zona

Decomposizione della varianza della quota UE fra stranieri, al netto della discretizzazione dei piccoli conteggi. **Calcolata dal file sezioni**, cioè dalla verità censuaria: non dipende dalla popolazione sintetica ed è invariata dalla v1.0.

	var tra zone	var reale dentro	sovradisersione	rapporto
Brescia (33 zone)	0,00168	0,00991	2,89×	5,9×
Parma (13 zone)	0,00110	0,01249	3,50×	11,3×
Bologna (18 zone)	0,00072	0,01124	3,04×	15,7×

Condizionare sul quartiere perde l'85–94% del segnale compositivo. Il risultato è monotono nella dimensione media delle zone ed è confermato su tre partizioni diverse.

Validazione esterna puntuale

	fonte comunale	sintetico (cens. 2023)	rapporto
Primo Maggio (Brescia), quota stranieri	0,329	0,293	1,12
Bologna, quota UE fra stranieri	0,214	0,213	1,00

Un fatto rilevante per il progetto Caffaro

Classifica di Brescia per quota di stranieri:

Fiumicello	0,368	Buffalora	0,088
Centro Storico Nord	0,314	Villaggio Violino	0,073
Primo Maggio	0,293		

Fiumicello, uno dei due quartieri della **ZonaCaffaro, è quello con la più alta quota di stranieri della città** — il doppio della media comunale. Lingua, canali informativi e fiducia nelle istituzioni sono fortemente differenziati su quell'asse, ma l'anello 2 condiziona **FIDUCIA** e **AMBIENTE** su sesso, età e istruzione e **non** su cittadinanza: oggi la popolazione sintetica di Fiumicello ha attitudini indistinguibili da quelle di Mompiano a parità di profilo demografico.

11. Un principio metodologico ricorrente

Ogni metrica che scala con la numerosità di cella va rapportata alla propria ipotesi nulla prima di essere confrontata fra configurazioni diverse.

Il problema si è presentato tre volte con la stessa forma:

1. **Varianza compositiva della quota UE (§10).** Con 30 stranieri per sezione la varianza fra sezioni è alta per pura combinatoria. Isolata con un test di sovradisersione: osservato / atteso sotto assegnazione casuale entro zona.
2. **Distanza compositiva fra tier (§6).** Il 0,569 grezzo di Parma è per il 79% discretizzazione; l'eccesso reale è 1,29.
3. **Pavimento MRE del PCD** (`nota_mre_floor_v01.tex`). La formula $1/(2\sqrt{N})$ del paper GibbsPCD confonde errore assoluto e relativo; il pavimento corretto dipende dalla rarità dei vincoli.

In tutti e tre i casi la metrica grezza ordinava le configurazioni in modo diverso — e talvolta inverso — rispetto alla metrica corretta.

Corollario operativo: quando è disponibile una configurazione in cui il segnale è **noto essere assente**, va usata come controllo. In §6, Brescia e Bologna a livello di sezione danno eccesso 1,04 e 1,01: la metrica è tarata correttamente proprio perché lì non trova nulla.

Changelog

v1.2 — 29/07/2026 Condizionale geografico del paese collegato e attivo su tutte e tre le città (§6), con misura dell'eccesso rispetto all'ipotesi nulla. §10 con i numeri delle esecuzioni correnti. Nuova §11 sul principio dell'ipotesi nulla. Assunzione (4) sostituita dalla (4').

v1.1 — 29/07/2026 Consolidamento in `gsp_common.py`. Correzione dei nomi delle zone di Bologna e dell'istruzione nei bin infantili. Sistema a tier costruito. `join_civici_sezioni.py` generalizzato a tre regioni.

v1.0 — 28/07/2026 Prima stesura.