

Popolazioni sintetiche GSP — documento di riferimento

Versione 1.3 — 29 luglio 2026 Descrive i file `popolazione_K9C_avq_full.csv` per Brescia, Parma e Bologna: come caricarli, cosa contengono, come sono stati costruiti, quali limiti dichiarati portano con sé e dove trovare i dati reali per il confronto.

Novità rispetto alla v1.2: dodici variabili di **fiducia istituzionale** su scala 0-10 (§2.2); tutte le codifiche AVQ risolte sul tracciato ufficiale, incluse due che erano inferite in modo errato; quarta occorrenza del principio dell'ipotesi nulla (§11). Gli attributi passano da 28 a **40**.

1. I file

```
~/progetti/gsp/data/comuni/{COMUNE}/constraints_2024/popolazione_K9C_avq_full.c
```

comune	codice	individui	attributi
Brescia	017029	198.259	40
Parma	034027	198.121	40
Bologna	037006	390.098	40

Totale 786.478 individui sintetici, ciascuno con indirizzo civico e coordinate geografiche.

Caricamento

Ci sono tre trappole di tipo. Questo snippet le gestisce tutte:

```
python
```

```

import pandas as pd, os

AVQ = ["AMBIENTE", "FIDUCIA", "SALUTE", "CRONI", "FUMO", "MH",
       "BMI", "BMIMIN", "CPESO",
       "PUNTIFI1", "PUNTIFI2", "PUNTIFI3", "PUNTIFI4", "PUNTIFI5",
       "PUNTIFI6", "PUNTIFI7", "PUNTIFI8", "PUNTIFI10", "PUNTIFI12",
       "PUNTIFI13", "VOTOUSL"]

def carica(comune, anno=2024):
    f = os.path.expanduser(
        f"~/progetti/gsp/data/comuni/{comune}/constraints_{anno}/"
        f"popolazione_K9C_avq_full.csv")
    p = pd.read_csv(f, low_memory=False, dtype={
        "zona": "string",          # 34027001: NON leggere come int
        "sezione": "string",       # 340270000994: 12 cifre
        "civico": "string",        # '19A': numero + esponente
    })
    for c in AVQ:
        p[c + "_num"] = pd.to_numeric(p[c], errors="coerce")
    return p

```

In alternativa, tutti i percorsi e i registri stanno in `gsp_common.py` (§4).

Trappole:

1. `zona` e `sezione` sono codici, non numeri.
2. Le variabili AVQ sono **stringhe** perché mescolano codici numerici e `non_applicabile` — tranne `SALUTE`, unica senza missing strutturali.
3. `area` usa `NaN` per gli italiani, non `non_applicabile` (§7).

2. Gli attributi

2.1 Anello 1 — MaxEnt (vincolati)

Dieci attributi le cui marginali e incroci riproducono il constraint set censuario con $MRE \approx 4 \cdot 10^{-4}$.

colonna	modalità	note
zona	codice a 8 cifre	quartiere o zona statistica, §3
quartiere	stringa	denominazione della zona
sezzo	M, F	
eta	0-8, 9-14, 15-24, 25-34, 35-49, 50-64, 65-74, 75+	bin del constraint set
stato_civile	celibe_nubile, coniugato_unito, divorziato_sciolto, vedovo	unioni civili collassate in coniugato_unito
cittadinanza	ITL, FRG	giuridica; FRG include gli apolidi
istruzione	nessun_titolo, elementare, media, diploma, laurea_o_its, post_laurea	laurea_o_its = triennale + ITS; post_laurea = magistrale + ciclo unico + dottorato
condizione	occupato, in_cerca, studente, casalinga, percettore_pensioni, altra_condizione, non_applicabile	non_applicabile = under 15 (categoria sostantiva)
background	italiano_nativo, italiano_rientrato, naturalizzato_g2, naturalizzato_immigrato, straniero_g2, straniero_immigrato	non coincide con cittadinanza
origine_genitori	entrambi_italiani, madre_italiana_padre_straniero, madre_straniera_padre_italiano, entrambi_stranieri, non_applicabile	

Metà delle 30 combinazioni (background × origine_genitori) è logicamente impossibile ed è esclusa dal supporto per costruzione.

2.2 Anello 2 — AVQ e nazionalità

colonna	modalità	fonte
area	UE , EXTRA_UE , NaN (italiani)	ST17/18/20/21 della sezione
paese	143-151 paesi + Italia	censimento comunale × fonte comunale geografica (§6)

Ventuno variabili AVQ, tutte assegnate **in blocco dallo stesso donatore** (hot-deck), quindi con correlazioni interne preservate per costruzione. Il pool è **regionale**: 8.111 donatori per la Lombardia, 4.629 per l'Emilia-Romagna, con condizionamento su **sexo × macroetà × istruzione4** e collasso gerarchico progressivo.

Codifiche — risolte sul tracciato ufficiale

variabile	domanda	codifica
AMBIENTE	soddisfazione per la situazione ambientale (aria, acqua, ecc.) della zona in cui vive	1 = molto ... 4 = per niente
FIDUCIA	"Lei pensa che ci si possa fidare della maggior parte della gente oppure bisogna stare molto attenti?"	1 = ci si può fidare (24,5%), 2 = stare attenti
SALUTE	salute percepita	1 = molto bene ... 5 = molto male
CRONI	malattie croniche o problemi di salute ≥ 6 mesi	1 = no, 2 = sì
FUMO	abitudine al fumo	1 = fumatore, 2 = ex, 3 = mai
MH	indice SF-12 di salute mentale	continua 0-100, più alto = meglio
BMI	indice di massa corporea, adulti	1 = sottopeso ... 4 = obeso
BMIMIN	IOTF 2012, 3-17 anni	1 = normo/sotto, 2 = sovrappeso/obeso
CPESO	frequenza con cui controlla il proprio peso	1 = più spesso ... 5 = mai
PUNTI*FI	"quanto si fida delle seguenti istituzioni"	0-10 , più alto = più fiducia
VOTOUSL	giudizio complessivo sul servizio ricevuto nell'ASL	0-10

FIDUCIA è **fiducia interpersonale generalizzata**, non istituzionale: è l'item classico di Rosenberg (WVS, ESS, GSS). Il ~25% di risposte positive è il valore italiano nelle serie internazionali. La **polarità invertita** (1 = fiducia) è stata dedotta dal segno negativo delle correlazioni con **PUNTIFI**: l'associazione fra fiducia generalizzata e istituzionale è positiva in tutta la letteratura.

AMBIENTE è il **costrutto più rilevante per il lavoro Caffaro**, e non lo si sapeva prima della v1.3: non è preoccupazione ambientale generica ma **valutazione della qualità ambientale del proprio luogo di residenza**. Vedi §8 per il limite che ne consegue.

La batteria di fiducia istituzionale

variabile	istituzione	copertura
PUNTIFI1	Parlamento italiano	alta
PUNTIFI2	sistema giudiziario	alta
PUNTIFI3	forze dell'ordine	alta
PUNTIFI4	partiti politici	alta
PUNTIFI5	Parlamento europeo	alta
PUNTIFI8	Governo regionale	alta
PUNTIFI10	Governo comunale	alta
PUNTIFI12	vigili del fuoco	alta
PUNTIFI6	Presidente della Repubblica	ridotta
PUNTIFI7	Governo italiano	ridotta
PUNTIFI13	banche	ridotta
VOTOUSL	ASL (esperienza diretta)	bassa

Struttura interna, replicata nel sintetico entro ±0,01:

PUNTIFI1	-	PUNTIFI7	(Parlamento - Governo)	0,863
PUNTIFI8	-	PUNTIFI10	(Regione - Comune)	0,812
PUNTIFI1	-	PUNTIFI5	(Parlamento IT - UE)	0,792
PUNTIFI3	-	PUNTIFI12	(forze ordine - vigili f.)	0,609

Due fattori distinti. Forze dell'ordine e vigili del fuoco correlano 0,61 fra loro ma solo 0,14-0,27 con le istituzioni politiche: è la separazione fra fiducia nei *servizi* e fiducia nella *politica*.

Regione e Comune sono quasi indistinguibili (0,812). Per Caffaro significa che chi diffida del Comune diffida anche di ARPA e ATS, che sono articolazioni regionali: non esiste un canale istituzionale alternativo.

Medie AVQ 2024, nazionali: vigili del fuoco 8,10 · forze dell'ordine 6,70 · ASL 6,34 · **Governo comunale 5,13 · Governo regionale 4,65.**

Copertura: tre fasce

Il modulo AVQ **ruota fra le annate**. `assign_avq.py` distingue variabili *necessarie* (se mancano, l'annata si scarta) da *opzionali* (`--targets-opt`), prese dove ci sono): così le dodici nuove non costringono a dimezzare il pool di donatori.

fascia	variabili	Brescia	Parma	Bologna
base (2023+2024)	le 9 originali, <code>PUNTIFI1, 2, 3, 4, 5, 8, 10, 12</code>	~87%	~86%	~88%
solo 2024	<code>PUNTIFI6, 7, 13</code>	42,8%	42,4%	42,9%
solo 2024 × utenti ASL	<code>VOTOUSL</code>	15,4%	20,0%	20,4%

Il missing della seconda e terza fascia è **planned missing**: dipende dall'annata del donatore, non dall'individuo. Chi analizza quelle variabili lavora su una frazione della popolazione, ma non selezionata su caratteristiche individuali.

Universi diversi per variabile. `BMIMIN` copre il 13,6% (minori 3-17), `SALUTE` il 100%. Non esiste un sottoinsieme di righe completo su tutte: un `dropna()` listwise su tutte e 21 restituisce **zero righe**. Usare `DataFrame.corr(min_periods=...)`, e vedere §11 sul criterio corretto.

2.3 Anello 3 — risoluzione fine

colonna	tipo	descrizione
sezione	codice a 12 cifre	sezione di censimento (<code>SEZ21_ID</code>), basi 2021)
eta_anni	0-100	età esatta in anni
via	stringa	odonimo ANNCSU
civico	stringa	numero + esponente (<code>12</code> , <code>19A</code>)
lon, lat	float, EPSG:4258	coordinate del civico ($\approx$ WGS84)
indirizzo_fonte	<code>sezione</code> / <code>zona</code> / <code>convivenza</code>	provenienza dell'indirizzo
	<code>sezione</code>	<code>zona</code> <code>convivenza</code>
Brescia	197.511 (99,62%)	199 549
Parma	197.601 (99,74%)	39 481
Bologna	389.432 (99,83%)	36 630

- `zona`: la sezione è popolata ma priva di civici ANNCSU;
- `convivenza`: sezione fittizia `888888x` (senza tetto, convivenze anagrafiche). **Nessun indirizzo**, coordinate = centroide della zona.

3. Livello territoriale — non è uniforme, e i codici si sovrappongono

comune	livello	zone	abitanti/zona	sezioni
Brescia	<code>COM_ASC1</code> (quartieri)	33	6.008	1.822
Parma	<code>COM_ASC1</code> (quartieri)	13	15.240	1.357
Bologna	<code>COM_ASC2</code> (zone statistiche)	18	21.672	2.224

Bologna usa ASC2 perché i suoi 6 quartieri ASC1 sono troppo pochi; ASC3 (90 aree) è inutilizzabile per la coda di zone minuscole (la più piccola ha 13 abitanti). Parma pubblica solo ASC1. Il livello è fissato nel registro di `gsp_common.py`, non scelto da riga di comando.

3.1 I codici ASC si sovrappongono fra livelli

I livelli sono numerati **indipendentemente**. A Bologna `COM_ASC1` va da `37006011` a `37006016` e `COM_ASC2` da `37006001` a `37006018`.

37006011	come ASC1 ->	Borgo Panigale-Reno	(quartiere, 61.149 ab.)
37006011	come ASC2 ->	Marconi	(zona statistica, 14.687 ab.)

Il codice da solo non identifica la zona. Un merge sul solo codice riesce e restituisce il nome sbagliato, senza errori né valori mancanti. `G.verificalivello()` intercetta il caso.

3.2 Incidente: i nomi delle zone di Bologna erano errati

Fino al 29/07/2026 il dizionario `codice → nome` di Bologna era **permutato**: 16 codici su 18. Nessun controllo strutturale poteva vederlo — una permutazione resta una biiezione perfetta.

L'errore è emerso quando il consolidamento ha sostituito la mappa cablata con una derivata dalle sezioni. L'identificazione ha usato due vincoli indipendenti che concordano: la struttura della gerarchia (gruppi 3, 3, 4, 2, 4, 2, che si sovrappongono in un solo modo) e i conteggi di stranieri per zona degli open data comunali. I codici ASC2 seguono l'**ordine alfabetico** dei nomi, ignorando gli spazi.

Lezione: le denominazioni vanno verificate contro una fonte esterna. I dati numerici erano corretti — calcolati sui codici; sbagliate erano solo le etichette leggibili, cioè ciò che finisce in mappe e tabelle.

Quartieri di Parma

34027001	Parma Centro	34027006	San Pancrazio	34027011	Cittadella
34027002	Oltretorrente	34027007	San Leonardo	34027012	Montanara
34027003	Molinetto	34027008	Cortile San Martino	34027013	Vigatto
34027004	Pablo	34027009	Lubiana		
34027005	Golese	34027010	San Lazzaro		

4. `gsp_common.py` — registro e primitive condivise

Consolida i cinque registri di comuni duplicati negli script. Nel registro sta **solo ciò che non è derivabile**; i percorsi sono formule sul codice ISTAT.

python

```
import gsp_common as G

G.info("034027")          G.procom("034027")          # 34027
G.cod_prov("034027")      G.cod_avq("034027")      # 80 (REGMf in AVQ)
G.livello_col("037006")   # "COM_ASC2"
G.zona_nomi("037006")     # {codice: nome}
G.path_sezioni / path_civici / path_constraints / path_comune / path_shp
G.largest_remainder(n, pesi)      G.spartisci(idx, conta, valori)
G.norm_code(serie, comune)        G.norm_nome("S. Leonardo")
G.paesi_censuari("034027")        G.etichette_paese("034027")
G.risolvi_paese(etichetta, rif)    G.EU27_ISO
```

```
bash
```

```
python scripts/gsp_common.py --check
python scripts/gsp_common.py --dump-nomi 037006
```

Il consolidamento è stato eseguito come **refactor puro**, verificato per identità byte-a-byte dell'output su ogni script migrato.

5. La pipeline

fetch_comune.py	SDMX ISTAT -> 11 tavole censuarie comunali	
build_sezioni.py	file regionale -> {comune}_sezioni_2023.csv	
join_civici_sezioni.py	ANNCSU + shapefile -> civici agganciati alle sezioni	
build_zona_tables.py	sezioni -> Z1..Z4, Z6 al livello ASC scelto	
build_constraints.py	tavole -> constraint set (blocchi c1..c10)	
cs_build.py	-> supporto X + vincoli (cs_K9C.json)	
fit_cs.py	-> MaxEnt esatto -> popolazione_K9C.csv	
assign_nationality.py	-> + paese (comunale)	anello 2
assign_avq.py	-> + 21 variabili AVQ	
enrich.py	-> + sezione, area, paese (geografico),	
usa opendata_paese.py	eta_anni, indirizzo, lon/lat	anello 3

$\overline{|X|} = 161.280 \times n_{\text{zone}}$. $\text{MRE}(\alpha > 0) \approx 4 \cdot 10^{-4}$, indipendente da $\overline{|X|}$ su tre ordini di grandezza.

Perché l'allocazione esatta conta

MAE della popolazione per sezione: **1,36-1,58** su medie di 109-175 abitanti. Un campionamento multinomiale darebbe $\approx 9,6$. Il fattore $\sim 6,5$ viene dall'allocazione esatta

dentro ogni gruppo; il residuo è l'accumulo di arrotondamenti su una trentina di gruppi per sezione, quindi **non cresce con la popolazione**.

Copertura regionale

```
bash
python scripts/join_civici_sezioni.py emilia_romagna | lombardia | puglia
```

Bounding box derivato dallo shapefile, codici provincia dai dati. Un contatore segnala i civici che ANNCSU attribuisce a un comune ma che cadono in sezioni di un altro (42 a Brescia, 14 a Parma, 0 a Bologna).

6. Condizionale geografico del paese — attivo

tier	livello	fonte	comune
0	comune	solo censimento	default, ogni comune nuovo
1	quartiere	33 CSV, senza sesso, ~19 paesi + residuale	Brescia
2	zona	parquet con sesso, 155 paesi	Bologna
3	sezione	microdati individuali	Parma

`--no-tier` ripristina il comportamento comunale. **Copertura: 100% dalla geografia su tutte e tre, zero fallback** — il peso di sezione per gli stranieri è $P \times q$ con $q = ST/P$, quindi nessuno straniero può atterrare dove il censimento non ne conta.

Formulazione

Le fonti locali sono **anagrafiche** e di data diversa dal censimento. Se ne usa la **forma**, non i livelli:

```
seed          T0(p,s,g) = struttura locale
margine 1     somma_g  T(p,s,g) = censimento comunale (paese, sesso)
margine 2     somma_ps T(p,s,g) = popolazione straniera censuaria di g
```

Due margini censuari con lo stesso totale: sistema sempre risolubile, IPF converge in 9-88 iterazioni con scarto ~1e-11. Imporre anche i conteggi locali renderebbe i margini incompatibili (anagrafe 40.090 stranieri a Brescia contro 37.478 censuari).

Il gruppo residuale entra nel seed: la sua massa si distribuisce sui paesi non nominati *in quel geo* proporzionalmente alla quota nazionale. Con la fonte assente il risultato coincide **esattamente** con il tier 0.

Riconciliazione delle denominazioni

	agganciati	residuo
Brescia	89,2%	4.346 = (ALTRE CITTADINANZE), tetto strutturale della fonte
Bologna	100,0%	7 persone in paesi assenti dal censimento
Parma	100,0%	13 persone

(G.AGGREGATI_PAESE) elenca i codici che **non** sono paesi. Filtrare per esclusione e non per forma del codice: i paesi hanno di norma un ISO alpha-2 ma non sempre ((X95) Kosovo, (XSD_S) Sud Sudan), e alcuni aggregati **hanno** forma alpha-2 — (EU) in particolare, somma dei 27 già presenti singolarmente, gonfiava il margine censuario del 21%.

Quanto porta la geografia

Frazione di stranieri che cambia nazionalità passando dal condizionale comunale a quello geografico, contro la stessa quantità sotto **ipotesi nulla** (due permutazioni indipendenti: nessuna struttura, stesse numerosità).

		osservata	nulla	eccesso
Brescia	per quartiere	0,197	0,094	2,08
	per sezione	0,408	0,393	1,04
Parma	per quartiere	0,156	0,074	2,10
	per sezione	0,530	0,412	1,29
Bologna	per quartiere	0,169	0,066	2,57
	per sezione	0,421	0,417	1,01

A livello di quartiere l'informazione è sostanziale e simile ovunque: 2,1-2,6 volte quanto si sposterebbe per caso. In concreto, ~7.400 stranieri di Brescia, ~5.400 di Parma, ~10.000 di Bologna cambiano nazionalità in modo informativo.

Una fonte povera ma geograficamente risolta vale quanto una ricca. Brescia (19 paesi più un residuo del 10,8%, senza sesso) ottiene 2,08 contro il 2,57 di Bologna (155 paesi con sesso). Per i comuni futuri: basta una tabella (paese x quartiere), anche troncata alle prime venti nazionalità.

Brescia e Bologna a livello di sezione danno 1,04 e 1,01, cioè nulla — correttamente, perché il loro condizionale si ferma alla zona. Questo valida la metrica per via negativa. Il

1,29 di Parma è l'unico eccesso reale sotto il quartiere.

Il tier 3 non ripaga la complessità in aggregato: quasi tutto il guadagno di Parma è già catturato al quartiere. Resta però migliore per il singolo individuo, ed è la risoluzione necessaria per analisi che incrocino nazionalità e posizione fine.

I microdati di Parma: condizionale o validazione

202.111 righe, una per residente, con `SEZ21`, `Cittad`, `ETA`, `Sesso`, `Ncomp`, `Relpar`, `SEZ21_ID`
= "34027" + SEZ21.zfill(7)), aggancio 99,9%.

uso	variabili
condizionale	<code>Cittad × SEZ21 × Sesso</code>
validazione esterna, mai usate per generare	<code>ETA × SEZ21</code> ; <code>Ncomp</code> , <code>Relpar</code> ; co-occorrenza di nazionalità nella stessa sezione; <code>Tipores</code>

È l'unica occasione di **validazione esterna vera** che il progetto abbia: finora si è verificata solo la coerenza interna.

7. Limiti e assunzioni dichiarate

n.	assunzione	dove
(4')	<code>paese ⊥ tutto (area, sesso, geo)</code> — <code>geo</code> = quartiere, zona o sezione secondo il tier	§6
(6)	<code>target AVQ ⊥ tutto (sesso, macroetà, istruzione4, regione)</code>	AVQ
(8)	<code>sezione ⊥ (istruzione, condizione, background) (zona, sesso, età3, cittadinanza)</code>	anello 3
(9)	entro il quinquennio, l'età segue la distribuzione comunale per anno singolo	anello 3
(10)	l'indirizzo è uniforme fra i civici della sezione	anello 3
(11)	nessuna struttura familiare	anello 3

La (4') sostituisce la vecchia (4). Per Brescia resta parzialmente in vigore sul 10,8% di stranieri nella categoria `ALTRE CITTADINANZE`.

Limiti della risoluzione per età

- **L'istruzione ha risoluzione effettiva di 4 classi d'età, non 8.** Il vincolo usa (Y9-24), (Y25-49), (Y50-64), (Y_GE65); dentro ogni classe la distribuzione viene da un **IPF con soglie minime di conseguimento** ((elementare) 10, (media) 13, (diploma) 18, (laurea_o_its) 20, (post_laurea) 22). *Prima della correzione del 29/07/2026 il 32,8% dei 9-14enni risultava diplomato o laureato.*
- **Resta sovrastimata (media) nel bin (9-14):** la licenza media si consegue a 14 anni, quindi riguarda circa un sesto del bin.
- **Effetto coorte perso fra (65-74) e (75+):** (Y_GE65) li rende indistinguibili.
- **Il background migratorio ha risoluzione di zona,** non di sezione.

Convenzioni per "assente" — non uniformate

forma	dove
(non_applicabile) (stringa)	(condizione), (origine_genitori), 20 delle 21 AVQ
(NaN)	(area), (via), (civico)
nessuna	(SALUTE), (paese) (= (Italia) per gli italiani)

(non_applicabile) è a volte una **categoria sostantiva** (la condizione professionale degli under-15), a volte un **missing individuale** ((BMIMIN) per gli adulti), a volte un **planned missing** legato all'annata del donatore ((PUNTIFI6, 7, 13), (VOTOUSL)).

8. Punti aperti

- **(AMBIENTE) non varia per quartiere.** È soddisfazione per l'ambiente *della zona in cui si vive*, ma è condizionata solo su sesso, età e istruzione: nella popolazione sintetica Fiumicello e Mompiano hanno la stessa distribuzione. Per un sito contaminato è precisamente ciò che serve superare, ed è ora il **candidato numero uno per il tilt areale**. Vale lo stesso per le (PUNTIFI).
- **Provenienza del paese non tracciata.** Non esiste una colonna (paese_fonte) analoga a (indirizzo_fonte).
- **Struttura familiare.** (Ncomp) e (Relpar) dei microdati di Parma, più (cens_posizione_famiglia) (scaricata e mai usata) per gli altri comuni.
- **Convivenze.** Riprodotte con scarto $\pm 2-5\%$, il peggiore fra tutte le celle.
- **K10C.** Esiste solo per Brescia, con (settore) come decimo attributo, e porta ancora l'istruzione **pre-correzione**: va rigenerato se usato.
- **San Vito dei Normanni ((074017)):** registrato, civici presenti, file sezioni non generato. (COM_ASC1) ha un solo valore: resterà un comune **senza articolazione zonale**.

- **Confronto fra città.** Le tre popolazioni usano condizionali di risoluzione diversa su partizioni di taglia diversa. Per un confronto rigoroso conviene rigenerarle al **quartiere**, dove gli eccessi sono simili (2,1-2,6).

9. Dove sono i dati reali, per il confronto

```
{COMUNE}/constraints_2024/  
    cs_K9C.json          vincoli con alpha target, categories, domain_sizes,  
zona_nomi  
    targets_K9C.json     tabelle target per blocco  
    fit_K9C.json          lambdas, MRE, entropia, supporto  
    manifest.json        fonte e tipo (hard/soft) di ogni blocco  
{COMUNE}/zona_2023/    z1..z4, z6, zona_nomi  
data/submun/{slug}_sezioni_2023.csv  
    P1, ST1, ST16/ST19, P30-P45 e P67-P82, ST25-ST30  
data/opendata/{COMUNE}/    fonti comunali per §6  
data/avq/anni/avq{Y}/METADATI/AVQ_Tracciato_{Y}.html    codifiche AVQ
```

Versione senza condizionale geografico, per i confronti:

```
bash  
  
python scripts/enrich.py 037006 --anno 2024 --no-tier \  
    --out popolazione_K9C_avq_full_tier0.csv
```

Geometrie per la visualizzazione

```
data/geodata/{regione}/R{NN}_21/SHP/R{NN}_21_WGS84.shp  
    R03 Lombardia    R08 Emilia-Romagna    R16 Puglia    CRS EPSG:32632
```

I poligoni delle zone si ottengono per **dissolve delle sezioni**:

```
python  
  
col = G.livello_col("034027")  
s = gpd.read_file(G.path_shp("emilia_romagna"))  
s = s[s.PRO_COM == G.procom("034027")]  
zone = s.dissolve(by=col).reset_index().to_crs("EPSG:4326")  
zone["nome"] = zone[col].astype("Int64").astype(str).map(G.zona_nomi("034027"))
```

Per Bologna (`G.livello_col`) è (`COM_ASC2`): un dissolve su (`COM_ASC1`) darebbe 6 poligoni invece di 18, e i codici — sovrapposti fra livelli (§3.1) — mapperebbero comunque su dei nomi, sbagliati.

10. Riepilogo numerico

Esecuzioni del 29 luglio 2026.

	Brescia	Parma	Bologna
codice ISTAT	017029	034027	037006
regione (AVQ)	Lombardia (30)	Emilia-Romagna (80)	Emilia-Romagna (80)
popolazione	198.259	198.121	390.098
attributi	40	40	40
zone	33 (ASC1)	13 (ASC1)	18 (ASC2)
sezioni	1.822	1.357	2.224
sezioni occupate	1.773	1.313	2.152
civici ANNCSU	49.730	35.826	77.595
stranieri (censimento)	37.478	34.436	58.963
stranieri (sintetici)	37.475	34.434	59.130
quota stranieri	18,9%	17,4%	15,1%
donatori AVQ nel pool	8.111	4.629	4.629
donatori distinti usati	8.108 (100,0%)	4.618 (99,8%)	4.625 (99,9%)
riuso medio donatore	24,5×	42,9×	84,3×
supporto X K9C	5.322.240	2.096.640	2.903.040
tier paese (§6)	1 (quartieri)	3 (sezione)	2 (zone)

Il riuso dei donatori è un tetto strutturale. Il 99,8-100% del pool viene usato almeno una volta: la diversità dell'anello 2 è satura, e nella popolazione di Bologna esistono al massimo 4.629 vettori psicografici distinti indipendentemente dai 390.098 individui.

Validazione per sezione

	sezioni	media/sez	MAE pop.	corr	MAE stranieri	corr	MAE UE	corr
Brescia	1.822	108,8	1,58	0,9998	0,98	0,9989	0,13	0,9976
Parma	1.357	146,0	1,43	0,9999	1,13	0,9985	0,16	0,9980
Bologna	2.224	175,4	1,36	0,9999	1,08	0,9983	0,17	0,9982

I totali comunali coincidono esattamente con il censimento. Gli scarti sui totali di stranieri (−3, −2, +167) sono entro 0,7 σ del rumore multinomiale di estrazione.

Struttura spaziale: la sezione conta molto più della zona

Decomposizione della varianza della quota UE fra stranieri, al netto della discretizzazione. **Calcolata dal file sezioni**, cioè dalla verità censuaria: non dipende dalla popolazione sintetica ed è invariata dalla v1.0.

	var tra zone	var reale dentro	sovradisersione	rapporto
Brescia (33 zone)	0,00168	0,00991	2,89×	5,9×
Parma (13 zone)	0,00110	0,01249	3,50×	11,3×
Bologna (18 zone)	0,00072	0,01124	3,04×	15,7×

Condizionare sul quartiere perde l'85–94% del segnale compositivo.

Validazione esterna puntuale

	fonte comunale	sintetico (cens. 2023)	rapporto
Primo Maggio (Brescia), quota stranieri	0,329	0,293	1,12
Bologna, quota UE fra stranieri	0,214	0,213	1,00

Un fatto rilevante per il progetto Caffaro

Fiumicello	0,368	Buffalora	0,088
Centro Storico Nord	0,314	Villaggio Violino	0,073
Primo Maggio	0,293		

Fiumicello, uno dei due quartieri della `ZonaCaffaro`, ha la più alta quota di stranieri della città — il doppio della media comunale. Lingua, canali informativi e fiducia nelle istituzioni sono fortemente differenziati su quell'asse, ma `AMBIENTE`, `FIDUCIA` e le `PUNTIFI` sono condizionate su sesso, età e istruzione e **non** su cittadinanza né sulla geografia (§8).

11. Un principio metodologico ricorrente

Ogni metrica che scala con la numerosità di cella va rapportata alla propria ipotesi nulla prima di essere confrontata fra configurazioni diverse.

Quattro occorrenze, stessa forma:

1. **Varianza compositiva della quota UE** (§10). Con 30 stranieri per sezione la varianza fra sezioni è alta per pura combinatoria. Isolata con un test di sovradisersione contro l'assegnazione casuale entro zona.
2. **Distanza compositiva fra tier** (§6). Il 0,569 grezzo di Parma è per il 79% discretizzazione; l'eccesso reale è 1,29.
3. **Pavimento MRE del PCD** (`nota_mre_floor_v01.tex`). La formula $1/(2\sqrt{N})$ del paper GibbsPCD confonde errore assoluto e relativo.
4. **Numerosità effettiva di una popolazione hot-deck** (§2.2). Le correlazioni fra variabili AVQ *sembrano* poggiare su 198.121 osservazioni ma poggiano su al più 4.629 donatori distinti. Per coppie a universi quasi disgiunti la base scende a poche decine: `BMIMIN` × `VOTOUSL` ha 266 individui ma una manciata di donatori, e produceva una correlazione di -0,61 priva di significato. `assign_avq.py` maschera ora le coppie con meno di 100 **donatori** distinti, non individui.

In tutti e quattro i casi la metrica grezza ordinava le configurazioni in modo diverso — e talvolta inverso — rispetto alla metrica corretta.

Corollario operativo: quando esiste una configurazione in cui il segnale è *noto essere assente*, va usata come taratura. In §6, Brescia e Bologna a livello di sezione danno eccesso 1,04 e 1,01: la metrica è tarata correttamente proprio perché lì non trova nulla.

Changelog

v1.3 — 29/07/2026 Dodici variabili di fiducia istituzionale (`PUNTIFI*`, `VOTOUSL`) su scala 0-10, con meccanismo di target opzionali che evita di dimezzare il pool di donatori per il modulo AVQ a rotazione. Tutte le codifiche AVQ risolte sul tracciato ufficiale: `FIDUCIA` è fiducia interpersonale con polarità invertita, `AMBIENTE` è soddisfazione per l'ambiente della zona di residenza, `CPESO` è frequenza di controllo del peso. Attributi da 28 a 40. Quarta occorrenza del principio dell'ipotesi nulla (§11).

v1.2 — 29/07/2026 Condizionale geografico del paese collegato e attivo (§6). §10 con numeri correnti. §11 sul principio dell'ipotesi nulla.

v1.1 — 29/07/2026 Consolidamento in `gsp_common.py`. Correzione dei nomi delle zone di Bologna e dell'istruzione nei bin infantili. Sistema a tier costruito.

v1.0 — 28/07/2026 Prima stesura.