

Popolazioni sintetiche GSP — documento di riferimento

Versione 1.7 — 30 luglio 2026 Descrive i file `popolazione_K9C_avq_full.csv` per Brescia, Parma, Bologna e Modena: come caricarli, cosa contengono, come sono stati costruiti, quali limiti dichiarati portano con sé, dove trovare i dati reali per il confronto e **come aggiungere un comune nuovo** (§12).

Questa versione sostituisce tutte le precedenti.

1. I file

```
~/progetti/gsp/data/comuni/{COMUNE}/constraints_2024/popolazione_K9C_avq_full.c
```

comune	codice	individui	attributi	tier paese
Brescia	017029	198.259	40	1
Parma	034027	198.121	40	3
Bologna	037006	390.098	40	2
Modena	036023	184.597	40	0

Totale 971.075 individui sintetici, ciascuno con indirizzo civico e coordinate geografiche.

Caricamento

Ci sono tre trappole di tipo. Questo snippet le gestisce tutte:

```
python
```

```

import pandas as pd, os

AVQ = ["AMBIENTE", "FIDUCIA", "SALUTE", "CRONI", "FUMO", "MH",
       "BMI", "BMIMIN", "CPESO",
       "PUNTIFI1", "PUNTIFI2", "PUNTIFI3", "PUNTIFI4", "PUNTIFI5",
       "PUNTIFI6", "PUNTIFI7", "PUNTIFI8", "PUNTIFI10", "PUNTIFI12",
       "PUNTIFI13", "VOTOUSL"]

def carica(comune, anno=2024):
    f = os.path.expanduser(
        f"~/progetti/gsp/data/comuni/{comune}/constraints_{anno}/"
        f"popolazione_K9C_avq_full.csv")
    p = pd.read_csv(f, low_memory=False, dtype={
        "zona": "string",          # 34027001: NON leggere come int
        "sezione": "string",       # 340270000994: 12 cifre
        "civico": "string",        # '19A': numero + esponente
    })
    for c in AVQ:
        p[c + "_num"] = pd.to_numeric(p[c], errors="coerce")
    return p

```

In alternativa, tutti i percorsi e i registri stanno in `gsp_common.py` (§4).

Trappole:

1. `zona` e `sezione` sono codici, non numeri.
2. Le variabili AVQ sono **stringhe** perché mescolano codici numerici e `non_applicabile` — tranne `SALUTE`, unica senza missing strutturali.
3. `area` usa `NaN` per gli italiani, non `non_applicabile` (§7).

2. Gli attributi

2.1 Anello 1 — MaxEnt (vincolati)

Dieci attributi le cui marginali e incroci riproducono il constraint set censuario con $MRE \approx 4 \cdot 10^{-4}$.

colonna	modalità	note
zona	codice a 8 cifre	quartiere o zona statistica, §3
quartiere	stringa	denominazione della zona
sezzo	M, F	
eta	0-8, 9-14, 15-24, 25-34, 35-49, 50-64, 65-74, 75+	bin del constraint set
stato_civile	celibe_nubile, coniugato_unito, divorziato_sciolto, vedovo	unioni civili collassate in coniugato_unito
cittadinanza	ITL, FRG	giuridica; FRG include gli apolidi
istruzione	nessun_titolo, elementare, media, diploma, laurea_o_its, post_laurea	laurea_o_its = triennale + ITS; post_laurea = magistrale + ciclo unico + dottorato
condizione	occupato, in_cerca, studente, casalinga, percettore_pensioni, altra_condizione, non_applicabile	non_applicabile = under 15 (categoria sostantiva)
background	italiano_nativo, italiano_rientrato, naturalizzato_g2, naturalizzato_immigrato, straniero_g2, straniero_immigrato	non coincide con cittadinanza
origine_genitori	entrambi_italiani, madre_italiana_padre_straniero, madre_straniera_padre_italiano, entrambi_stranieri, non_applicabile	

Metà delle 30 combinazioni (background × origine_genitori) è logicamente impossibile ed è esclusa dal supporto per costruzione.

2.2 Anello 2 — AVQ e nazionalità

colonna	modalità	fonte
area	UE, EXTRA_UE, NaN (italiani)	ST17/18/20/21 della sezione
paese	143-151 paesi + Italia	censimento comunale × fonte comunale geografica (§6)

Ventuno variabili AVQ, tutte assegnate in blocco dallo stesso donatore (hot-deck), quindi con correlazioni interne preservate per costruzione. Il pool è regionale: 8.111 donatori per la Lombardia, 4.629 per l'Emilia-Romagna, con condizionamento su sesso × macroetà × istruzione4 e collasso gerarchico progressivo. Il pool impila le annate 2023 e 2024 — non il 2022, che assign_avq.py scarta perché vi manca CRONI — meno i record con ISTRMi = 99. Anatomia completa, numerosità efficace e limiti: §13.

Codifiche — risolte sul tracciato ufficiale

variabile	domanda	codifica
AMBIENTE	soddisfazione per la situazione ambientale (aria, acqua, ecc.) della zona in cui vive	1 = molto ... 4 = per niente
FIDUCIA	"Lei pensa che ci si possa fidare della maggior parte della gente oppure bisogna stare molto attenti?"	1 = ci si può fidare (24,5%), 2 = stare attenti
SALUTE	salute percepita	1 = molto bene ... 5 = molto male
CRONI	malattie croniche o problemi di salute $\geq$ 6 mesi	1 = no, 2 = sì
FUMO	abitudine al fumo	1 = fumatore, 2 = ex, 3 = mai
MH	indice SF-12 di salute mentale	continua 0-100, più alto = meglio
BMI	indice di massa corporea, adulti	1 = sottopeso ... 4 = obeso
BMIMIN	IOTF 2012, 3-17 anni	1 = normo/sotto, 2 = sovrappeso/obeso
CPESO	frequenza con cui controlla il proprio peso	1 = più spesso ... 5 = mai
PUNTIFI*	"quanto si fida delle seguenti istituzioni"	0-10, più alto = più fiducia
VOTOUSL	giudizio complessivo sul servizio ricevuto nell'ASL	0-10

FIDUCIA è fiducia interpersonale generalizzata, non istituzionale: è l'item classico di Rosenberg (WVS, ESS, GSS). La polarità invertita (1 = fiducia) è stata dedotta dal segno negativo delle correlazioni con **PUNTIFI**.

AMBIENTE è il costrutto più rilevante per il lavoro Caffaro: non è preoccupazione ambientale generica ma valutazione della qualità ambientale del proprio luogo di residenza. Vedi §8.

La batteria di fiducia istituzionale

variabile	istituzione	copertura
PUNTIFI1	Parlamento italiano	alta
PUNTIFI2	sistema giudiziario	alta
PUNTIFI3	forze dell'ordine	alta
PUNTIFI4	partiti politici	alta
PUNTIFI5	Parlamento europeo	alta
PUNTIFI8	Governo regionale	alta
PUNTIFI10	Governo comunale	alta
PUNTIFI12	vigili del fuoco	alta
PUNTIFI6	Presidente della Repubblica	ridotta
PUNTIFI7	Governo italiano	ridotta
PUNTIFI13	banche	ridotta
VOTOUSL	ASL (esperienza diretta)	bassa

Struttura interna, replicata nel sintetico entro $\pm 0,01$:

PUNTIFI1	-	PUNTIFI7	(Parlamento - Governo)	0,863
PUNTIFI8	-	PUNTIFI10	(Regione - Comune)	0,812
PUNTIFI1	-	PUNTIFI5	(Parlamento IT - UE)	0,792
PUNTIFI3	-	PUNTIFI12	(forze ordine - vigili f.)	0,609

Due fattori distinti. Forze dell'ordine e vigili del fuoco correlano 0,61 fra loro ma solo 0,14-0,27 con le istituzioni politiche: è la separazione fra fiducia nei *servizi* e fiducia nella *politica*.

Regione e Comune sono quasi indistinguibili (0,812). Per Caffaro significa che chi diffida del Comune diffida anche di ARPA e ATS, che sono articolazioni regionali: non esiste un canale istituzionale alternativo.

Medie AVQ 2024, nazionali: vigili del fuoco 8,10 · forze dell'ordine 6,70 · ASL 6,34 · **Governo comunale 5,13 · Governo regionale 4,65.**

Fonte non citata. Questi cinque valori circolano nelle note di progetto senza riferimento. Vanno verificati sulla pubblicazione ISTAT prima di comparire in una

| figura, o tolti: una tacca di riferimento sbagliata sposta la lettura di ogni confronto.

Copertura: tre fasce

Il modulo AVQ **ruota davvero fra le annate**: `PUNTIFI6`, `PUNTIFI7`, `VOTOUSL` e `FORZE_ARMATE` non esistono nei tracciati 2022 e 2023, `PUNTIFI13` manca nel 2023. `assign_avq.py` distingue variabili *necessarie* (se mancano, **l'annata intera si scarta**) da *opzionali* (`--targets-opt`, prese dove ci sono): così le variabili a rotazione non costringono a dimezzare il pool.

fascia	variabili	copertura tipica
base (2023+2024)	le 9 originali, <code>PUNTIFI1, 2, 3, 4, 5, 8, 10, 12</code>	86-88%
solo 2024	<code>PUNTIFI6, 7, 13</code>	42-43%
solo 2024 × utenti ASL	<code>VOTOUSL</code>	15-20%

Il missing della seconda e terza fascia è **planned missing**: dipende dall'annata del donatore, non dall'individuo. La *percentuale*, però, dipende anche da noi: con il pool a due annate il 2024 vale il 52,8%, e la copertura si prevede a due decimali dalla composizione del pool (§13.1).

Universi diversi per variabile. `BMIMIN` copre il 13,6% (minori 3-17), `SALUTE` il 100%. Un `dropna()` listwise su tutte e 21 restituisce **zero righe**. Usare `DataFrame.corr(min_periods=...)`, e vedere §11.

2.3 Anello 3 — risoluzione fine

colonna	tipo	descrizione
<code>sezione</code>	codice a 12 cifre	sezione di censimento (<code>SEZ21_ID</code> , basi 2021)
<code>eta_anni</code>	0-100	età esatta in anni
<code>via</code>	stringa	odonimo ANNCSU
<code>civico</code>	stringa	numero + esponente (<code>12</code> , <code>19A</code>)
<code>lon</code> , <code>lat</code>	float, EPSG:4258	coordinate del civico (≈ WGS84)
<code>indirizzo_fonte</code>	<code>sezione</code> / <code>zona</code> / <code>convivenza</code>	provenienza dell'indirizzo

	sezione	zona	convivenza
Brescia	197.511 (99,62%)	199	549
Parma	197.601 (99,74%)	39	481
Bologna	389.432 (99,83%)	36	630
Modena	184.269 (99,82%)	278	50

- `zona`: la sezione è popolata ma priva di civici ANNCSU. Modena ha il valore più alto in termini relativi (0,15%), pur avendo **più civici di Brescia** (60.488 contro 49.730) a fronte di meno abitanti: non è scarsità complessiva ma distribuzione;
- `convivenza`: sezione fittizia `888888x`. **Nessun indirizzo**, coordinate = centroide della zona.

3. Livello territoriale — non è uniforme, e i codici si sovrappongono

comune	livello	zone	abitanti/zona	sezioni	sez./zona
Brescia	<code>COM_ASC1</code> (quartieri)	33	6.008	1.822	55
Parma	<code>COM_ASC1</code> (quartieri)	13	15.240	1.357	104
Bologna	<code>COM_ASC2</code> (zone statistiche)	18	21.672	2.224	124
Modena	<code>COM_ASC1</code> (quartieri)	4	46.149	2.186	546

Bologna usa ASC2 perché i suoi 6 quartieri ASC1 sono troppo pochi; ASC3 (90 aree) è inutilizzabile per la coda di zone minuscole. Parma e Modena pubblicano **solo** ASC1. Il livello è **fissato nel registro** di `gsp_common.py`, non scelto da riga di comando.

Le quattro zone di Modena sono la partizione più grossolana in pipeline. Si usano comunque: servono ai vincoli Z del MaxEnt e danno un `quartiere` leggibile, mentre il lavoro geografico lo fa l'anello 3 (§10).

3.1 I codici ASC si sovrappongono fra livelli

I livelli sono numerati **indipendentemente**. A Bologna `COM_ASC1` va da `37006011` a `37006016` e `COM_ASC2` da `37006001` a `37006018`.

37006011	come ASC1 -> Borgo Panigale-Reno	(quartiere, 61.149 ab.)
37006011	come ASC2 -> Marconi	(zona statistica, 14.687 ab.)

Il codice da solo non identifica la zona. Un merge sul solo codice riesce e restituisce il nome sbagliato, senza errori né valori mancanti. `G.verificalivello()` intercetta il caso.

3.2 Le denominazioni delle zone vanno verificate, sempre

Fino al 29/07/2026 il dizionario `codice → nome` di Bologna era **permutato**: 16 codici su 18. Nessun controllo strutturale poteva vederlo — una permutazione resta una biiezione perfetta. I dati numerici erano corretti, perché calcolati sui codici; sbagliate erano solo le etichette leggibili, cioè ciò che finisce in mappe e tabelle.

Metodo di verifica, in ordine di praticità. Bastano due assi concordanti; il terzo è disponibile solo in alcuni casi.

(a) Baricentro e dispersione dei civici. Dal file `{prov}_{nome}_civici_sezioni_asc.csv`, media e deviazione standard di `COORD_X_COMUNE`/`COORD_Y_COMUNE` per `COM_ASC*`, convertite in km. Il centro storico si riconosce dal raggio minimo; i nomi che contengono riferimenti cardinali si accoppiano alle direzioni. Nessun download.

(b) Concentrazione dei toponimi. Gli odonimi ANNCSU che contengono un toponimo devono cadere nel quartiere che lo nomina.

(c) Popolazione per zona da fonte comunale. Se il portale pubblica la popolazione per quartiere, il confronto con `P1` aggregato per `COM_ASC*` identifica la mappa. Lo scarto atteso è ~1-2% (anagrafe contro censimento).

(d) Struttura della gerarchia, solo per comuni con due livelli ASC: le taglie dei gruppi si sovrappongono in un solo modo.

Su Modena i tre assi disponibili hanno dato lo stesso esito:

codice	est_km	nord_km	raggio_km	civici	pop.cens.	pop.anagr.
36023001	0,11	0,64	0,68	10.234	24.469	24.038
36023002	2,09	1,36	2,22	14.662	48.018	48.376
36023003	0,85	-2,11	2,34	17.869	59.842	59.675
36023004	-2,65	0,63	3,07	17.723	52.268	52.051

toponimi: SAN FAUSTINO -> 004 (100%) · CROCETTA -> 002 · BUON PASTORE -> 003
SAN DAMASO -> 003 · EMILIA CENTRO -> 001

Denominazioni

Parma (13 quartieri)

34027001 Parma Centro	34027006 San Pancrazio	34027011 Cittadella
34027002 Oltretorrente	34027007 San Leonardo	34027012 Montanara
34027003 Molinetto	34027008 Cortile San Martino	34027013 Vigatto
34027004 Pablo	34027009 Lubiana	
34027005 Golese	34027010 San Lazzaro	

Modena (4 quartieri, numerazione ufficiale del Comune)

36023001 Centro Storico	(portale comunale: CENTRO STORICO-S.CATALDO)
36023002 Crocetta, San Lazzaro, Modena Est	
36023003 Buon Pastore, Sant'Agnese, San Damaso	
36023004 San Faustino, Madonnina, Quattro Ville	

Brescia e Bologna sono in `gsp_common.py`. I codici ASC2 di Bologna seguono l'ordine **alfabetico** dei nomi, ignorando gli spazi.

4. `gsp_common.py` — registro e primitive condivise

Consolida i cinque registri di comuni duplicati negli script. Nel registro sta **solo ciò che non è derivabile**; i percorsi sono formule sul codice ISTAT.

```
python

import gsp_common as G

G.info("034027")          G.procom("034027")          # 34027
G.cod_prov("034027")      G.cod_avq("034027")          # 80 (REGMf in AVQ)
G.livello_col("037006")   G.zona_nomi("037006")
G.verifica_livello(codici, comune)
G.path_sezioni / path_civici / path_constraints / path_comune / path_shp
G.largest_remainder(n, pesi)      G.spartisci(idx, conta, valori)
G.norm_code(serie, comune)        G.norm_nome("S. Leonardo")
G.paesi_censuari(comune)          G.etichette_paese(comune)
G.risolvi_paese(etichetta, rif)   G.EU27_ISO      G.AGGREGATI_PAESE
```

```
bash

python scripts/gsp_common.py --check
python scripts/gsp_common.py --dump-nomi 037006
```

Il consolidamento è stato eseguito come **refactor puro**, verificato per identità byte-a-byte dell'output su ogni script migrato.

5. La pipeline

fetch_comune.py	SDMX ISTAT -> 11 tavole censuarie comunali	
build_sezioni.py	file regionale -> {comune}_sezioni_2023.csv	
join_civici_sezioni.py	ANNCSU + shapefile -> civici agganciati alle sezioni	
build_zona_tables.py	sezioni -> Z1..Z4, Z6 al livello ASC scelto	
build_constraints.py	tavole -> constraint set (blocchi c1..c10)	
cs_build.py	-> supporto X + vincoli (cs_K9C.json)	
fit_cs.py	-> MaxEnt esatto -> popolazione_K9C.csv	
assign_nationality.py	-> + paese (comunale)	anello 2
assign_avq.py	-> + 21 variabili AVQ	
enrich.py	-> + sezione, area, paese (geografico),	
usa_opendata_paese.py	eta_anni, indirizzo, lon/lat	anello 3

$\boxed{|X|} = 161.280 \times n_{\text{zone}}$. $MRE(\alpha > 0) \approx 4 \cdot 10^{-4}$, **indipendente da** $\boxed{|X|}$ su quattro punti che coprono un ordine di grandezza ($6,5 \cdot 10^5 \rightarrow 5,3 \cdot 10^6$).

Perché l'allocazione esatta conta

MAE della popolazione per sezione: **0,74–1,58** su medie di 84–175 abitanti. Un campionamento multinomiale darebbe $\approx 9,6$.

Il MAE **non cresce con la popolazione** e sembra anzi migliorare con zone più grandi: Modena, con 546 sezioni per zona, ha il MAE più basso (0,74).

6. Condizionale geografico del paese

tier	livello	fonte	comune
0	comune	solo censimento	Modena , e ogni comune nuovo
1	quartiere	33 CSV, senza sesso, ~19 paesi + residuale	Brescia
2	zona	parquet con sesso, 155 paesi	Bologna
3	sezione	microdati individuali	Parma

`--no-tier` forza il comportamento comunale su qualunque comune. **Copertura: 100%**
dalla geografia su tutte e quattro, zero fallback — il peso di sezione per gli stranieri è $\boxed{P \times}$

`q`) con `q = ST/P`, quindi nessuno straniero può atterrare dove il censimento non ne conta.

Formulazione

Le fonti locali sono **anagrafiche** e di data diversa dal censimento. Se ne usa la **forma**, non i livelli:

```
seed          T0(p,s,g) = struttura locale
margine 1     somma_g  T(p,s,g) = censimento comunale (paese, sesso)
margine 2     somma_ps T(p,s,g) = popolazione straniera censuaria di g
```

Due margini censuari con lo stesso totale: sistema sempre risolubile, IPF converge in 9-88 iterazioni con scarto $\sim 1e-11$. Imporre anche i conteggi locali renderebbe i margini incompatibili (anagrafe 40.090 stranieri a Brescia contro 37.478 censuari).

Con la fonte assente il seed è la quota nazionale replicata su ogni zona.

Il tier 0 è collaudato

Modena è il primo comune senza fonte locale, e il ramo di default — quello che ogni comune nuovo userà — è stato verificato end-to-end confrontandolo con `--no-tier`:

```
distanza in variazione totale, complessiva:  0,0023  (66 stranieri su
28.412)
per quartiere, media:                        0,029
per confronto, condizionale geografico:      0,156 - 0,197
```

Il collaudo ha scoperto due bug latenti, entrambi della stessa famiglia — classificare per etichetta invece che per codice:

- le denominazioni ISTAT sono invertite (`Ceca, Repubblica`), quindi il confronto con `startswith` classificava la Repubblica Ceca come extra-UE;
- la regex sugli aggregati catturava `africa` ovunque nella stringa, quindi escludeva `Sud Africa`, che è un paese.

Entrambi ora usano i codici (`G.EU27_ISO`, `G.AGGREGATI_PAESE`). Il filtro va fatto **per esclusione e non per forma del codice**: i paesi hanno di norma un ISO alpha-2 ma non sempre (`X95` Kosovo, `XSD_S` Sud Sudan), e alcuni aggregati hanno forma alpha-2 — `EU` in particolare, somma dei 27 già presenti singolarmente, gonfiava il margine censuario del 21%.

Riconciliazione delle denominazioni

	agganciati	residuo
Brescia	89,2%	4.346 = ALTRE CITTADINANZE, tetto strutturale della fonte
Bologna	100,0%	7 persone in paesi assenti dal censimento
Parma	100,0%	13 persone

Quanto porta la geografia

Frazione di stranieri che cambia nazionalità passando dal condizionale comunale a quello geografico, contro la stessa quantità sotto ipotesi nulla (due permutazioni indipendenti).

		osservata	nulla	eccesso
Brescia	per quartiere	0,197	0,094	2,08
	per sezione	0,408	0,393	1,04
Parma	per quartiere	0,156	0,074	2,10
	per sezione	0,530	0,412	1,29
Bologna	per quartiere	0,169	0,066	2,57
	per sezione	0,421	0,417	1,01

A livello di quartiere l'informazione è sostanziale e simile ovunque: 2,1-2,6 volte quanto si sposterebbe per caso.

Una fonte povera ma geograficamente risolta vale quanto una ricca. Brescia (19 paesi più un residuo del 10,8%, senza sesso) ottiene 2,08 contro il 2,57 di Bologna (155 paesi con sesso). Per i comuni futuri: basta una tabella paese × quartiere, anche troncata alle prime venti nazionalità.

Brescia e Bologna a livello di sezione danno 1,04 e 1,01, cioè nulla — correttamente, perché il loro condizionale si ferma alla zona. Questo valida la metrica per via negativa. Il 1,29 di Parma è l'unico eccesso reale sotto il quartiere.

I microdati di Parma: condizionale o validazione

202.111 righe, una per residente, con SEZ21, Cittad, ETA, Sesso, Ncomp, Relpar, SEZ21_ID = "34027" + SEZ21.zfill(7), aggancio 99,9%.

uso	variabili
condizionale	Cittad × SEZ21 × Sesso
validazione esterna, mai usate per generare	ETA × SEZ21; Ncomp, Relpar; co-occorrenza di nazionalità nella stessa sezione; Tipores

7. Limiti e assunzioni dichiarate

n.	assunzione	dove
(4')	paese ⊥ tutto (area, sesso, geo) — geo secondo il tier; per il tier 0 non vincola	§6
(6)	target AVQ ⊥ tutto (sesso, macroetà, istruzione4, regione)	AVQ
(8)	sezione ⊥ (istruzione, condizione, background) (zona, sesso, età3, cittadinanza)	anello 3
(9)	entro il quinquennio, l'età segue la distribuzione comunale per anno singolo	anello 3
(10)	l'indirizzo è uniforme fra i civici della sezione	anello 3
(11)	nessuna struttura familiare	anello 3

Limiti della risoluzione per età

- **L'istruzione ha risoluzione effettiva di 4 classi d'età, non 8.** Il vincolo usa Y9-24, Y25-49, Y50-64, Y_GE65; dentro ogni classe la distribuzione viene da un **IPF con soglie minime di conseguimento** (elementare 10, media 13, diploma 18, laurea_o_its 20, post_laurea 22).
- **Resta sovrastimata media nel bin 9-14.**
- **Effetto coorte perso fra 65-74 e 75+.**
- **Il background migratorio ha risoluzione di zona, non di sezione.**

Convenzioni per "assente" — non uniformate

forma	dove
<code>non_applicabile</code> (stringa)	<code>condizione</code> , <code>origine_genitori</code> , 20 delle 21 AVQ
<code>NaN</code>	<code>area</code> , <code>via</code> , <code>civico</code>
nessuna	<code>SALUTE</code> , <code>paese</code> (= <code>Italia</code>) per gli italiani)

8. Punti aperti

Aggiungere la cittadinanza alla cella di condizionamento AVQ

Analisi completata il 29/07/2026, patch predisposta e non applicata.

AVQ pubblica `CITTMi` (3 modalità: `1` italiana, `3` e `9` da identificare). L'effetto sulla **fiducia istituzionale** è **sostanziale e monotono**, ~1 punto su 10, replicato in due regioni indipendenti:

media pesata	ITA (1)	gr. 3	gr. 9
<code>PUNTIFI10</code> Comune, Lombardia	5,16	5,81	7,00
<code>PUNTIFI8</code> Regione, Lombardia	4,38	5,24	6,51
<code>PUNTIFI10</code> Comune, Emilia	5,22	6,09	6,59
<code>PUNTIFI8</code> Regione, Emilia	4,97	5,97	5,78

I non italiani si fidano delle istituzioni PIÙ degli italiani — direzione opposta all'intuizione, ma nota in letteratura. Nessun effetto invece su `AMBIENTE` (2,37/2,30/2,14) né su `FIDUCIA` (1,75/1,77/1,84).

Numerosità: ~430 non italiani nel pool emiliano su due annate. Il livello di cella pieno non regge (~11 donatori), il secondo sì (~43). Serve il collasso gerarchico con la cittadinanza in priorità alta:

```
python
```

```
CELL_COLS = ["sesso", "macroeta", "istr4", "citt"]
CELL_LEVELS = [
    ["sesso", "macroeta", "istr4", "citt"],
    ["sesso", "macroeta", "citt"],
    ["macroeta", "citt"],
    ["sesso", "macroeta", "istr4"],
    ["sesso", "macroeta"],
    ["macroeta"],
]
```

Prima di applicare: identificare le modalità (3) e (9) in (METADATI/Classificazioni/).

Limite da dichiarare comunque: il campione AVQ di stranieri è autoselezionato sulla competenza linguistica. Descrive gli stranieri più integrati, quindi la fiducia istituzionale stimata è verosimilmente **sovrastimata**. Per un lavoro mirato la fonte giusta sarebbe *Condizione e integrazione sociale dei cittadini stranieri*.

Modena: due opportunità non sfruttate

Rilevate il 29/07/2026 esplorando il portale open data comunale.

Rioni: una partizione dieci volte più fine dell'ASC1. Il dataset *Serie storiche della popolazione residente* espone la popolazione per **37 rioni**, con cittadinanza binaria, età quinquennali e sesso, dal 2002 al 2024.

	zone	ab./zona	quota stranieri min → max
ASC1 (in uso)	4	46.149	0,124 → 0,255 (fattore 2)
rioni	37	4.968	0,039 → 0,590 (fattore 15)

Il guadagno **non** sarebbe sulla quota di stranieri — le sezioni sono già 59 volte più fini e (ST1) è dato censuario — ma sull'**assunzione (8)**: istruzione, condizione professionale e background migratorio hanno risoluzione di zona, e con quattro zone da 46.000 abitanti sono di fatto uniformi sulla città. Con 37 zone acquisterebbero struttura geografica reale, che in una città è forte proprio su quegli attributi.

Serve una **mappatura sezione → rione**, ottenibile dai civici se il portale pubblica la numerazione civica con il rione (stesso meccanismo del voto di maggioranza già usato altrove), oppure per join spaziale dalle geometrie dei rioni. Da verificare che i rioni **partizionino** le sezioni: una sezione a cavallo introdurrebbe un errore da misurare.

Costo: è una **deviazione dallo standard ISTAT**. Il registro dovrebbe ammettere livelli non-(COM_ASC*), e il confronto fra città si complicherebbe. (|x|) K9C passerebbe da 645.120 a 5.967.360.

Cittadinanza per paese: non disponibile. I dataset demografici del portale (*Popolazione residente dal 1995, Serie storiche, Emigrati per sesso cittadinanza ed età*) hanno tutti **CITTADINANZA** binaria. Modena resta quindi **tier 0**, ed è il caso che ha permesso di collaudare il ramo di default (§6).

Serie storiche 2002-2024 per rione. Non serve alla pipeline, che è statica, ma è materiale per una domanda diversa: come si è formata la geografia attuale. L'anzianità di insediamento di una comunità in un quartiere è un predittore di attaccamento al luogo, potenzialmente rilevante per il lavoro sulla percezione ambientale.

Altri punti aperti

- **AMBIENTE** non varia per quartiere. È il candidato numero uno per il tilt areale. La cittadinanza non basta: serve un'altra covariata di zona e un target areale osservato su cui calibrarla — senza il quale il parametro del tilt resterebbe un'assunzione travestita da risultato.
- `assign_nationality.py` è quasi vestigiale. `area` e `paese` che produce sono interamente sovrascritti da `enrich.py`; l'unica funzione residua è generare il file che `assign_avq.py` legge, al quale servono solo `sezzo`, `eta`, `istruzione`.
- **Ramo di remapping ASC2→ASC1 irraggiungibile** in `assign_nationality.py`: `G.verificalivello()` interviene prima.
- **Provenienza del paese non tracciata**: non esiste `paese_fonte`.
- **Struttura familiare.** `Ncomp` e `Relpar` dei microdati di Parma.
- **K10C.** Esiste solo per Brescia e porta l'istruzione pre-correzione.
- **San Vito dei Normanni** (`074017`): `COM_ASC1` ha un solo valore, resterà un comune senza articolazione zonale.
- **Confronto fra città.** Risoluzioni diverse su partizioni di taglia diversa: per un confronto rigoroso conviene rigenerare al **quartiere**.

9. Dove sono i dati reali, per il confronto

```
{COMUNE}/constraints_2024/  
  cs_K9C.json      vincoli con alpha target, categories, domain_sizes,  
zona_nomi  
  targets_K9C.json tabelle target per blocco  
  fit_K9C.json     lambdas, MRE, entropia, supporto  
  manifest.json    fonte e tipo (hard/soft) di ogni blocco  
{COMUNE}/zona_2023/ z1..z4, z6, zona_nomi  
data/submun/{slug}_sezioni_2023.csv  
  P1, ST1, ST16/ST19, P30-P45 e P67-P82, ST25-ST30  
data/opendata/{COMUNE}/  fonti comunali per §6  
data/avq/anni/avq{Y}/METADATI/AVQ_Tracciato_{Y}.html  codifiche AVQ
```

Versione senza condizionale geografico, per i confronti:

```
bash
```

```
python scripts/enrich.py 037006 --anno 2024 --no-tier \  
--out popolazione_K9C_avq_full_tier0.csv
```

Geometrie per la visualizzazione

```
data/geodata/{regione}/R{NN}_21/SHP/R{NN}_21_WGS84.shp  
R03 Lombardia      R08 Emilia-Romagna    R16 Puglia      CRS EPSG:32632
```

I poligoni delle zone si ottengono per **dissolve delle sezioni**:

```
python
```

```
col = G.livello_col("034027")  
s = gpd.read_file(G.path_shp("emilia_romagna"))  
s = s[s.PRO_COM == G.procom("034027")]  
zone = s.dissolve(by=col).reset_index().to_crs("EPSG:4326")  
zone["nome"] = zone[col].astype("Int64").astype(str).map(G.zona_nomi("034027"))
```

Per Bologna (`G.livello_col`) è (`COM_ASC2`): un dissolve su (`COM_ASC1`) darebbe 6 poligoni invece di 18, e i codici — sovrapposti fra livelli (§3.1) — mapperebbero comunque su dei nomi, sbagliati.

10. Riepilogo numerico

Esecuzioni del 29 luglio 2026.

	Brescia	Parma	Bologna	Modena
codice ISTAT	017029	034027	037006	036023
regione (AVQ)	Lombardia (30)	Emilia-R. (80)	Emilia-R. (80)	Emilia-R. (80)
popolazione	198.259	198.121	390.098	184.597
attributi	40	40	40	40
zone	33 (ASC1)	13 (ASC1)	18 (ASC2)	4 (ASC1)
sezioni	1.822	1.357	2.224	2.186
sezioni occupate	1.773	1.313	2.152	2.118
civici ANNCSU	49.730	35.826	77.595	60.488
stranieri (censimento)	37.478	34.436	58.963	28.415
stranieri (sintetici)	37.475	34.434	59.130	28.412
quota stranieri	18,9%	17,4%	15,1%	15,4%
donatori AVQ nel pool	8.111	4.629	4.629	4.629
donatori distinti usati	8.108 (100,0%)	4.618 (99,8%)	4.625 (99,9%)	4.617 (99,7%)
riuso medio donatore	24,5×	42,9×	84,3×	40,0×
supporto X K9C	5.322.240	2.096.640	2.903.040	645.120
tier paese (§6)	1	3	2	0

Il riuso dei donatori è un tetto strutturale. Il 99,7-100% del pool viene usato almeno una volta: la diversità dell'anello 2 è satura. Ma il numero di donatori usati **non** è la numerosità efficace, che è più bassa di un fattore 2,8 per il riuso diseguale: vedi §13.3.

Validazione per sezione

	sezioni	media/sez	MAE pop.	corr	MAE stranieri	corr	MAE UE	corr
Brescia	1.822	108,8	1,58	0,9998	0,98	0,9989	0,13	0,9976
Parma	1.357	146,0	1,43	0,9999	1,13	0,9985	0,16	0,9980
Bologna	2.224	175,4	1,36	0,9999	1,08	0,9983	0,17	0,9982
Modena	2.186	84,4	0,74	0,9999	0,63	0,9993	0,09	0,9969

I totali comunali coincidono esattamente con il censimento. Gli scarti sui totali di stranieri (-3, -2, +167, -3) sono entro $0,7\sigma$ del rumore multinomiale.

Struttura spaziale: la sezione conta molto più della zona

Decomposizione della varianza della quota UE fra stranieri, al netto della discretizzazione. **Calcolata dal file sezioni**, cioè dalla verità censuaria.

	abitanti/zona	var tra zone	var reale dentro	sovradis.	rapporto
Brescia (33 zone)	6.008	0,00168	0,00991	2,89×	5,9×
Parma (13 zone)	15.240	0,00110	0,01249	3,50×	11,3×
Bologna (18 zone)	21.672	0,00072	0,01124	3,04×	15,7×
Modena (4 zone)	46.149	0,00040	0,01756	3,17×	43,5×

Il rapporto cresce monotonamente con la dimensione media delle zone, su quattro partizioni da 4 a 33 unità. Condizionare sul quartiere perde l'85-98% del segnale compositivo.

Quantità e composizione hanno scale spaziali diverse. Modena lo rende evidente: le quattro zone distinguono nettamente il Centro Storico (25,5% di stranieri) dal resto (12,4-16,9%), ma la composizione *per origine* di quegli stranieri è quasi identica ovunque. L'accessibilità economica del patrimonio abitativo opera a scala di quartiere; la segregazione per nazionalità opera per isolato.

Validazione esterna puntuale

	fonte comunale	sintetico (cens. 2023)	rapporto
Primo Maggio (Brescia), quota stranieri	0,329	0,293	1,12
Bologna, quota UE fra stranieri	0,214	0,213	1,00
Modena, popolazione per quartiere (4 zone)	—	—	0,982- 1,007

Un fatto rilevante per il progetto Caffaro

Fiumicello	0,368	Buffalora	0,088
Centro Storico Nord	0,314	Villaggio Violino	0,073
Primo Maggio	0,293		

Fiumicello, uno dei due quartieri della **ZonaCaffaro**, ha la più alta quota di stranieri della città — il doppio della media comunale. Ma **AMBIENTE**, **FIDUCIA** e le **PUNTIFI** sono condizionate su sesso, età e istruzione e **non** su cittadinanza né sulla geografia (§8).

11. Due principi metodologici ricorrenti

11.1 Rapportare sempre all'ipotesi nulla

Ogni metrica che scala con la numerosità di cella va rapportata alla propria ipotesi nulla prima di essere confrontata fra configurazioni diverse. Quattro occorrenze, stessa forma:

- 1. **Varianza compositiva della quota UE (§10)** — isolata con un test di sovradisersione contro l'assegnazione casuale entro zona.
- 2. **Distanza compositiva fra tier (§6)** — il 0,569 grezzo di Parma è per il 79% discretizzazione; l'eccesso reale è 1,29.
- 3. **Pavimento MRE del PCD** (`nota_mre_floor_v01.tex`) — la formula $1/(2\sqrt{N})$ del paper GibbsPCD confonde errore assoluto e relativo.
- 4. **Numerosità effettiva di una popolazione hot-deck (§13.3)** — le correlazioni AVQ sembrano poggiare su ~200.000 osservazioni ma poggiano su un pool di 4.629 donatori, la cui numerosità **efficace** di Kish è 1.478-2.007 sull'intera popolazione e ~3.200 sull'universo di una singola variabile. Il conteggio dei donatori distinti sopravvaluta di un fattore 2,8; la correzione per grappolo familiare toglie un altro 40%.

In tutti e quattro i casi la metrica grezza ordinava le configurazioni in modo diverso — e talvolta inverso — rispetto alla metrica corretta.

Corollario: quando esiste una configurazione in cui il segnale è *noto essere assente*, va usata come taratura.

11.2 Due percorsi che devono coincidere sono un test permanente

Il confronto fra ramo tier e ramo comunale non serve solo a misurare il guadagno del condizionale geografico: è una **verifica incrociata**. Su Modena, dove il tier 0 deve riprodurre esattamente il comportamento comunale, la discrepanza residua ha rivelato due bug latenti (§6) presenti da sempre e invisibili a qualunque test su un solo ramo.

12. Aggiungere un comune nuovo

Procedura ricavata dall'aggiunta di Modena (29/07/2026). Tempo complessivo circa mezz'ora, di cui tre minuti di download vincolati dal rate limit ISTAT. Il grosso del lavoro umano sta nella **fase 2**.

Prerequisiti regionali (una volta per regione)

serve	dove
<code>Dati_regionali_2023.zip</code> → <code>R{NN}_..._sezioni.xlsx</code>	<code>data/submun/Dati_regionali_2023/</code>
shapefile basi territoriali <code>R{NN}_21_WGS84.shp</code>	<code>data/geodata/{regione}/R{NN}_21/SHP/</code>
indirizzario ANNCSU regionale	<code>data/geodata/{regione}/indirizzario*/</code>
voce in <code>G.REGIONI</code>	<code>gsp_common.py</code>

Poi, una volta sola per regione:

```
bash
python scripts/join_civici_sezioni.py {regione}
```

Processa **tutte le province** della regione, quindi i civici di ogni comune di quella regione sono già pronti.

Fase 0 — verifica preliminare (nessun download)

```
bash
python scripts/build_sezioni.py {CODICE} --regione {N} --dry-run
```

Funziona anche senza voce di registro. Riporta popolazione, numero di sezioni e, per ciascun livello `COM_ASC1/2/3`, quante zone e con quale distribuzione di popolazione.

Decisione: quale livello usare. Criteri emersi finora:

n. zone	ab./zona	giudizio
1	—	nessuna articolazione: comune K6C/K8C senza zona
4-6	45-65k	grossolano ma usabile (Modena)
13-18	15-22k	buono
33+	~6k	ottimo
zone con < ~500 ab.	—	inutilizzabili: celle vuote nei vincoli Z

Se esistono più livelli, scegliere quello con la cardinalità migliore purché non abbia code minuscole (Bologna ASC3 ha 90 aree ma la più piccola ha 13 abitanti: scartato).

Fase 1 — bootstrap del registro

Voce **parziale** in G.COMUNI, con nomi: None:

python

```
"036023": {
    "nome": "Modena", "slug": "modena", "regione": "emilia_romagna",
    "livello": "quartieri",
    "livelli": {
        "quartieri": {"col": "COM_ASC1", "n": 4,
                      "nomi": None, "parent": None},
    },
},
```

bash

```
python scripts/build_sezioni.py {CODICE}
```

Scrivi data/submun/{slug}_sezioni_2023.csv.

Fase 2 — denominazioni delle zone (il punto critico)

Dove cercarle: portale open data comunale, sito istituzionale, delibere sulle circoscrizioni. Non esistono in nessun file ISTAT.

Come verificarle: §3.2, almeno due assi concordanti. Il metodo (a), baricentri dei civici, richiede solo il file civici già generato:

python

```

c = pd.read_csv(G.path_civici(comune), dtype={"CODICE_ISTAT": str},
               low_memory=False)
c = c[c.CODICE_ISTAT == comune]
c = c[pd.to_numeric(c.COM_ASC1, errors="coerce").fillna(0) != 0]
c["z"] = pd.to_numeric(c.COM_ASC1, errors="coerce").astype("Int64").astype(str)
lon0, lat0 = c.COORD_X_COMUNE.mean(), c.COORD_Y_COMUNE.mean()
g = c.groupby("z").agg(civici=("COORD_X_COMUNE", "size"),
                     lon=("COORD_X_COMUNE", "mean"), lat=("COORD_Y_COMUNE", "mean"),
                     dlon=("COORD_X_COMUNE", "std"), dlat=("COORD_Y_COMUNE", "std"))
g["est_km"] = (g.lon-lon0)*111*np.cos(np.radians(lat0))
g["nord_km"] = (g.lat-lat0)*111
g["raggio_km"] = np.sqrt((g.dlon*111*np.cos(np.radians(lat0)))**2 + (g.dlat*111

```

Poi il metodo (b), concentrazione dei toponimi, cercando in **ODONIMO** i nomi che compaiono nelle denominazioni.

Non saltare questa verifica: l'incidente di Bologna (§3.2) è passato inosservato per settimane e ha prodotto mappe con i nomi scambiati.

Infine si completa il registro e:

```

bash

python scripts/gsp_common.py --check {CODICE}

```

Tutto verde tranne le directory di lavoro, che non esistono ancora.

Fase 3 — dati ISTAT via SDMX

```

bash

python scripts/fetch_comune.py {CODICE} --explore # gratis: strutture in cache
python scripts/fetch_comune.py {CODICE}          # 11 tavole, ~3 min

```

L'**--explore** verifica che il comune sia nelle codelist territoriali; non garantisce che le osservazioni esistano.

Rate limit ISTAT: 5 query/minuto, violazioni = blocco IP di giorni. Il throttle è a 15 s ed è condiviso fra processi; il guard su 429/403/503 ferma tutto invece di martellare.

Verifica obbligatoria — il totale SDMX censuario deve coincidere con **P1** del file sezioni:

```
python
```



```
d = pd.read_csv(os.path.join(G.path_comune(comune),
                                "cens_sesso_eta_cittadinanza_decoded.csv"), low_memory=False)
d["n"] = pd.to_numeric(d.OBS_VALUE, errors="coerce").fillna(0)
print(d[d.TIME_PERIOD.astype(str)=="2023"].n.sum() / 8) # = P1
```

Il fattore 8 vale perché ogni persona è contata due volte per ciascuna delle tre dimensioni che variano (sesso, cittadinanza, età), una nella propria modalità e una nell'aggregato. Su tutti e quattro i comuni finora il risultato è stato **esatto al singolo abitante**.

Fase 4 — anello 1 (MaxEnt)

```
bash

python scripts/build_zona_tables.py {CODICE}
python scripts/build_constraints.py {CODICE} --anno 2024
python scripts/cs_build.py {CODICE} --anno 2024 --livello K9C
python scripts/fit_cs.py {CODICE} --anno 2024 --livello K9C --eps 1e-8 \
    --min-alpha 2e-4 --sparse --no-gibbs
```

Da controllare, nell'ordine:

- `build_zona_tables`: `attesi {n}` e il `[sanity]` top-5 per quota stranieri — deve essere geograficamente plausibile;
- `build_constraints`: **passare sempre `--anno 2024`** (il default è 2025, che salterebbe i blocchi C7/C8 con un `print` e non un errore); il preflight deve dare dieci `ok`;
- `cs_build`: `|X| = 161.280 × n_zone`;
- `fit_cs`: `MRE( $\alpha > 0$ )  $\approx 4 \cdot 10^{-4}$` , e `massa su celle escluse: 0.00e+00`.

Le celle escluse post-hoc devono valere `|X|/2 + (esclusioni K7C) × 15`; metà del supporto è impossibile perché metà delle combinazioni `background × origine_genitori` è logicamente incoerente.

Fase 5 — anelli 2 e 3

```
bash
```

```
OPT=PUNTIFI1,PUNTIFI2,PUNTIFI3,PUNTIFI4,PUNTIFI5,PUNTIFI6,PUNTIFI7,PUNTIFI8,PUN
```

```
python scripts/assign_nationality.py {CODICE} --anno 2024 \  
--pop-file popolazione_K9C.csv --out popolazione_K9C_naz.csv
```

```
python scripts/assign_avq.py {CODICE} --anno 2024 \  
--pop-file popolazione_K9C_naz.csv --out popolazione_K9C_avq.csv \  
--targets AMBIENTE,FIDUCIA,SALUTE,CRONI,FUMO,MH,BMI,BMIMIN,CPESO \  
--targets-opt $OPT
```

```
python scripts/enrich.py {CODICE} --anno 2024
```

Il `--pop-file` esplicito serve dove esistono più livelli K: l'auto-detect prende il più ricco.

Fase 6 — validazione finale

```
bash
```

```
python scripts/gsp_common.py --check {CODICE} # tutto verde  
head -1 ../popolazione_K9C_avq_full.csv | tr ',' '\n' | wc -l # 40
```

Nel log di `enrich`:

riga	valore atteso
<code>[3c] paese: tier N</code>	100% dalla geografia, 0% riserva comunale
<code>[3e] indirizzo</code>	≥ 99,5% dalla sezione
<code>MAE pop.</code>	0,7-1,6, correlazione ≥ 0,9998
totali	coincidenti col censimento; stranieri entro ~1 σ

Cosa cercare negli open data comunali (tier 1-3)

Il condizionale geografico del paese richiede una tabella `paese × unità territoriale`, eventualmente con sesso. **La cittadinanza binaria non basta**: serve il paese di dettaglio.

cercare	esito
«stranieri per cittadinanza e quartiere/zona»	tier 1 o 2
microdati anagrafici con <code>Cittad</code> e sezione	tier 3
solo <code>italiana/straniera</code>	tier 0
nessun portale	tier 0

Il tier 0 è il caso normale e non richiede nulla. Le denominazioni dei paesi vanno riconciliate con `G.SINONIMI_PAESE`, che è nazionale e già copre i casi ricorrenti.

Modi di fallire, osservati

sintomo	causa
nomi di zona plausibili ma sbagliati	mappa <code>codice → nome</code> permutata: verificare su due assi (§3.2)
merge sui codici zona che «funziona» ma dà nomi assurdi	codici ASC1/ASC2 sovrapposti (§3.1)
blocchi C7/C8 «saltati»	<code>--anno</code> dimenticato: il default 2025 non ha <code>cens_migr_backg</code>
<code>build_zona_tables</code> esce con <code>attesi N, trovati M</code>	il file regionale è cambiato, o il livello nel registro è sbagliato
dissolve delle sezioni con troppi pochi poligoni	usato <code>COM_ASC1</code> dove il registro dice <code>COM_ASC2</code>

13. Lo strato donatore AVQ — anatomia, numerosità efficace, limiti

Ricostruita il 30/07/2026 leggendo `assign_avq.py`, i microdati grezzi e la nota metodologica ISTAT «Aspetti della vita quotidiana — anno 2024, aspetti metodologici dell'indagine» (2026). È la sezione da cui partire per la parte su dati e limiti di un paper che usi lo strato AVQ.

Ogni quantità è marcata con la provenienza: **misurato** da un conteggio sui file, **dichiarato** dalla nota ISTAT, **aperto** dove non è determinata.

13.1 Composizione del pool: quali annate, e perché

Il pool impila 2023 e 2024, non tutte e tre le annate disponibili. Il meccanismo è in

load_avq:

```
python
missing = [c for c in base + targets if c not in d.columns]
if missing:
    print(f"[avq] {y}: variabili NECESSARIE mancanti {missing}, annata saltata")
    continue
```

Un'annata viene **scartata per intero** se le manca una sola variabile fra i `--targets`. I tracciati differiscono — 741 colonne nel 2022, 708 nel 2023, 736 nel 2024 — e `CRONI` **non esiste nel 2022**. Essendo fra i target obbligatori, il 2022 è caduto.

Il secondo filtro è silenzioso: `ISTRMI_MAP` mappa quattro codici (1, 7, 9, 10) e `ISTRMi = 99`, «**titolo non indicato**», **non è mappato**. Quei record prendono `istr4 = NaN` e spariscono in `dropna(subset=CELL_COLS)` senza messaggio.

Il conto si chiude esattamente (**misurato**):

	2022	2023	2024	2023+2024	- <code>ISTRMi</code> 99	pool
Emilia-Romagna	2.380	2.210	2.471	4.681	-52	4.629 ✓
Lombardia	3.793	4.010	4.139	8.149	-38	8.111 ✓

I file completi contengono 128.777 record nazionali (42.022 + 41.750 + 45.005): quello è l'inventario, non il pool.

Il costo di `CRONI`, e il compromesso che comporta

Spostare `CRONI` fra le opzionali farebbe rientrare il 2022:

pool Emilia-Romagna	4.629 → 7.061	×1,53
n_eff (PUNTIFI10)	3.220 → ~4.900	
banda di confidenza	×7,0 → ×5,7	

Ma **non è un miglioramento netto**. Le variabili presenti solo nel 2024 vedrebbero il proprio denominatore crescere, e la loro copertura scenderebbe dal 42-43% al ~28%. Il compromesso è fra numerosità efficace di tutte le variabili e copertura delle quattro a rotazione. **Da decidere consapevolmente**, con il numero accanto: una variabile obbligatoria assente in un'annata costa un terzo del pool a tutte le altre venti.

Perché le coperture sono quelle

La rotazione del modulo AVQ è **reale e dell'ISTAT**: `PUNTIFI6`, `PUNTIFI7`, `VOTOUSL` e `FORZE_ARMATE` non esistono nei tracciati 2022 e 2023, `PUNTIFI13` manca nel 2023. Ciò che dipende da noi è il **denominatore**: con il pool a due annate il 2024 vale il 52,8%, e la copertura osservata si prevede a due decimali (**misurato**):

PUNTIFI6	$0,528 \times 0,876$ (universo 15+) $\times 0,92$ (non risposta) = 0,425	
		osservato 0,427
PUNTIFI13	stessa previsione	osservato 0,424
VOTOUSL	$0,528 \times 0,876 \times 0,38$ (filtro esperienza) = 0,176	
		osservato 0,202

Una voce della batteria manca

Nel tracciato la batteria occupa dodici posizioni consecutive (525-536) con identica scala e formulazione. Undici si chiamano `PUNTIFI{n}`; la dodicesima si chiama `FORZE_ARMATE`, posizione 534. Non essendo elencata fra i target, **non è nella popolazione**: la batteria sintetica ha undici voci su dodici.

Corollario di metodo. Sia la lista dei target sia `ISTRMI_MAP` sono tabelle scritte a mano che **falliscono in silenzio**: producono assenze, non errori, e le assenze non si vedono finché non si cercano. In un pomeriggio ne sono emerse tre — `FORZE_ARMATE`, l'annata 2022, i 52 donatori senza titolo di studio — e nessuna aveva mai prodotto un messaggio. Le altre corrispondenze compilate a mano o per prefisso meritano lo stesso controllo.

13.2 Il condizionamento, definizioni effettive

ETAMi → macroeta	1-4 → "0-13" 10-11 → "35-54" 14-15 → "65+" 5-9 → "15-34" 12-13 → "55-64"
bin censuario → macroeta	0-8, 9-14 → "0-13" 35-49 → "35-54" 65-74, 75+ → "65+" 15-24, 25-34 → "15-34" 50-64 → "55-64"
ISTRMi → istr4	1 → terziario 9 → media minori → "eta_infantile" (chiave dedicata) 7 → diploma 10 → elementare_o_meno
collasso	[sesso, macroeta, istr4] → [sesso, macroeta] → [macroeta] → pool regionale
soglia	min_record = 20 donatori per usare il pool di cella

L'approssimazione dichiarata, quantificata. Il codice annota «50-64 → 55-64, approssimazione: 50-54 assimilato a 55-64»: un cinquantenne sintetico riceve le AVQ da un donatore di 55-64 anni. La classe quinquennale 50-54 vale 14.724 individui su Modena e 15.899 su Parma, cioè il **35% del bin (50-64)** e l'**8% della popolazione (misurato)**. Per salute percepita, fumo e benessere psicologico cinque anni a quell'età non sono trascurabili.

Quanto scatta il collasso gerarchico: non serve stimarlo. `assign_avq.py` stampa `[donor]` individui per livello di condizionamento effettivo con le percentuali dei tre livelli più il fallback regionale. La stima indiretta dalle firme — 15,3% confinate alla cella piena su Modena, 8,3% su Bologna — è un limite inferiore contaminato dalle collisioni fra donatori, e va sostituita col dato del log.

13.3 Numerosità efficace

La formula

Tutti gli individui sintetici che condividono un donatore hanno **lo stesso valore** su tutte le variabili AVQ. Per la media su `(n)` individui provenienti da `(D)` donatori con molteplicità `(m_d)`:

$$\bar{x} = (1/n) \sum_d m_d x_d \quad \text{Var}(\bar{x}) = \sigma^2 \sum_d m_d^2 / n^2 = \sigma^2 / n_{\text{eff}}$$

$$n_{\text{eff}} = n^2 / \sum_d m_d^2$$

che è la formula di Kish. **Il conteggio dei donatori distinti non basta:** sopravvaluta `(n_eff)` di un fattore 2,8 quando il riuso è diseguale, perché Kish è una statistica di secondo momento e vive nella coda della distribuzione dei riusi.

Interpretazione: condizionatamente al pool, i valori AVQ sintetici sono una funzione deterministica dell'assegnazione. L'incertezza rilevante per un'inferenza sulla popolazione reale è quella di campionamento **del pool**, e `(n_eff)` misura quanti rispondenti indipendenti stanno sotto la statistica.

L'universo, non la copertura

`(n_eff)` va calcolato **per variabile, sul suo universo**. Calcolarlo sull'intera popolazione lo dimezza, perché le firme dei minori collassano su quattro valori e producono classi enormi che dominano `(Σm²)` pur non partecipando alla variabile (**misurato**, Modena):

popolazione intera	n = 184.597	n_eff = 1.520	efficienza 0,36
PUNTIFI10, 15 e più	n = 157.974	n_eff = 3.220	efficienza 0,80

Gli universi si riconoscono dalla forma, non dalla percentuale: `(MH)` copre lo 0,876 e la quota di 15 anni e più vale 0,8763. Scrivere «copertura 87,6%» descrive un sintomo; «universo: 15 anni e più» descrive il dato.

Tre meccanismi distinti, da non confondere:

	riconoscimento	esempi
universo	0,00 sotto una soglia d'età, ~0,98 sopra	tutte le PUNTIFI , MH , AMBIENTE
rotazione del modulo	costante in ogni classe d'età	PUNTIFI6 , PUNTIFI7 , PUNTIFI13 , VOTOUSL
filtro per esperienza	cresce con l'età	VOTOUSL : 0,12 a 15-24, 0,30 a 65-74

Il terzo **non è ignorabile**: chi giudica l'ASL è chi ci è stato, quindi più anziano e più malato. La media non è «il giudizio dei modenesi sull'ASL» ma «il giudizio di chi c'è stato».

n_eff di Kish è un limite superiore

L'AVQ **campiona famiglie e intervista tutti i componenti** (§3.1 della nota metodologica): 45.005 individui in 19.775 famiglie, **2,28 per famiglia (dichiarato)**. I donatori non sono osservazioni indipendenti, e Kish li tratta come tali. La correzione è il fattore di grappolo $\frac{1}{1 + (k-1) \cdot \rho}$.

Le ICC calcolate impilando le annate sono **contaminate**, perché PROFAM riparte da 1 ogni anno e famiglie di anni diversi finiscono nello stesso grappolo — si riconosce da $k = 5,67$ invece di ~2. Le sole stime pulite sono quelle delle variabili presenti in **una sola annata**, per cui PROFAM è di fatto univoco (**misurato**):

	ρ	k	fattore
PUNTIFI6	0,652	2,01	1,66
PUNTIFI7	0,613	2,01	1,62
FORZE_ARMATE	0,589	2,03	1,61
VOTOUSL	0,556	1,43	1,24

$\rho \approx 0,6$ per la **fiducia istituzionale**, molto più dello 0,2-0,3 che si assumerebbe per default: le opinioni politiche si condividono in casa.

Modena, PUNTIFI10

n = 157.974

n_eff di Kish

3.220

banda × 7,0

/ fattore 1,66

1.941

banda × 9,0

| **aperto**: da rifare con chiave ANNO|PROFAM su tutte le variabili.

Gli effetti di disegno si compongono

$n_{eff} / 1,66$ corregge solo il grappolo familiare. Restano:

- **stratificazione e calibrazione.** Il campione è calibrato su 24 totali noti per regione — sesso $\times$ otto classi d'età, sei tipologie comunali, stranieri per sesso (**dichiarato**) — che **coincidono con le nostre variabili di condizionamento**. Per stime *demografiche* la calibrazione riduce la varianza sotto quella di un campione casuale semplice: dal modello del prospetto 2 si ricava un deff di **0,72-0,75** per l'Emilia-Romagna. Ma quel modello è interpolato sulle stime pubblicate, in maggioranza demografiche: per una variabile attitudinale, che età e sesso non predicono, la calibrazione non aiuta e il deff è presumibilmente ≥ 1 . **aperto**;
- **sovrastima dichiarata.** Negli strati NAR si estrae un solo comune e la varianza si stima per collassamento degli strati, che sovrastima; anche trattare l'estrazione come con reimmissione sovrastima (**dichiarato**, §6.2 della nota). Gli errori pubblicati sono quindi conservativi;
- **le firme sottostimano i donatori del 9-10%:** nel pool emiliano 418 donatori e in quello lombardo 821 hanno 21-uple indistinguibili (**misurato**). L'errore va nella direzione prudente.

Il modello per calcolare gli errori campionari AVQ è disponibile e verificato: $\log(\epsilon^2) = a + b \cdot \log(\hat{Y})$, con per l'Emilia-Romagna, persone, $a = 8,799059$ e $b = -1,134869$. Riproduce il prospetto 4 a tre decimali.

La formulazione generale

Qualunque popolazione sintetica che imputi attributi da un'indagine donatrice eredita la numerosità di quella indagine come tetto, indipendentemente da quanti individui contiene — e la eredita ridotta dal riuso diseguale (Kish) e dal disegno dell'indagine (grappoli, stratificazione, calibrazione).

misurato su quattro comuni: n_{eff} sull'intera popolazione sta fra 1.478 e 2.007, con popolazioni da 184.597 a 390.098. Bologna ha 2,1 volte gli abitanti di Modena e n_{eff} più grande del 5%; **Parma ha più individui di Modena e n_{eff} più basso**. La dimensione del comune non entra: il tetto è il pool regionale.

	individui	firme	n_{eff}	efficienza
Brescia	198.259	7.287	2.007	0,28
Modena	184.597	4.199	1.520	0,36
Parma	198.121	4.200	1.478	0,35
Bologna	390.098	4.207	1.599	0,38

13.4 Cosa il pool eredita dall'indagine

dichiarato, nota metodologica ISTAT 2024:

- **disegno a due stadi**, comuni poi famiglie; nei comuni NAR un solo comune campione per strato, con probabilità proporzionale alla dimensione;
- **grappoli familiari**: selezionate le famiglie, si intervistano tutti i componenti di fatto;
- **esclusi gli istituti di convivenza**. La popolazione sintetica include invece le convivenze (50–630 per comune), che ricevono quindi donatori da un universo che non le contiene. **aperto**: entità dell'effetto;
- **proxy sotto i 14 anni**: le informazioni dei minori sono fornite da un adulto. Gli universi osservati sono filtri di questionario, non restrizioni campionarie;
- **facoltà di non rispondere** su quesiti sensibili, che spiega parte del ~2% di non risposta dentro l'universo.

Il file *public use* dà 2.471 record emiliani per il 2024 contro i 2.486 del prospetto 1. Quindi in meno, lo 0,6%: citando il prospetto e lavorando sul file, i due numeri non coincidono.

13.5 Una verifica che passa

La copertura delle AVQ nella popolazione sintetica è quella del pool, non un artefatto dell'assegnazione (**misurato**):

	pool ER	popolazione Modena
SALUTE	1,000	1,000
MH	0,892	0,876
AMBIENTE	0,883	0,864
PUNTIFI1	0,874	0,857

Scarto costante del 2% su tutte, e

SALUTE

 esatta: **l'hot-deck trasmette il pattern di mancanza del donatore intatto**, come l'assunzione (6) richiede. È una verifica diretta dell'anello 2 che non era mai stata fatta.

13.6 Da rivedere prima di un paper

1.

CRONI

 fra le opzionali? +53% di pool e +50% di

n_eff

 su tutte le variabili, al prezzo della copertura delle quattro a rotazione (§13.1).
2.

FORZE_ARMATE

 nei target: la batteria è incompleta di una voce su dodici.
3.

ISTRMi = 99

: 52 e 38 donatori scartati in silenzio. Da dichiarare o mappare su una classe «non indicato» con cella propria.
4. ICC corretta con chiave

ANNO | PROFAM

, su tutte le variabili.

5. **deff per variabili attitudinali:** il modello ISTAT è tarato sulle stime demografiche e non si applica.
6. **Convivenze:** ricevono donatori da un universo che le esclude.
7. **Log di generazione:** le percentuali per livello di collasso sono già stampate e vanno recuperate invece che stimate.
8. **Fonte delle medie nazionali della batteria,** mai citata (§2.2).

Changelog

v1.7 — 30/07/2026 Nuova §13, lo strato donatore AVQ: composizione effettiva del pool (2023+2024, per `CRONI` assente nel 2022, meno i record con `ISTRMi`=99), definizioni vere del condizionamento, numerosità efficace di Kish per universo di variabile, correzione per grappolo familiare, e cosa il pool eredita dal disegno campionario ISTAT. Corretti §2.2 e §11.1: il numero di donatori distinti non è la numerosità efficace. Segnalata l'assenza di `FORZE_ARMATE` dalla batteria.

v1.6 — 29/07/2026 Nuova §12, procedura operativa per aggiungere un comune, ricavata dall'aggiunta di Modena. Annotate in §8 le due opportunità non sfruttate su Modena (37 rioni, serie storiche 2002-2024) e la conferma che il portale comunale non pubblica la cittadinanza per paese. §3.2 riorganizzata come metodo di verifica in quattro varianti.

v1.5 — 29/07/2026 Aggiunta Modena: primo comune **tier 0** collaudato end-to-end. Metodo di verifica delle denominazioni di zona. Corretti due bug di classificazione per etichetta anziché per codice. Nuova §11.2.

v1.4 — 29/07/2026 Analisi dell'effetto della cittadinanza sulle variabili AVQ (§8).

v1.3 — 29/07/2026 Dodici variabili di fiducia istituzionale su scala 0-10. Codifiche AVQ risolte sul tracciato ufficiale. Attributi da 28 a 40.

v1.2 — 29/07/2026 Condizionale geografico del paese collegato e attivo. §11.

v1.1 — 29/07/2026 Consolidamento in `gsp_common.py`. Correzione dei nomi delle zone di Bologna e dell'istruzione nei bin infantili.

v1.0 — 28/07/2026 Prima stesura.